

**PERBANDINGAN WAV2VEC2 DAN DATA2VEC TERHADAP
FITUR LATEN AUDIO UNTUK TILAWAH AL-QURAN**

TUGAS AKHIR

Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Teknik
pada jurusan Teknik Informatika Fakultas Sains dan Teknologi
Universitas Islam Negeri Sunan Gunung Djati Bandung

Oleh

MUJAHID ANSORI MAJID

1197050093



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI SUNAN GUNUNG DJATI
BANDUNG
2026M/1447H**

DAFTAR ISI

	Hlm.
DAFTAR ISI.....	i
DAFTAR GAMBAR.....	iii
DAFTAR TABEL	iv
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	4
1.3. Tujuan Penelitian.....	5
1.4. Batasan Masalah.....	5
1.5. Manfaat Penelitian.....	5
1.6. Kerangka Pemikiran	6
1.7. Sistematika Penulisan.....	9
BAB II KAJIAN LITERATUR	11
2.1. Tinjauan Pustaka	11
2.2. Landasan Teori.....	15
2.2.1. Kecerdasan buatan (Artificial Intelegents)	15
2.2.2. Deep Learning.....	15
2.2.3. Similarity Search.....	16
2.2.4. Vector Embedding	17
2.2.5. Self-Supervised Learning (SSL)	17
2.2.6. Wav2vec 2.0	17
2.2.7. Data2vec	20
2.2.8. Cosine Similarity	22
2.2.9. Metriks Evaluasi Retrieval.....	23
2.2.10. Dataset Quran-MD	25
2.2.11. Metode Penelitian CRISP-DM.....	25
BAB III METODOLOGI PENELITIAN	27
3.1. Business Understanding	27
3.2. Data Understanding.....	29
3.3. Data Preparation.....	30
3.4. Modeling	32

3.5.	Evaluation.....	34
3.6.	Deployment	36
BAB IV HASIL DAN PEMBAHASAN		38
4.1.	Hasil Business Understanding.....	38
4.1.1.	Identifikasi Masalah.....	38
4.1.2.	Tujuan Penelitian	39
4.1.3.	Kriteria Evaluasi dan Keberhasilan.....	40
4.2.	Hasil Data Understanding	42
4.2.1.	Karakteristik Himpunan data Mahasiswa	43
4.2.2.	Karakteristik Himpunan Data Quran-MD.....	44
4.2.3.	Cakupan relevansi dan Ukuran Skenario	45
4.2.4.	Kualitas Data.....	46
4.3.	Hasil Data Preparation.....	46
4.3.1.	Normalisasi Audio	46
4.3.2.	Pembagian set <i>dev</i> dan set <i>test</i>	49
4.4.	Modeling	50
4.4.1.	Ekstraksi Frozen Embedding per-lapisan	50
4.4.2.	Data Cleaning.....	51
4.4.3.	Similarity Scoring dan Ranking.....	51
4.5.	Evaluation.....	52
4.5.1.	Kinerja Retrieval Frozen Embedding	53
4.5.2.	Perbandingan Wav2vec2 dan Data2vec.....	54
4.5.3.	Lapisan Paling Informatif	Error! Bookmark not defined.
4.5.4.	Kinerja Retrieval Frozen Embedding	56
4.5.5.	Perbandingan Wav2vec2 dan Data2vec.....	Error! Bookmark not defined.
4.5.6.	Lapisan paling informatif.....	56
4.6.	Deployment (Pertimbangan Penerapan).....	57
4.6.1.	Skema Penerapan Sistem Retrieval.....	57
4.6.2.	Kelayakan penerapan berdasarkan temuan	57
BAB V KESIMPULAN DAN SARAN		59
5.1.	Kesimpulan.....	59
DAFTAR PUSTAKA.....		62

DAFTAR GAMBAR

Gambar 1.1 Kerangka Pemikiran.....	6
Gambar 2.1 Arsitektur Wav2vec2	20
Gambar 2.2 Arsitektur Data2vec	22
Gambar 4. 1 Hasil Evaluasi Tiap-tiap Layer	57

DAFTAR TABEL

Tabel 2.1 State of the art	11
Tabel 2.2 Konfigurasi Blok Konvolusi Temporal pada Encoder Audio.....	18
Tabel 3.1 Summary Statistic Dataset Query	Error! Bookmark not defined.
Tabel 4.1 Atribut dan Tipe Data Quran-MD.....	42
Tabel 4.2 Ukuran Data dan Cakupan Relevansi pada Setiap Skenario Evaluasi...	45
Tabel 4.3 Distribusi Pengetesan Dataset.....	52
Tabel 4.4 Kinerja Model Pada Setiap Skenario	53
Tabel 4.5 Selisih MAP pada kedua Model	54
Tabel 4.1 Atribut dan Tipe Data Quran-MD.....	42
Tabel 4.2 Ukuran Data dan Cakupan Relevansi pada Setiap Skenario Evaluasi...	45
Tabel 4.3 Distribusi Pengetesan Dataset.....	52
Tabel 4.4 Kinerja Model Pada Setiap Skenario	53
Tabel 4.5 Selisih MAP pada kedua Model	54

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perkembangan *deep learning* dalam pemrosesan audio telah didominasi oleh model Self-Supervised Learning (SSL), dengan Wav2Vec 2.0 menjadi salah satu model yang berpengaruh dalam perkembangan pembelajaran representasi ujaran berbasis *self-supervised learning*. Model ini mampu mempelajari representasi laten (*latent embeddings*) langsung dari data audio mentah tanpa memerlukan label transkripsi. Representasi yang dihasilkan kemudian dapat dimanfaatkan dan disesuaikan untuk berbagai tugas pemrosesan suara, dengan kebutuhan data berlabel yang lebih sedikit [1], [2]. Kemampuan model-model ini dalam menghasilkan fitur laten menjadi fondasi bagi tugas-tugas non-transkripsi, termasuk penelusuran kemiripan audio, yang mencocokkan potongan bacaan dengan entri yang paling mirip di *database* berdasarkan kemiripan *vector embedding*, bukan mencocokkan melalui teks hasil enkripsi [3]. Pendekatan ini telah didukung oleh temuan empiris yang menunjukkan bahwa sistem *retrieval* berbasis *latent embedding* yang dihasilkan langsung dari audio secara konsisten mengungguli pendekatan dua tahap dari ASR ke *retrieval*, karena kesalahan transkripsi pada tahap ASR akan berpropagasi dan mendegradasi kualitas pencocokan pada tahap selanjutnya [4], [5]. Karakteristik inilah yang menjadikan pendekatan berbasis *embedding* lebih sesuai untuk konteks pencocokan bacaan Quran, yang menuntut presisi tinggi pada aspek fonetik dan tajwid.

Al-Qur'an berisi teks berbahasa Arab dengan kaidah pelafalan (tajwid) yang ketat dan presisi tinggi, tidak hanya memiliki signifikansi religius bagi umat Muslim, tetapi juga merupakan *testbed* fonetik yang menantang secara teknis untuk sistem pemrosesan suara. Dalam eksperimen yang dilakukan oleh Toyin model berbasis *Arab-monolingual* mampu mengungguli model multibahasa yang memiliki ukuran dua kali lipat dalam tugas pengenalan ucapan Arab [6]. Temuan ini diperkuat oleh Li et

al yang secara kuantitatif menunjukkan bahwa encoder SSL yang dilatih menggunakan teks berbahasa inggris menghasilkan fitur fonetik yang kurang informatif ketika diterapkan pada inputan lintas-bahasa tanpa adaptasi domain [7]. Namun demikian, bukti-bukti tersebut terbatas pada arsitektur berbasis *contrastive learning* seperti Wav2Vec2. Sementara itu, Data2Vec menggunakan paradigma *self-distillation* yang secara fundamental berbeda. alih-alih membandingkan representasi positif melawan negatif, Data2Vec melatih jaringan *student* untuk memprediksi representasi kontekstual penuh yang dihasilkan oleh jaringan *teacher* atas seluruh masukan [1], [8]. Perbedaan ini secara teoretis berpotensi menghasilkan representasi fonetik yang lebih umum untuk lintas bahasa, karena target prediksi berupa konteks laten yang melimpah bukan unit diskrit yang terikat pada distribusi fonetik bahasa *pretraining*. Temuan Xue et al. menunjukkan bahwa penggantian target diskrit dengan target kontinu ala Data2Vec menurunkan *phoneme error rate* lintas bahasa sebesar 5,3% [9]. Temuan tersebut memperlihatkan adanya perbedaan karakteristik representasi yang dihasilkan oleh masing-masing paradigma *pre-training*, sehingga perbandingan kedua model pada tugas *retrieval* menjadi relevan untuk dilakukan.

Temuan-temuan di atas membuka peluang untuk dilakukan riset untuk memberikan jawaban terhadap fenomena yang belum terjawab. Seluruh bukti kegagalan lintas bahasa yang tersedia hanya terbatas pada arsitektur *contrastive learning*, sementara kajian terhadap paradigma *self-distillation* yang dimiliki Data2Vec dalam skenario serupa masih sangat terbatas. Lebih jauh lagi, perbandingan langsung antara Wav2Vec2 dan Data2Vec untuk tugas audio retrieval yang dievaluasi melalui metrik *similarity search* seperti Top-K Accuracy, Mean Reciprocal Rank (MRR), dan Mean Average Precision (MAP), bukan metrik transkripsi (WER/CER) hingga kini masih minim di literatur. Ketidadaan perbandingan ini menyisakan pertanyaan fundamental: apakah perbedaan paradigma pretraining antara kedua model menghasilkan kualitas representasi fonetik yang berbeda pula untuk tugas retrieval ayat Al-Qur'an.

Namun, karakteristik representasi yang unggul pada tugas transkripsi tidak dapat langsung dianggap memberikan hasil yang sama pada tugas retrieval.

Retrieval dan transkripsi mengukur aspek representasi yang berbeda. Pada tugas *Automatic Speech Recognition* (ASR). Representasi audio digunakan sebagai dasar untuk menghasilkan transkripsi, kemudian model disesuaikan melalui proses pelatihan terkontrol agar mampu menjalankan tugas tersebut. Oleh karena itu, metrik seperti Word Error Rate (WER) tidak hanya dipengaruhi oleh kualitas representasi awal, tetapi juga oleh proses penyesuaian model terhadap tugas transkripsi.

Sebaliknya pada sistem retrieval berbasis frozen embedding, parameter model tidak dilatih untuk pada data Al-Qur'an. Representasi yang dihasilkan model langsung digunakan untuk membentuk *vector embedding*. Kemudian hasil representasi nya dibandingkan menggunakan skoring *cosine similarity*. Dengan demikian, kualitas hasil dari masing-masing model diuji melalui kemampuan *vector embedding* dalam menempatkan audio yang berasal dari ayat yang sama pada posisi yang berdekatan serta memisahkan audio dari ayat yang berbeda. Kinerja sistem kemudian dinilai menggunakan metrik retrieval, yaitu *Mean Average Precision* (MAP), *Mean Reciprocal Rank* (MRR), dan Top-K Accuracy.

Perbedaan karakteristik antara tugas ASR dan retrieval tersebut menunjukkan bahwa perbandingan kinerja Wav2Vec2 dan Data2Vec perlu dilakukan secara langsung dalam kondisi *frozen embedding* dan dalam tugas retrieval ayat Al-Qur'an. Perbandingan ini tidak diarahkan untuk menetapkan bahwa salah satu model selalu lebih baik, tetapi untuk memperoleh gambaran empiris mengenai kinerja masing-masing model pada tugas retrieval audio ayat Al-Qur'an, tetapi untuk memperoleh gambaran empiris mengenai kinerja masing-masing model pada tugas retrieval audio ayat Al-Qur'an. Selain itu, perbandingan dilakukan untuk mengetahui apakah kedua model menghasilkan pola kinerja yang berbeda ketika digunakan untuk mencocokkan audio bacaan dengan ayat yang sesuai.

Berdasarkan celah penelitian tersebut, penelitian ini berfokus pada implementasi Wav2Vec2 dan Data2Vec sebagai penghasil representasi laten audio, kemudian membandingkan kinerja kedua model dalam sistem retrieval ayat Al-

Qur'an. Setiap model digunakan tanpa fine-tuning pada data Al-Qur'an sehingga perbandingan dapat dilakukan terhadap kemampuan representasi pretrained dalam kondisi yang sama. Analisis pada setiap lapisan model juga dilakukan untuk menentukan konfigurasi lapisan yang memberikan hasil retrieval paling baik bagi masing-masing model.

Dengan pendekatan tersebut, hasil penelitian tidak diarahkan pada penetapan model yang unggul secara universal. Hasil penelitian digunakan untuk menjelaskan kinerja kedua model pada ruang lingkup data, metode, dan skenario evaluasi yang digunakan. Apabila terdapat perbedaan kinerja, perbedaan tersebut dianalisis berdasarkan nilai metrik retrieval dan interval kepercayaan. Apabila perbedaan tidak menunjukkan makna statistik yang kuat, hasil tersebut tetap menjadi temuan penting karena menunjukkan bahwa kedua model memiliki kinerja yang relatif sebanding dalam skenario retrieval yang digunakan.

Oleh karena itu, penelitian ini diarahkan untuk mengimplementasikan Wav2Vec2 dan Data2Vec dalam menghasilkan fitur laten audio untuk retrieval ayat Al-Qur'an, serta membandingkan kinerja kedua model berdasarkan metrik similarity search. Melalui implementasi dan perbandingan tersebut, penelitian ini diharapkan dapat memberikan gambaran mengenai kesesuaian masing-masing model untuk tugas retrieval audio pada domain bacaan Al-Qur'an. Hasil penelitian juga dapat menjadi landasan teknis bagi pengembangan sistem pencarian ayat Al-Qur'an berbasis suara tanpa melalui tahap transkripsi.

1.2. Rumusan Masalah

Berdasarkan Rumusan masalah terbagi menjadi beberapa point

1. Bagaimana implementasi model Wav2vec2 dan Data2vec dalam tugas *retrieval* ayat Al-Quran?
2. Bagaimana kinerja *frozen-embedding* Wav2vec2 dan Data2vec dalam tugas *retrieval* ayat Al-Qur'an?

1.3. Tujuan Penelitian

Tujuan dari penelitian ini sebagai berikut:

1. Mengimplementasikan model Wav2vec2 dan Data2vec dalam tugas retrieval ayat Al-Quran.
2. Mengevaluasi kinerja frozen embedding Wav2vec2 dan Data2vec dalam tugas *retrieval* ayat Al-Qur'an

1.4. Batasan Masalah

Batasan masalah dari penelitian ini adalah sebagai berikut:


1. Penelitian dibatasi pada penggunaan model *pre-trained* Data2Vec dan Wav2Vec2 tanpa proses *fine-tuning*.
2. Eksperimen dilakukan pada teks Al-Qur'an, dengan objek penelitian berupa surah Al – Fatihah dan surah-surah dalam Juz Amma.
3. Pengujian input audio hanya dapat dilakukan perayat.

1.5. Manfaat Penelitian

Penelitian yang dilakukan ini memiliki manfaat dalam memberikan pemahaman ilmiah yang lebih mengenai seberapa efektif model representasi audio seperti Data2vec dan Wav2vec2 dalam domain pembacaan ayat suci Al-Quran. Khususnya dalam tugas retrieval ayat. Juga dapat menjadi pedoman atau acuan bagi peneliti dan pengembang perangkat lunak dalam memilih model mana yang cocok dalam tugas retrieval ayat Al-Qur'an

1.6. Kerangka Pemikiran

Berdasarkan uraian tersebut kerangka pemikiran dapat diuraikan sebagai berikut



Gambar 1.1 Kerangka Pemikiran

Penelitian ini berangkat dari sebuah fenomena dalam bidang pemrosesan audio, yaitu kemampuan model *Self-Supervised Learning* (SSL) seperti Wav2vec2 dan Data2vec dalam menghasilkan representasi laten, langsung dari audio mentah tanpa memerlukan label transkripsi. Kemampuan ini membuka peluang bagi tugas penelurusan kemiripan audio (*audio retrieval*). Di mana sistem *retrieval* yang bekerja langsung pada *latent embedding* dapat mengungguli pendekatan dua tahap berbasis ASR. Keunggulan ini bersumber dari kemampuannya menghindari kesalahan propagasi (*error propagation*), yakni kesalahan transkripsi pada tahap ASR yang akan merambat dan mendegradasi kualitas pencocokan pada tahap selanjutnya.

Fenomena tersebut ditopang oleh sejumlah landasan teori dan studi literatur. Pada tataran mekanisme model, Wav2vec2 mempelajari representasi melalui *contrastive learning* yang membedakan sampel positif dan negatif menggunakan *quantized discrete units*. Sementara Data2vec mengadopsi paradigma *self-distillation* yang melatih jaringan student untuk memprediksi representasi kontekstual penuh dari jaringan *teacher* dengan target berupa konteks latent yang kontinu. Perbedaan paradigma inilah yang menjadi dasar perbandingan dalam penelitian ini. Pada tataran tugas *retrieval*, penelitian Öberg menunjukkan bahwa pencarian audio dapat dilakukan langsung dari audio tanpa tahap enkripsi [3]. Teori ini didukung pula oleh bukti empiris *Gemini embedding 2*, secara eksplisit menunjukkan bahwa pendekatan *cascaded ASR* ke *retrieval* mengalami *error propagation* [4]. Sedangkan WavRag membuktikan bahwa *retrieval* langsung dari audio mampu menyamai akurasi pipeline ASR dengan efisiensi yang jauh lebih tinggi [5].

Meskipun demikian, keunggulan tersebut belum tentu berlaku ketika model diterapkan pada domain fonetik yang spesifik seperti bahasa Arab dalam bacaan Al-Qur'an. Persoalan muncul karena model SSL umumnya di-*pretrain* pada korpus Bahasa Inggris dan kurang informatif untuk fonetik Arab. Penelitian Toyin et al dan Li et al telah menunjukkan keterbatasan ini [6], [7]. namun bukti tersebut hanya terbatas pada arsitektur berbasis *contrastive learning* seperti Wav2vec2. Sementara itu, potensi paradigma *self-distillation* yang dimiliki Data2Vec untuk tugas audio

retrieval Al-Quran masih sangat minim dikaji, dan perbandingan langsung antara kedua model menggunakan metrik similarity search, bukan metrik transkripsi seperti *word error rate* (WER) hingga kini masih terbatas dalam literatur.

Untuk menjawab persoalan tersebut, penelitian ini menawarkan pendekatan berupa implementasi dan perbandingan Wav2Vec2 dan Data2Vec dalam menghasilkan representasi laten untuk tugas retrieval ayat Al-Qur'an. Fitur laten dari kedua model *pretrained* diekstraksi dalam kondisi beku atau *frozen*, kemudian digunakan untuk membentuk representasi vektor audio. Setiap vektor *query* dibandingkan dengan vektor pada database (*ground truth*) menggunakan *cosine similarity* sebagai *scoring function*, lalu hasilnya diurutkan untuk menghasilkan daftar retrieval mulai dari ayat yang memiliki skor paling tinggi menuju yang terendah.

Evaluasi dilakukan menggunakan metrik *Mean Average Precision* (MAP), *Mean Reciprocal Rank* (MRR), dan Top-K Accuracy. Selain membandingkan kinerja kedua model, evaluasi juga dilakukan pada beberapa lapisan untuk mengetahui lapisan yang menghasilkan kinerja retrieval paling baik. Hasil lapisan terbaik tersebut digunakan sebagai konfigurasi dalam perbandingan utama antara Wav2Vec2 dan Data2Vec.

Proses penelitian dilaksanakan mengikuti kerangka kerja atau *framework* Cross-Industry Standard Process for Data Mining (CRISP-DM) yang diadaptasi ke dalam beberapa tahap, yaitu Business Understanding, Data Understanding, Data Preparation, Modeling, Evaluation, dan Deployment. Tahapan tersebut digunakan untuk mengarahkan proses pengumpulan data, persiapan audio, ekstraksi frozen embedding, penerapan similarity search, evaluasi kinerja, serta analisis hasil.

Hasil akhir penelitian berupa implementasi sistem retrieval berbasis frozen embedding menggunakan Wav2Vec2 dan Data2Vec, serta perbandingan kinerja kedua model pada data audio ayat Al-Qur'an. Hasil tersebut diharapkan dapat memberikan gambaran mengenai model dan konfigurasi lapisan yang paling sesuai untuk mendukung pengembangan sistem audio retrieval pada domain bacaan Al-Qur'an.

1.7.Sistematika Penulisan

Sistematika penulisan laporan tugas akhir ini disusun ke dalam lima bab yang saling berkait secara berurutan, dengan gambaran kandungan setiap bab sebagai berikut.

BAB I: PENDAHULUAN

Bab ini menguraikan dasar pemikiran yang melatarbelakangi dilakukannya penelitian, mencakup latar belakang yang memaparkan fenomena dan celah penelitian, rumusan masalah sebagai pertanyaan penelitian yang hendak dijawab, batasan masalah yang menetapkan ruang lingkup penelitian, manfaat penelitian, state of the art, kerangka pemikiran, serta sistematika penulisan. Bab ini berfungsi sebagai fondasi mengarahkan keseluruhan penelitian.

BAB II: TINJAUAN PUSTAKA

Bab ini memaparkan landasan teori dan konsep-konsep fundamental yang menjadi dasar ilmiah penelitian, meliputi teori mengenai Self-Supervised Learning (SSL), arsitektur dan mekanisme kerja model Wav2Vec2 dan Data2Vec, konsep representasi latent (*latent embedding*), tugas audio retrieval, serta metrik evaluasi similarity search. Berbeda dengan Bab I yang menyoroti mengapa penelitian mesti dilakukan, bab ini menyediakan kerangka teoritis apa saja konsep yang digunakan untuk memahami dan menyelesaikan permasalahan.

BAB III: METODOLOGI PENELITIAN

Bab ini menjelaskan tahapan prosedur pelaksanaan penelitian secara sistematis mengikuti kerangka kerja *Cross-Industry Standard Process for Data Mining* (CRISP-DM) yang diadaptasi, mencakup pengumpulan data, pre-processing, ekstraksi representasi laten, implementasi similarity search, hingga skenario evaluasi. Jika Bab II menjelaskan apa landasan teorinya, bab ini menguraikan bagaimana teori tersebut diterapkan secara teknis dan operasional dalam penelitian.

BAB IV: HASIL DAN PENELITIAN

Bab ini menyajikan hasil implementasi dan evaluasi sistem retrieval audio ayat Al-Qur'an menggunakan frozen embedding Wav2Vec2 dan Data2Vec. Pembahasan mencakup hasil persiapan data, ekstraksi representasi laten pada setiap lapisan model, penerapan cosine similarity, penyusunan peringkat hasil retrieval, serta evaluasi menggunakan metrik Top-K Accuracy, Mean Reciprocal Rank (MRR), dan Mean Average Precision (MAP). Bab ini juga menyajikan perbandingan kinerja kedua model berdasarkan konfigurasi lapisan yang optimal dan membahas implikasi hasil tersebut terhadap penerapan sistem retrieval berbasis suara.

BAB V: KESIMPULAN DAN SARAN

Bab ini memuat kesimpulan yang menjawab secara ringkas dan tegas rumusan masalah berdasarkan temuan pada Bab IV, disertai saran dan untuk pengembangan penelitian selanjutnya. Berbeda dengan Bab IV yang menyajikan analisis rinci, bab ini merangkum intisari penelitian secara menyeluruh dan menawarkan arah bagi penelitian di masa mendatang.

BAB II KAJIAN LITERATUR

2.1. Tinjauan Pustaka

Analisis literatur terhadap artikel maupun jurnal terdahulu yang relevan dilakukan untuk memperdalam pemahaman mengenai permasalahan utama dalam penerapan *Self-Supervised Learning* (SSL) pada representasi ucapan (*speech representation*) serta pemanfaatannya untuk pencarian audio berbasis kemiripan (*audio similarity search*) dengan pendekatan *query-by-example*. Kajian ini sekaligus bertujuan untuk mengidentifikasi keterbatasan penelitian sebelumnya. Berikut rangkuman dari penelitian terdahulu dalam bentuk tabel.

Tabel 2.1 State of the art

No	Peneliti	Metode	Dataset	Hasil
1	Baevski dkk (2020) [1]	<i>contrastive masked prediction of quantized units</i>	LibriSpeech, Libri-light	WER 1,8%/3,3% (clean/other) dengan 10 menit data berlabel + 53k jam pra-pelatihan WER 4,8%/8,2%.
2	Baevski dkk (2022) [8]	<i>self-distillation, teacher-student EMA,</i>	LibriSpeech/ Libri-light, ImageNet-1K, BooksCorpus + Wikipedia	Pada setup 100 jam data berlabel: WER 2,8%/6,8% (test clean/other), mengungguli Wav2Vec2 Base (3,4%/8,0%) dan HuBERT Base (3,4%/8,1%).
3.	Alkanhal, dkk (2021) [10]	Wav2vec2 dan Data2vec	Aswat, Common Voice (AR), MGB-2	Mencapai WER SOTA 11,7% pada Common Voice dan 10,3% pada MGB-2 berkat pra- pelatihan pada Aswat.

No	Peneliti	Metode	Dataset	Hasil
4.	Öberg (2025) [3]	Projection Network + contrastive triplet loss pada embedding Wav2Vec2	Google FLEURS, Common Voice	embedding hasil transformasi mencapai MRR 0,811 dan Recall@20 0,931, jauh meningkat dari embedding asli.
5.	San, dkk (2021) [11]	QbE-STD dengan frozen Wav2Vec2 (English-mono & XLSR-53).	Gronings, Besemah, Mavir/Mboshi; LibriSpeech, XLSR-53.	Peningkatan relatif 56– 86% atas SOTA; English- mono mengungguli XLSR multibahasa pada 4 dataset.
6.	Zhaoqi Li, dkk (2021) [12]	Neural acoustic word embeddings + Wav2Vec, circle loss menggantikan triplet loss	Korpus QbE- STD	Average Precision (AP) meningkat relatif 11,1% dibanding sistem MFCC; konvergensi $\pm 40\%$ epoch lebih cepat dengan circle loss.
7.	Xie dkk (2022) [13]	Two-phase: Siamese Network + contrastive loss, lalu MLP classifier	ASVspoof 2019 Logical Access (LA)	EER turun dari SOTA sebelumnya 4,07% menjadi 1,15% pada evaluation set.
8.	Tang, dkk (2022) [14]	Perbandingan HuBERT vs Data2Vec pada SID & ASR	SUPERB benchmark (task SID & ASR; basis LibriSpeech/V oxCeleb-line)	Data2Vec Base: SID 70,21% / WER 4,94%; HuBERT Base: SID 81,42% / WER 6,42% HuBERT unggul di SID, Data2Vec unggul di ASR.

No	Peneliti	Metode	Dataset	Hasil
9.	Yoon, dkk (2023) [15]	Data2Vec 2.0 Base, regularisasi konsistensi, fine-tune parsial.	LibriSpeech 960 jam, 11 SUPERB subtasks	Mengungguli Data2Vec 2.0 di hampir semua tugas kecuali QbE; mencapai SOTA pada PR, ASR, KS, IC, SF, dan ER (mis. WER 4,68%, SID 82,40%).
10.	Yang, dkk (2024) [16]	Frozen embedding Data2Vec Base/Large + lightweight prediction head	LibriSpeech, QUESST, VoxCeleb, LibriTTS	Data2Vec Large mencapai speaker-invariance terbaik (7,38 ACC), PER terbaik (2,58%), dan performa VC terbaik (6,75 MCD, 100% akurasi kemiripan target speaker).

Penelitian mengenai representasi ucapan yang dilatih sendiri (*self-supervised*) telah mengalami kemajuan pesat, dimulai dengan fondasi seperti Wav2vec 2.0 dan Data2vec [1], [8] yang mampu mempelajari representasi laten koheren dari *raw audio*. Namun, mayoritas penelitian awal dan penelitian lanjutan berkonsentrasi pada peningkatan kinerja ASR (*automatic speech recognition*), termasuk studi lintas bahasa dan adaptasi domain. Sebagaimana penelitian lain berfokus pada non-retrieval yang tetap memanfaatkan kualitas embedding SSL, seperti deteksi *spoofing* suara dan identifikasi suarat yang menggabungkan *Siamase Network* pada fitur Wav2vec2 [13]. Meskipun demikian, Sebagian studi mulai menggeser fokus ke kapabilitas *retrieval* dari *embedding* ini, misalnya penelitian Öberg mengenai audio search berbasis transformasi *embedding* Wav2vec2 dengan *contrastive learning* [3].

Pada ranah *retrieval* berdasarkan kemiripan, sejumlah penelitian telah membuktikan keunggulan pendekatan berbasis *embedding* SSL. Nay san, dkk telah membuktikan bahwa representasi dari Wav2vec2 dapat melakukan *query-by-example spoken term detection* lintas bahasa tanpa transkripsi maupun fine-tuning dengan peningkatan 56%-86% atas *state of the art* sebelumnya [11]. Sejalan dengan

itu, Zhaoqi Li, dkk membuktikan bahwa *Neural Acoustic Word Embeddings* berbasis pretrain Wav2vec2 mengungguli fitur MFCC untuk retrieval berbasis kemiripan [12]. Temuan-temuan ini menegaskan bahwa kualitas embedding SSL menjadikannya sangat sesuai dengan untuk tugas *similarity search*.

Dalam konteks bahasa Arab alkanhal, dkk melakukan perbandingan langsung antara Wav2vec2 dan Data2vec. Mereka menemukan bahwa Data2vec konsisten mengungguli Wav2vec2 dalam domain ASR Arab. Namun, perbandingan tersebut dilakukan dengan supervised fine-tuning dan juga dengan pengukuran metrik transkripsi, bukan frozen embedding tanpa fine-tuning dan metrik retrieval. Di sisi lain, kajian terhadap Data2vec pada tugas-tugas non-ASR mulai bermunculan dan justru memperlihatkan pola yang bergantung pada jenis tugasnya. Tang, dkk menemukan bahwa efektivitas Data2vec berbeda tergantung tugasnya, Data2vec lebih unggul dalam tugas yang berbasis konten contohnya ASR, namun kurang optimal dalam identifikasi pembicara. Yoon, dkk mengonfirmasi kecenderungan serupa, Data2vec 2.0 kuat pada tugas berbasis konten seperti ASR, tetapi performa query-by-example nya justru menurun ketika diberi regulasi tambahan [15]. Evaluasi berskala besar yang dilakukan oleh Yang, dkk mempertegas hal ini, menunjukan bahwa Data2vec mencapai performa terbaik pada Voice Conversion dan Phone Recognition, tetapi tertinggal pada Speaker Identification dan ASR out-of-distribution dibanding HuBERT dan WavLM.

Berdasarkan kajian tersebut, terlihat bahwa keunggulan Data2vec tidak bersifat universal, melainkan spesifik terhadap jenis tugas. Fakta ini memunculkan pertanyaan fundamental yang belum terjawab dalam literatur: apakah keunggulan Data2vec pada ASR bahasa Arab akan sama ketika kedua model dievaluasi tanpa fine-tuning dan menggunakan metrics dalam domain similarity search seperti MAP, Top-K, dan MRR.

Penelitian ini menghadirkan perbedaan penting dengan menempatkan kedua model tersebut dalam konteks *retrieval* audio ayat Al-Qur'an yang mana memiliki karakteristik fonetik dan aturan tajwid yang unik. Berbeda dengan penelitian pada umumnya yang menitik beratkan pada pengukuran performa transkripsi ASR, penelitian ini mengevaluasi kemampuan Wav2vec2 dan Data2vec

dalam mencocokkan cuplikan bacaan dengan ayat terkait melalui pendekatan komparatif berbasis kemiripan embedding. Dengan demikian, penelitian ini menawarkan kontribusi yang masih minim dieksplorasi, sekaligus menyediakan landasan teknis bagi pengembangan sistem pendukung hafalan dan pembelajaran Al-Qur'an yang lebih adaptif dan aplikatif.

2.2. Landasan Teori

2.2.1. Kecerdasan buatan (Artificial Intelligence)

Kecerdasan buatan (Artificial Intelligence) merupakan salah satu cabang ilmu komputer yang mempelajari perancangan sistem yang mampu melakukan kecerdasan manusia, seperti penalaran, persepsi, pembelajaran, dan pengambilan keputusan [17]. Russel dan Norvig mengklasifikasikan AI ke dalam empat sudut pandang, yaitu sistem yang berpikir seperti manusia, bertindak seperti manusia, berpikir secara rasional, dan bertindak secara rasional. Pendekatan terakhir yakni rational agent yang bertindak untuk mencapai hasil terbaik menurut ukuran kinerja tertentu, menjadi kerangka dominan dalam AI modern [17].

Dalam perkembangannya, Machine learning (ML) muncul sebagai sub-bidang AI yang berfokus pada kemampuan sistem untuk belajar pola dari data tanpa dirprogram secara eksplisit untuk setiap kasus [18]. ML sendiri terbagi menjadi tiga paradigma utama supervised learning (belajar dari data yang berlabel), unsupervised learning (menemukan struktur dari data tak berlabel), dan self-supervised learning yang menjadi fondasi penelitian ini. Penelitian ini berada dalam ranah AI karena memanfaatkan model pembelajaran representasi untuk memahami dan mencocokkan sinyal ucapan Al-Qur'an secara otomatis.

2.2.2. Deep Learning

Deep learning adalah cabang dari machine learning yang menggunakan jaringan saraf tiruan berlapis yang jumlahnya sangat banyak (*deep neural networks*) untuk mempelajari representasi data secara berjenjang (*hierarchical representation*) [19]. Berbeda dari ML tradisional yang bergantung pada feature engineering manual yang mana, harus membutuhkan manusia untuk memberikan data yang berlabel, deep learning mempelajari fitur secara otomatis. Lapisan-

lapisan awal menangkap fitur tingkat rendah (misalnya pola frekuensi pada audio), sedangkan lapisan yang lebih dalam menyusun fitur tingkat tinggi yang lebih abstrak (misalnya unit fonetik) [19]

Sebuah jaringan saraf tersusun atas neuron-neuron yang mentransformasikan input melalui bobot this equation $\mathbf{W}$, bias $\mathbf{b}$. Dan fungsi aktivasi non-linear σ , sehingga keluaran satu lapisan dinyatakan sebagai berikut

$$\mathbf{h} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b}) \quad (2.1)$$

Parameter jaringan dioptimasi dengan meminimalkan *loss function* melalui algoritma *backpropagation* dan *gradient descent* [19]. Arsitektur yang relevan bagi penelitian ini adalah jaringan konvolusi (Convolutional Neural Network, CNN) yang efektif mengekstrak fitur local dari sinyal, dan Transformer [20] yang memodelkan ketergantungan jangka Panjang melalui mekanisme self-attention. Kedua arsitektur inilah yang Menyusun tulang punggung model Wav2vec2 2.0 dan varian speech dari Data2Vec.

2.2.3. Similarity Search

Similarity search adalah proses menemukan objek-objek dalam suatu database yang paling mirip dengan sebuah objek kueri (data input), berdasarkan ukuran kemiripan tertentu [21]. Dalam paradigma modern, setiap objek, baik teks, gambar, maupun audio, direpresentasikan sebagai vector bilangan riil di ruang berdimensi tinggi, sehingga pencarian kemiripan tereduksi menjadi persoalan *Nearest Neighbor Search* di ruang vector tersebut [21]

Formalnya, diberikan sebuah vector kueri $\mathbf{q}$ dan himpunan vector database $D=\{\mathbf{d}_1, \dots, \mathbf{d}_N\}$, sistem menghitung skor kemiripan $s(\mathbf{q}, \mathbf{d}_i)$ untuk setiap $\mathbf{d}_i$, lalu mengurutkan hasilnya secara menurun untuk menghasilkan daftar peringkat (*ranked list*). Pendekatan ini menjadi tulang punggung sistem information retrieval modern [21]. Dalam penelitian ini, similarity search diterapkan pada embedding audio ayat Al-Qur'an. Data kueri dibandingkan langsung terhadap database embedding ayat tanpa melalui tahap transkripsi, sehingga menghindari propagasi kesalah dari tahap ASR (*automatic speech recognition*).

2.2.4. Vector Embedding

Vector Embedding adalah representasi suatu objek dalam bentuk vector yang padat berdimensi tetap $v \in \mathbb{R}^d$ yang dirancang sedemikian rupa sehingga kedekatan geometrics antar vektor mencerminkan kemiripan semantic atau perseptual antar objek yang diwakilinya [19]. Prinsip utamanya adalah distributional hypothesis, yang mana objek objek yang serupa akan menempati posisi yang berdekatan di dalam ruang vector (*embedding space*)

Pada domain audio, embedding dihasilkan oleh model self-supervised seperti Wav2vec2 2.0 dan Data2vec, yang memetakan sinyal audio mentah menjadi barisan vector kontekstual. Embedding inilah yang menjadi objek perbandingan dalam penelitian ini. Kualitas sebuah embedding untuk tugas retrieval dapat dilihat dari kemampuannya dalam menempatkan audio dari ayat yang sama secara berdekatan sekaligus memisahkan audio dari ayat yang berbeda. Sifat geometris tersebut menjadi dasar pengukuran kinerja dan perbandingan kedua model dalam penelitian ini.

2.2.5. Self-Supervised Learning (SSL)

Self-Supervised Learning (SSL) adalah paradigma pembelajaran mesin di mana model dilatih untuk mempelajari representasi yang berguna dari data yang tidak memiliki *label* dengan menghasilkan labelnya sendiri. SSL terletak di antara *Supervised Learning* (yang membutuhkan label manual ekstensif) dan *Unsupervised Learning* (yang mencari pola tanpa label).

Inti dari SSL terletak pada penciptaan "Tugas Preteks" (*Pretext Task*). Tugas ini memaksa model untuk memahami dan memprediksi bagian tersembunyi (*masked*) atau bagian yang hilang (*corrupted*) dari data input itu sendiri.

2.2.6. Wav2vec 2.0

Wav2vec 2.0 adalah sebuah model self-supervised learning (SSL) yang mempelajari representasi dari ucapan langsung atau audio mentah melalui pendekatan *contrastive learning*. Arsitekturnya terdiri dari tiga komponen inti; feature encoder konvolusional, jaringan konteks berbasis Transformer, dan modul

kuantisasi yang bekerja dalam satu tugas pretext. Memprediksi unit terakuntisasi yang benar dari representasi konteks pada posisi yang ditutup (*masked*).

2.2.6.1. Feature encoder

Sinyal audio mentah $\mathcal{X}$ (16 kHz) diproses oleh tujuh blok konvolusi temporal, masing-masing berisi 512 kanal dengan Layer Normalization dan aktivasi GELU. Susunan stride (5,2,2,2,2,2,2) dan lebar kernel (10,3,3,3,3,2,2) menghasilkan barisan representasi laten $z_1, \dots, z_T$ pada frekuensi keluaran sekitar 49 Hz (jarak antar-frame ≈ 20 ms), dengan receptive field selebar 400 sampel input atau setara 25 ms audio.

Tabel 2.2 Konfigurasi Blok Konvolusi Temporal pada Encoder Audio

Blok	Stride	Kernel	Kanal
1	5	10	512
2-5	2	3	512
6-7	2	2	512

2.2.6.2. Jaringan konteks $g: \mathcal{Z} \rightarrow \mathcal{C}$

Representasi laten z diumpankan ke jaringan Transformer N4 yang memodelkan ketergantungan jangka panjang antar-frame melalui self-attention, menghasilkan representasi kontekstual $c_1, \dots, c_T$. Konfigurasi Base memakai 12 blok ($d = 768$, 8 Head, sedangkan Large memakai 24 blok ($d = 1024$, 16 head). Informasi posisi ditanamkan melalui relative positional convolutional embedding (kernel 128, 16 grup), bukan positional encoding absolut. Representasi laten z diumpankan ke jaringan Transformer N4 yang memodelkan ketergantungan jangka panjang antar-frame melalui self-attention, menghasilkan representasi kontekstual $c_1, \dots, c_T$. Konfigurasi Base memakai 12 blok ($d = 768$, 8 head), sedangkan Large memakai 24 blok ($d = 1028$, 16 head). Informasi posisi ditanamkan melalui relative positional convolutional embedding (kernel 128, 16 grup), bukan positional encoding absolut.

2.2.6.3. Modul kuantisasi

Secara paralel, laten z didiskretisasi melalui product quantization N9 dengan $G = 2$ codebook, masing-masing $V = 320$ entri. Pemilihan entri dibuat terdiferensiasi menggunakan Gumbel-Softmax N7, N8

$$p_{g,v} = \frac{\exp((l_{g,v} + n_{g,v})/\tau)}{\sum_{k=1}^V \exp((l_{g,k} + n_{g,k})/\tau)} \quad (2.2)$$

dengan $l_{g,v}$ logit entri v pada grup g , τ temperatur (dijadwalkan turun dari 2 ke 0,5), dan $n_v = -\log(-\log(u_v))$, $u_v \sim \mathcal{U}(0,1)$ derau Gumbel. Pada forward pass dipilih entri diskret $i = \arg \max_j p_{g,j}$; pada backward pass digunakan gradien fungsi Gumbel-Softmax kontinu (straight-through estimator N10) sehingga tetap dapat dilatih.

2.2.6.4. Fungsi Objektif

Pelatihan diarahkan gabungan dua komponen

$$\mathcal{L} = \mathcal{L}_m + \alpha \mathcal{L}_d, \quad \alpha = 0,1 \quad (2.3)$$


Contrastive loss $\mathcal{L}_m$ memaksa model membedakan target benar q_t dari $K = 100$ pengecoh

$$\mathcal{L}_m = -\log \frac{\exp\left(\frac{\text{sim}(c_t, q_t)}{\kappa}\right)}{\sum_{\tilde{q} \sim \mathcal{Q}_t} \exp\left(\frac{\text{sim}(c_t, \tilde{q})}{\kappa}\right)} \quad (2.4)$$

Dengan $\kappa = 0,1$ dan $\text{sim}(a, b) = \frac{a^T b}{|a||b|}$ (*cosine similarity*, berpersan sebagai scoring function). Diversity loss $\mathcal{L}_d$ mendorong pemakaian merata seluruh entri codebook via maksimalisasi entropi

$$\mathcal{L}_d = \frac{1}{G} \sum_{g=1}^G \sum_{v=1}^V \overline{p_{g,v}} \log \overline{p_{g,v}} \quad (2.5)$$

Melalui mekanisme kontrastif, Wav2Vec2 membentuk representasi dengan membedakan unit positif dan unit negatif pada ruang representasi. Karakteristik tersebut dapat menghasilkan struktur embedding yang lebih terpisah, sehingga dampaknya terhadap kinerja retrieval berbasis cosine similarity dapat diamati melalui evaluasi empiris dalam penelitian ini [22].



Gambar 2.1 Arsitektur Wav2vec2

2.2.7. Data2vec

Data2vec merupakan model Self-Supervised Learning (SSL) yang modality agnostic, artinya inputan yang dapat diproses dapat berupa audio, gambar ataupun text. Perbedaan mendasarnya dengan Wav2vec2 2.0 terletak pada bentuk prediksi, Data2vec tidak memprediksi unit diskret terkuantisasi, melainkan representasi laten kontekstual yang bersifat kontinu. Yang dihasilkan oleh model itu sendiri melalui skema self-distillation.

2.2.7.1. Skema Teacher dan Student (*self-distillation*)

Satu arsitektur Transformer [20] beroperasi dalam dua peran. Jaringan student yang memproses input yang dimasking dan menghasilkan prediksi $f_t(x)$ pada tiap posisi ter

masking. Jaringan teacher memproses input penuh (tanpa masking) dan menyediakan target regresi y_t . Student dilatih meregresi target teacher hanya pada posisi termasking

2.2.7.2. Pembaruan Teacher via EMA

Pembaruan teacher tidak dilakukan oleh gradient, melainkan menggunakan exponential moving average (EMA) dari parameter student $\Delta \leftarrow \tau \Delta + (1 - \tau)$ dengan Δ parameter teacher, θ parameter student. Nilai τ dinaikan linear dari τ_0 ke τ_e langkah awal lalu ditahan konstan, untuk ucapan $\tau_0 = 0, \tau_e = 0, \tau_n = 30.0$

2.2.7.3. Konstruksi Target Kontekstual

Target dibentuk dengan merata-ratakan keluaran K blok Transformer teratas teacher, setelah masing-masing dinormalisasi

$$y_t = \frac{1}{K} \sum_{l=L-K+1}^L \widehat{a}_t^l \quad (2.6)$$


Dengan L dengan jumlah total blok (12 pada base), $K = 8$ blok teratas $\widehat{a}_t^l$ keluaran blok l ternormalisasi. Untuk ucapan digunakan *instance normalization* [23]. Untuk gambar layer normalization [24]. Normalisasi ini mencegah keruntuhan representasi (representation collapse). Karena target menggabungkan berupa lapisan atas, ia bersifat kontekstual penuh. Target kontekstual penuh tersebut menjadi salah satu karakteristik Data2Vec yang membedakannya dari Wav2Vec2. Karakteristik ini telah dikaitkan dengan kemampuan menghasilkan representasi yang informatif pada sejumlah tugas pemrosesan suara [10], [16]. Dalam penelitian ini, karakteristik tersebut dianalisis melalui penerapan Data2Vec pada tugas retrieval audio ayat Al-Qur'an.

2.2.7.4. Fungsi Objektif

Student meregresi target dengan Smooth L1 loss (huber):

$$\mathcal{L}(y_t, f_t(x)) = \begin{cases} \frac{1}{2}(y_t - f_t(x))^2 / \beta, & |y_t - f_t(x)| \leq \beta \\ |y_t - f_t(x)| - \frac{1}{2}\beta, & \text{selainnya} \end{cases} \quad (2.7)$$

Parameter β mengatur peralihan wilayah kuadratik (l_2) dan linear (l_1) untuk $\beta \rightarrow \infty$ loss menjadi MSE murni yang bekerja baik pada domain ucapan.



Gambar 2.2 Arsitektur Data2vec

2.2.8. Cosine Similarity

Cosine Similarity mengukur kemiripan antara dua vektor berdasarkan sudut cosine di antara keduanya, tanpa perlu memperhitungkan besar magnitudonya [21]

$$\text{sim}(q, d) = \cos \theta = \frac{q \cdot d}{|q| |d|} = \frac{\sum_{i=1}^d q_i d_i}{\sqrt{\sum_{i=1}^d q_i^2} \sqrt{\sum_{i=1}^d d_i^2}} \quad (2.8)$$

Nilainya berkisar pada $[-1, 1]$, dengan nilai mendekati 1 menandakan arah vektor yang sangat mirip. Perlu ditegaskan bahwa dalam bidang retrieval, cosine similarity berperan sebagai fungsi penilaian (*scrolling function*), bukan sebagai metrik evaluasi [21]. Manning dkk. Membedakan secara tegas antara mekanisme scoring ranking dan metrik evaluasi efektivitas sistem. Selain itu cosine distance ($1 - \cos \theta$) bukan metrik jarak matematis, arena melanggar pertidaksamaan segitiga [25]. oleh karena itu, dalam penelitian ini cosine similarity digunakan sebagai fungsi penilai kemiripan untuk menghasilkan peringkat, sedangkan efektivitas retrieval diukur menggunakan metrik evaluasi yang dijelaskan pada sub-bab berikutnya.

2.2.9. Metriks Evaluasi Retrieval

Efektivitas sistem retrieval dievaluasi menggunakan metrik yang berbasis pada kualitas peringkat (ranking) hasil pencarian [21]. Penelitian ini menggunakan tiga metrik utama berikut.

2.2.9.1. Top K Accuracy

Metrik ini mengukur proporsi kueri yang dokumen relevannya ditemukan dalam K peringkat teratas dalam pencarian

$$\text{Top} - K \text{ Accuracy} = 1 \div |Q| \sum_{q \in Q} 1[\text{rank}(q) \leq K] \quad (2.9)$$

Dengan $|Q|$ adalah jumlah total kueri, dan $1[\cdot]$ adalah fungsi indikator yang bernilai 1 apabila dokumen relevan berada pada peringkat kurang dari atau sama dengan K, dan berniali 0 jika sebaliknya. Metrik ini mencerminkan kegunaan praktis sistem bagi pengguna yang umumnya hanya memeriksa hasil teratas.

2.2.9.2. Mean Reciprocal Rank (MRR)

MRR mengukur seberapa tinggi peringkat dokumen relevan pertama, dengan menghitung rata-rata kebalikan peringkatnya [21]. MRR memiliki rumus demikian

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i} \quad (2.10)$$

Dengan rank_i posisi peringkat dokumen relevan pertama untuk kueri ke- i . Nilai MRR mendekati 1 menunjukkan dokumen relevan cenderung berada di peringkat paling atas.

2.2.9.3. Mean Average Precision (MAP)

MAP merupakan metrik yang paling komprehensif karena memperhitungkan presisi pada setiap posisi dokumen relevan sepanjang daftar peringkat [21]. Untuk sebuah kueri, Average Precision (AP) dihitung sebagai

$$AP = \frac{1}{|R|} \sum_{k=1}^N P(k) \cdot \text{rel}(k) \quad (2.11)$$

Dengan $P(k)$ presisi pada peringkat k , $\text{rel}(k)$ fungsi indicator relevansi dokumen di peringkat k , $|R|$ jumlah total dokumen relevan, dan N jumlah dokumen. MAP kemudian adalah rata-rata AP atas seluruh kueri

$$\text{MAP} = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \text{AP}(q) \quad (2.12)$$

Ketiga metrik ini; Top-K Accuracy, MRR, dan MAP merupakan metrik evaluasi yang secara konseptual berbeda dengan cosine similarity yang berperan sebagai *scoring function*

2.2.10. Dataset Quran-MD

Penelitian ini menggunakan dataset Quran-MD (bx7), sebuah dataset multimodal yang tersedia pada platform huggingface. Dataset ini mengintegrasikan dimensi teks, linguistic, dan audio pada tingkat ayat maupun kata. Untuk setiap ayat disediakan teks Arab asli serta rekaman dari 30 pembaca (qori) yang berbeda guna mempresentasikan keragaman gaya bacaan (qiraat) dan nuansa dialektik.

Secara kuantitatif, koleksi Quran-MD terdiri atas dua sub-dataset terpisah. sub-dataset ayat (Buraaq/quran-md-ayahs) berisi 187080 sampel rekaman ayat lengkap. Dan sub-dataset kata (Buraaq/quran-md-words) berisi 77429 sampel pelafalan kata individual, sehingga totalnya mencakup sekitar 264509 audio format berformat mp3 yang meliputi 114 surah dan 6236 ayat unik (bx7). Sesuai batasan masalah penelitian, objek yang digunakan dibatasi pada surah Al-fatihah dan juz 30 dari sub-dataset tingkat ayat. Pasangan audio-teks yang tersedia pada dataset ini memungkinkan penerapan tugas similarity search berbasis suara tanpa transkripsi.

2.2.11. Metode Penelitian CRISP-DM

Penelitian ini mengadopsi kerangka kerja (*framework*) Cross-industry Standard Process for Data Mining (CRISP-DM) sebagai metodologi (bx8). CRISP-DM merupakan model process standar yang bersifat iteratif dan tidak bergantung pada industri maupun teknologi tertentu, sehingga sesuai untuk penelitian berbasis data dan machine learning. Kerangka ini terdiri atas enam fase yang saling terikat:

1. Business Understanding. Merumuskan tujuan penelitian, yaitu mengimplementasikan Wav2vec2 dan Data2vec sebagai penghasil vector embedding untuk retrieval ayat Al-Qur'an serta menetapkan kriteria evaluasi dan skema perbandingan kedua model.
2. Data understanding. Mengeksplorasi karakteristik dataset Quran-MD, mencakup distribusi qari, kualitas audio, dan cakupan surah yang digunakan.

3. Data preparation. Menyeleksi Surah Al-Fatihah dan Juz Amma, melakukan pre-processing audio dan menyiapkan pasangan kueri dan database untuk pengujian
4. Modeling. Mengekstrak embedding dari kedua model SSL tanpa adanya fine-tuning, lalu menghitung skor kemiripan menggunakan cosine similarity untuk menghasilkan peringkat retrieval.
5. Evaluation. Mengukur kinerja retrieval kedua model menggunakan metrik MAP, Top-K Accuracy, dan MRR.
6. Deployment. Menyusun Menyusun kesimpulan dan rekomendasi model serta konfigurasi lapisan yang paling sesuai berdasarkan hasil evaluasi dan skenario penelitian sebagai acuan bagi pengembangan sistem pembelajaran Al-Qur'an berbasis audio

BAB III METODOLOGI PENELITIAN

Metodologi penelitian yang diadaptasi dari penelitian ini yaitu *framework Cross-Industry Standard Process for Data Mining (CRISP-DM)*. Dikarenakan *framework* ini bersifat sistematis, adaptif serta *iterative* dan tidak terikat pada teknologi tertentu, sehingga sesuai dengan penelitian berbasis data dan *Machine Learning*. Namun demikian, karena penelitian ini bertujuan untuk membandingkan efektivitas fitur laten model Self-Supervised Learning tanpa dilakukan *transfer learning*, maka terdapat dua fase dalam *framework CRISP-DM* yang perlu disesuaikan agar selaras dengan tujuan penelitian ini, yaitu *Modeling* dan *Deployment*. Fase *Modeling* tidak berupa pelatihan model, melainkan ekstraksi representasi laten. Sementara fase *Deployment* diarahkan pada sintesis temuan, penilaian kelayakan penerapan, dan perumusan rekomendasi arsitektur berdasarkan hasil perbandingan kedua model, bukan penerapan sistem dalam lingkungan produksi. Dengan penyesuaian tersebut, proses penelitian dilaksanakan secara terstruktur melalui enam fase, mulai dari *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation* dan *Deployment* yang diadaptasi.

3.1. Business Understanding

Fase *business understanding* berfungsi menerjemahkan permasalahan penelitian menjadi sasaran analitis yang terukur [26]. Tujuan utama yang ditetapkan dalam penelitian ini adalah mengukur dan membandingkan efektivitas fitur laten dua model Self-Supervised Learning (SSL) model, yaitu Wav2vec2 dan Data2vec. Dalam tugas *retrieval* ayat Al-Quran. Perbandingan dilakukan dalam kondisi *frozen*. Penelitian ini memanfaatkan model *pre-trained* tanpa pelatihan ulang (*fine-tuning*). Sehingga metrik yang dihasilkan merupakan *raw performance* masing masing model.

Sasaran utama penelitian ini adalah mengimplementasikan dan membandingkan dua model Self-Supervised Learning, yaitu Wav2Vec2 dan Data2Vec, sebagai penghasil frozen embedding untuk retrieval audio ayat Al-Qur'an. Kedua model memiliki mekanisme *pre-training* yang berbeda. Wav2Vec2

menggunakan pendekatan *contrastive learning*, sedangkan Data2Vec menggunakan pendekatan *self-distillation* dengan target representasi kontekstual.

Perbedaan mekanisme tersebut menjadi dasar untuk melakukan perbandingan secara empiris. Perbandingan tidak diarahkan untuk menetapkan bahwa salah satu paradigma selalu lebih unggul, tetapi untuk mengetahui bagaimana kinerja masing-masing model ketika digunakan pada tugas retrieval berbasis cosine similarity. Hasil perbandingan juga digunakan untuk melihat apakah karakteristik representasi yang diperoleh pada tugas ASR menunjukkan pola yang sama ketika model digunakan dalam kondisi frozen embedding untuk retrieval.

Agar perbandingan kedua model dapat dilakukan secara objektif, kedua model diproses menggunakan data, pembagian dataset, prosedur ekstraksi, metode *similarity scoring*, dan skenario evaluasi yang sama. Kinerja sistem dinilai menggunakan metrik retrieval, yaitu Mean Average Precision (MAP), Mean Reciprocal Rank (MRR), dan Top-K Accuracy [21]. MAP digunakan untuk mengukur kualitas peringkat secara keseluruhan, MRR digunakan untuk mengukur posisi kemunculan hasil relevan pertama, sedangkan Top-K Accuracy digunakan untuk mengetahui apakah hasil relevan muncul pada sejumlah posisi teratas. Nilai cosine similarity digunakan sebagai skor untuk mengurutkan kandidat ayat, bukan sebagai metrik evaluasi akhir.

Penelitian ini dibatasi pada penggunaan pre-trained model tanpa fine-tuning, dengan objek teliti berupa surah Al-Fatihah dan Juz Amma, serta pengujian pada tingkat ayat. Selain evaluasi berdasarkan model, penelitian ini melakukan analisis terhadap representasi yang dihasilkan oleh setiap lapisan Wav2Vec2 dan Data2Vec. Analisis tersebut digunakan untuk menentukan konfigurasi lapisan yang menghasilkan kinerja retrieval terbaik bagi masing-masing model. Konfigurasi terbaik yang diperoleh dari data pengembangan kemudian digunakan dalam perbandingan utama antara Wav2Vec2 dan Data2Vec pada data pengujian. Dengan prosedur tersebut, perbandingan dilakukan berdasarkan konfigurasi yang paling sesuai bagi masing-masing model. Pada model yang menggunakan *contrastive* seperti Wav2vec2, informasi fonetik cenderung meningkat di layer tengah dan

menurun di layer akhir [27]. Sehingga lapisan terbaik untuk sebuah studi kasus tidak selalu berada pada lapisan terakhir. Dengan demikian penelitian ini sejak awal diarahkan untuk melakukan ekstraksi secara *layer-wise*.

3.2. Data Understanding

Fase ini bertujuan untuk mengidentifikasi sumber, struktur, cakupan, dan kualitas data yang digunakan dalam penelitian. Tahap ini dilaksanakan sebelum proses ekstraksi *embedding* agar karakteristik data yang dapat memengaruhi evaluasi *retrieval* dapat diketahui secara sistematis. Kegiatan pada tahap ini mencakup pengumpulan data awal, pemeriksaan atribut, analisis struktur direktori dan penamaan berkas, pemeriksaan karakteristik audio, serta penentuan identitas ayat yang digunakan sebagai dasar relevansi.

Penelitian ini menggunakan dua sumber data. Sumber pertama adalah Quran-MD [28] yang digunakan sebagai himpunan data referensi dan juga *query*. Quran-MD menyediakan audio bacaan Al-Qur'an pada tingkat ayat dari sejumlah qori dan disertai anotasi berupa identitas surah, ayat, serta identitas qori. Subset yang digunakan dibatasi pada surah Al-Fatihah dan surah-surah dalam Juz Amma agar sesuai dengan batasan masalah penelitian.

Sumber kedua adalah data primer yang berupa rekaman bacaan mahasiswa yang digunakan sebagai himpunan data referensi dan juga *query*. Pada tahap pengumpulan, rekaman diperoleh dari 81 mahasiswa Program Studi Teknik Informatika UIN Sunan Gunung Djati Bandung sebagai bagian dari kegiatan mata kuliah Tahfidz. Setiap mahasiswa diarahkan untuk mengumpulkan rekaman bacaan surah Al-Fatihah, surah-surah dalam Juz Amma, dan ayat Al-Qur'an yang berhubungan mengenai sains dan teknologi. Jumlah mahasiswa dan berkas yang dapat digunakan dalam eksperimen kemudian ditentukan melalui proses validasi data. Hasil validasi dan statistik akhir himpunan data disajikan pada proses hasil dan pembahasan.

Pemeriksaan struktur data mahasiswa dilakukan terhadap susunan direktori, format nama folder mahasiswa, format nama berkas, dan hubungan antara identitas mahasiswa dengan identitas surah. Pemeriksaan ini diperlukan karena berkas hasil pengumpulan dapat memiliki perbedaan penggunaan huruf besar dan huruf kecil,

separator, simbol, prefiks nomor surah, maupun penulisan nama surah. Variasi tersebut dinormalisasi menjadi identitas baku yang terdiri atas identitas mahasiswa, nomor surah, dan nomor ayat.

Karakteristik audio diperiksa melalui format berkas, *sampling rate*, jumlah kanal, durasi, dan keterbacaan berkas. Pemeriksaan tersebut digunakan untuk menentukan kebutuhan normalisasi audio menjadi 16 kHz dan mono sebelum audio diproses oleh Wav2Vec2 dan Data2vec. Keceragaman format diperlukan agar perbandingan kedua model tidak dipengaruhi oleh perbedaan struktur data pada masukan audio.

Pada himpunan data Quran-MD, pemeriksaan juga dilakukan terhadap distribusi qori, jumlah bacaan per ayat, dan kelengkapan identitas surah dan ayat. Pada himpunan data mahasiswa, pemeriksaan mencakup cakupan surah per mahasiswa, proses segmentasi video satu surah menjadi potongan ayah, validitas berkas audio hasil segmentasi, dan keterhubungan antara setiap klip ayat dengan rekaman sumbernya. Pemeriksaan tersebut digunakan untuk memastikan bahwa relevansi *query* dan dokumen dapat ditentukan berdasarkan pasangan nomor surah dan nomor ayat.

Hasil fase *Data Understanding* menjadi dasar bagi fase *Data Preparation*. Hasil yang dimaksud mencakup penetapan berkas yang dapat digunakan, kebutuhan normalisasi format audio, normalisasi penamaan, pemisahan rekaman berdasarkan identitas surah, serta pembentukan label relevansi. Statistik empiris mengenai jumlah mahasiswa, jumlah klip, cakupan surah, kualitas segmentasi, dan komposisi setiap skenario evaluasi disajikan pada bagian hasil dan pembahasan.

3.3. Data Preparation

Fase Data Preparation bertujuan mengubah data mentah menjadi data yang siap digunakan untuk proses ekstraksi representasi laten. Fase ini mencakup empat tahap yaitu seleksi data, normalisasi audio, verifikasi segmentasi ayat, konstruksi ground truth sebagai dasar evaluasi retrieval ayat.

Proses pertama adalah seleksi data sesuai dengan Batasan masalah, yakni memilih rekaman dari surah Al-Fatihah dan surah-surah dalam Juz Amma yang

disusun berdasarkan ayat. Dari proses seleksi ini akan disusun *identifier* yang terdiri dari gabungan qori, surah dan ayat. Untuk data pada Quran-MD karena mencakup keseluruhan surah yang kita perlukan hanyalah surah Al-Fatihah dan surah-surah Juz Amma. Sedangkan pada data *query* yaitu rekaman mahasiswa itu sudah terdiri dari surah-surah Juz Amma, namun perlu diingat untuk tugas pengumpulan tahfiz terdapat video ayat Al-Quran yang ada kaitannya dengan Sains dan teknologi, itupun perlu dipisahkan.

Proses kedua adalah normalisasi data, normalisasi data adalah menstandarisasi seluruh data audio yang akan dijadikan *ground truth* dan juga data input query yang nantinya digunakan sebagai data testing. Langkah ini untuk menjadi solusi dari pembahasan data understanding yang mengungkap bahwa data Quran-MD itu memiliki audio sampling rate dan jumlah kanal yang berbeda. Sehingga perlu dilakukan konversi pada data yang berbeda untuk sampling rate 16Khz dan jumlah kanal menjadi tunggal (*mono*). Hal ini bertujuan supaya hasil dari representasi laten antara model Wav2vec2 dan Data2vec berasal dari performa masing-masing model tersebut, bukan dari ketidaksesuaian data yang ada.

Proses ketiga adalah *pre-processing* diawali dengan proses normalisasi struktur dataset, yaitu menyeragamkan penamaan direktori dan berkas berdasarkan nomor serta nama surah yang sesuai dengan urutan dalam Al-Qur'an. Proses ini dilakukan untuk mengatasi ketidakkonsistenan penamaan, seperti perbedaan penggunaan huruf besar dan huruf kecil, variasi simbol, maupun format penamaan yang tidak mengikuti konvensi tertentu. Hasil normalisasi tersebut digunakan sebagai dasar dalam proses identifikasi surah secara otomatis pada tahap selanjutnya.

Setelah proses normalisasi selesai, dilakukan segmentasi ayat dan verifikasi terhadap data. Data yang digunakan sebagai *input query* berupa rekaman video mahasiswa yang dalam satu videonya membacakan satu surah secara utuh, mencakup seluruh surah dalam Juz Amma beserta surah Al-Fatihah. Oleh karena itu, setiap rekaman terlebih dahulu diekstraksi menjadi berkas audio, kemudian dilakukan proses segmentasi untuk membagi audio surah menjadi beberapa segmen yang masing-masing merepresentasikan satu ayat. Segmentasi dilakukan melalui

dua tahap. Pertama, model *forced alignment WhisperX* digunakan untuk memperoleh *timestamp* pada tingkat kata dari rekaman mahasiswa satu full surat. Kedua, batas antar ayat ditentukan melalui alokasi proporsional berdasarkan jumlah kata tiap ayat yang bersumber dari API Al-Quran, kemudian audio dipotong menggunakan library *pydub*. Perlu dicatat bahwa pembagian durasi berdasarkan rasio jumlah kata dapat menyebabkan kesalahan kecil pada setiap batas ayat. Kesalahan tersebut dapat terbawa dan bertambah secara kumulatif pada batas-batas berikutnya, sehingga posisi segmentasi dapat semakin melenceng dari batas ayat yang sebenarnya, terutama pada bagian akhir surat.

3.4. Modeling

Fase Modeling pada penelitian ini diadaptasi dari makna aslinya dalam *framework* CRISP-DM. karena penelitian ini menggunakan *frozen embedding* tanpa fine-tuning atau transfer learning, fase ini tidak melibatkan pelatihan model, melainkan berfokus pada ekstraksi representasi laten dari model pre-trained serta konstruksi *similarity* yang menjadi dasar proses retrieval. Fase ini terdiri atas empat sub-proses yaitu pemilihan model, ekstraksi representasi laten secara layer-wise, agregasi fitur menjadi vektor embedding, dan perhitungan skor kemiripan untuk menghasilkan peringkat.

Subproses pertama adalah pemilihan model. Penelitian ini menggunakan dua model Self-Supervised Learning (SSL), yaitu Wav2Vec2 dan Data2Vec, sebagai penghasil frozen embedding. Kedua model digunakan tanpa fine-tuning agar representasi yang dievaluasi berasal langsung dari model pretrained. Wav2Vec2 mempelajari representasi suara melalui pendekatan *contrastive learning* dengan membedakan representasi target dari sejumlah kandidat negatif [1], sedangkan Data2Vec menggunakan pendekatan *self-distillation* dengan memprediksi representasi laten kontekstual yang dihasilkan oleh jaringan teacher [8]. Perbedaan mekanisme pretraining tersebut menjadi dasar pelaksanaan analisis komparatif untuk mengetahui kinerja representasi yang dihasilkan oleh kedua model pada tugas retrieval audio ayat Al-Qur'an. Agar perbandingan dilakukan secara konsisten, kedua model diproses menggunakan data, tahapan preprocessing,

metode ekstraksi embedding, fungsi penilaian cosine similarity, dan prosedur evaluasi yang sama.

Proses selanjutnya adalah ekstraksi representasi laten. Setiap audio yang telah dinormalisasi, baik pada Database (D) maupun Query set (Q), diinputkan ke masing-masing model untuk memperoleh representasi laten. Ekstraksi tidak dibatasi pada lapisan Transformer terakhir, melainkan dilakukan pada seluruh lapisan. Pendekatan layer-wise ini diperlukan karena informasi fonetika dan leksikal pada model SSL tidak terdistribusi merata di seluruh lapisan, melainkan terkonsentrasi pada lapisan tertentu yang bergantung pada paradigma pretraining. Pada model bertipe bertipe contrastive seperti Wav2vec2, informasi fonetik cenderung memuncak di lapisan menengah dan menurun pada lapisan akhir, sehingga lapisan terbaik untuk guatu tugas belum tentu merupakan lapisan terakhir [27]. Dengan mengekstraksi seluruh lapisan, penelitian dapat menganalisis distribusi kinerja antar lapisan dan mengidentifikasi laipsan yang paling optimal bagi tugas retrieval fonetik.

Sub proses ketiga adalah agregasi fitur. Representasi laten pada tiap lapisan berupa urutan vektor sepanjang durasi audio, sehingga perlu digaregasi menjadi satu vector berdimensi tetap agar dapat dibandingkan antar audio. Agregasi dilakukan melalui temporal pooling, dalam hal ini mean pooling, yang merata-ratakan seluruh vector sepanjang dimensi waktu. Hasilnya adalah satu vector embedding per rekaman untuk setiap kombinasi model dan lapisan, yang selnajutnya disusun menjadi basis data vector terpisah bagi masing-masing kombinasi tersebut.

Sub proses terakhir adalah perhitungan *similarity score*. Untuk setiap input query, vector embedding nya akan dibandingkan terhadap seluruh vector pada Database menggunakan cosine similarity, kemudian hasilnya durutkan dari skor tertinggi hingga terendah untuk membentuk daftar peringkat (ranked list). Perlu ditegaskan bahwa dalam penelitian ini cosine similarity berperan sebagai scoring function yang menghasilkan peringkat, bukan sebagai metrik evaluasi [21]. Ayat dengan skor kemiripan tertinggi dianggap sebagai hasil retrieval yang paling

mendekati query, sedangkan kualitas keseluruhan peringkat akan diukur pada fase evaluasi menggunakan metrik yang sesuai.

3.5. Evaluation

Fase ini bertujuan untuk mengukur efektivitas retrieval dari kedua model secara kuantitatif dan membandingkan kinerja keduanya berdasarkan hasil evaluasi yang diperoleh. Pada fase inilah peringkat yang dihasilkan *cosine similarity* dinilai menggunakan metrik evaluasi retrieval. Metrik evaluasi menilai kualitas keseluruhan peringkat terhadap ground truth, bukan menghitung kemiripan antar vector [21].

Fase ini terdiri atas lima subproses, yaitu perhitungan metrik evaluasi, evaluasi layer-wise, analisis perbandingan model, perbandingan tiga skenario evaluasi terkontrol, dan analisis kualitatif.

Sub proses pertama adalah perhitungan metrik evaluasi retrieval. Penelitian ini menggunakan tiga metrik berbasis kualitas peringkat, yaitu Top-K Accuracy, Mean Reciprocal Rank (MRR), dan Mean Average Precision (MAP). Top-K Accuracy mengukur proporsi *query* yang dokumen relevannya berhasil ditempatkan dalam K peringkat teratas, dengan variasi nilai K berupa Top-1, Top-5, dan Top-10, dimana Top-1 digunakan sebagai ukuran evaluasi dengan persyaratan posisi hasil yang paling ketat karena dokumen relevan harus berada pada peringkat pertama. MRR mengukur seberapa tinggi peringkat dokumen relevan pertama, sedangkan MAP menilai kualitas peringkat secara menyeluruh dengan memperhitungkan presisi pada setiap posisi dokumen relevan sepanjang daftar. Ketiga metrik dihitung secara terpisah untuk Wav2vec2 dan Data2vec agar dapat dibandingkan secara langsung.

Sub proses kedua adalah evaluasi layer-wise. Ketiga metrik dihitung pada setiap lapisan Transformer dari kedua model. Hasilnya disusun menjadi kurva kinerja terhadap indeks lapisan sehingga dapat diidentifikasi lapisan yang menghasilkan kinerja retrieval tertinggi bagi masing-masing model. Evaluasi layer-wise digunakan untuk menentukan konfigurasi lapisan yang menghasilkan nilai MAP tertinggi bagi masing-masing model. Pemilihan lapisan dilakukan menggunakan himpunan pengembangan agar data pengujian tidak digunakan

dalam proses penentuan konfigurasi. Lapisan terpilih kemudian digunakan dalam perbandingan akhir Wav2Vec2 dan Data2Vec pada himpunan pengujian. Analisis ini juga memberikan informasi tambahan mengenai distribusi kualitas representasi retrieval pada setiap lapisan model. Pemilihan lapisan menggunakan himpunan pengembangan dan pelaporan akhir menggunakan himpunan pengujian dilakukan untuk mengurangi bias pemilihan konfigurasi.

Subproses ketiga adalah analisis perbandingan kinerja kedua model. Perbandingan dilakukan menggunakan hasil evaluasi Wav2Vec2 dan Data2Vec pada konfigurasi lapisan terbaik masing-masing. Nilai MAP, MRR, dan Top-K Accuracy digunakan untuk mendeskripsikan perbedaan kinerja retrieval, sedangkan interval kepercayaan bootstrap terhadap selisih Average Precision per kueri digunakan untuk menilai kebermaknaan perbedaan MAP kedua model.

Apabila interval kepercayaan 95% terhadap selisih MAP tidak mencakup nilai nol, perbedaan kinerja dinyatakan memiliki dukungan statistik pada tingkat kepercayaan yang digunakan. Sebaliknya, apabila interval kepercayaan mencakup nilai nol, belum terdapat bukti yang cukup untuk menyatakan bahwa salah satu model lebih unggul secara meyakinkan. Prosedur ini digunakan sebagai aturan interpretasi statistik dalam penelitian.

Sub proses keempat adalah perbandingan tiga scenario evaluasi dalam lingkungan yang terkontrol. Untuk memisahkan pengaruh kualitas representasi model dari pengaruh kualitas data, retrieval dijalankan pada tiga scenario yang berbagi satu protokol identik. Layer sweep pada dev set, pelaporan pada test set, serta uji signifikansi *bootstrap* namun berbeda pada sumber data query dan databasenya. Skenario A merupakan kondisi penelitian, yaitu query rekaman mahasiswa terhadap database Quran-MD (lintas dataset). Skenario B menggunakan Quran-MD pada kedua sisi dengan pembagian *leave-reciters-out*, sehingga qori pada query tidak muncul pada database, skenario ini menilai kualitas embedding pada kondisi akustik terkendali. Skenario C menggunakan data mahasiswa pada kedua sisi dengan pembagian *leave-students-out*, sehingga domain gap akustik dihilangkan sepenuhnya namun noise segmentasi tetap dipertahankan. Pada ketiga skenario, relevansi didefinisikan sebagai kesamaan pasangan (surah, ayat) lintas

pembaca, sehingga tidak ada satu pembaca yang muncul pada kedua sisi. Perbandingan skenario A dengan B mengisolasi pengaruh perbedaan domain akustik, sedangkan perbandingan skenario B dengan C mengisolasi pengaruh kualitas akuisisi dan segmentasi. Karena ketiga skenario memiliki ukuran database dan kerapatan dokumen relevan yang berbeda, nilai MAP dilaporkan bersama lift terhadap baseline acak agar perbandingan antar skenario bersifat jujur.

Sub proses terakhir adalah analisis kualitatif untuk melengkapi temuan kuantitatif. Analisis ini dilakukan melalui studi kasus mendalam terhadap query yang berhasil maupun gagal dalam proses retrieval. Kasus keberhasilan dan kegagalan ditelaah untuk menilai sensitivitas fonetik masing-masing model, misalnya mengidentifikasi kondisi ketika suatu model keliru mengambil ayat lain yang memiliki kemiripan bunyi atau pola matra yang tinggi. Hasil analisis ini digunakan untuk mengaitkan temuan empiris dengan justifikasi teori mengenai perbedaan struktur embedding yang dihasilkan oleh paradigma contrastive learning dan self-distillation.

3.6. Deployment

Fase Deployment pada penelitian ini diadaptasi dari makna aslinya dalam CRISP-DM. Karena penelitian bersifat komparatif dan fase ini tidak melibatkan penerapan model dalam sistem produksi. Melainkan berfokus pada sintesis temuan menjadi kesimpulan yang utuh serta perumusan rekomendasi bagi penelitian lanjutan. Fase ini terdiri atas tiga sub proses yaitu sintesis temuan, perumusan rekomendasi pemilihan model, dan identifikasi arah penelitian lanjutan.

Sub proses pertama adalah sintesis temuan. Seluruh hasil evaluasi, meliputi nilai metrik retrieval, kurva kinerja layer-wise, hasil perbandingan statistik, perbandingan antar skenario, dan temuan analisis kualitatif, dirangkum untuk memperoleh gambaran menyeluruh mengenai kinerja kedua model. Sintesis tersebut menjelaskan hasil implementasi Wav2Vec2 dan Data2Vec, perbedaan kinerja retrieval kedua model, tingkat kebermaknaan perbedaannya, serta konfigurasi lapisan yang paling sesuai bagi masing-masing model

Sub proses kedua adalah perumusan rekomendasi pemilihan model. Berdasarkan temuan yang telah disintesis, penelitian merumuskan panduan praktis

mengenai model dan konfigurasi lapisan yang paling sesuai untuk membangun sistem pencarian kemiripan ayat Al-Quran tanpa proses transkripsi maupun *fine-tuning*. Rekomendasi ini mempertimbangkan tidak hanya kualitas retrieval tertinggi, tetapi juga karakteristik representasi masing-masing paradigma pretraining sebagaimana terungkap dari hasil evaluasi.

Sub proses terakhir adalah identifikasi arah penelitian lanjutan berdasarkan keterbatasan yang teridentifikasi selama penelitian, dirumuskan sejumlah arah pengembangan yang dapat ditempuh pada penelitian berikutnya. Arah tersebut mencakup, antara lain, penerapan constrastive fine-tuning untuk menguji apakah adaptasi ringan pada model pretrain dapat meningkatkan kualitas retrieval, perluasan cakupan data ke seluruh juz Al-Quran, serta pengujian model Self-Supervised Learning lain sebagai pembanding tambahan. Arah-arrah ini sekaligus menandai batas ruang lingkup penelitian saat ini dan potensi kontribusinya di masa mendatang.

BAB IV

HASIL DAN PEMBAHASAN

4.1. Hasil Business Understanding

Tahap Business understanding menghasilkan dua output utama sesuai alur penelitian, yaitu identifikasi masalah penelitian, yaitu identifikasi masalah penelitian beserta tujuan penelitian, serta penetapan kriteria evaluasi dan indikator keberhasilan. Kedua output ini menjadi fondasi arah seluruh proses penelitian yang dilaksanakan, mulai dari pengumpulan data audio hingga evaluasi kinerja retrieval kedua model yang dibandingkan.

4.1.1. Identifikasi Masalah

Proses identifikasi masalah dilakukan melalui kajian literatur terhadap penelitian terdahulu mengenai model Self-Supervised Learning (SSL) untuk pemrosesan suara, serta analisis terhadap penerapan model-model tersebut pada domain Bahasa Arab. Berdasarkan hasil identifikasi tersebut, ditemukan bahwa model SSL yang di-*pretrain* pada data berbahasa Inggris cenderung menurun kinerjanya ketika diterapkan pada fonetik Arab, yang memiliki karakteristik khas seperti *emphatic consonants* dan *pharyngeal sounds* yang tidak dimiliki Bahasa Inggris [29]. Al Qur'an, sebagai teks berbahasa Arab dengan kaidah tajwid yang ketat dan presisi tinggi, menjadikan tantangan ini semakin nyata karena pencocokan bacaan menuntut ketepatan pada aspek fonetik, bukan sekedar kecocokan tekstual.

Analisis lebih lanjut terhadap literatur mengungkapkan tiga kesenjangan utama. Pertama, seluruh bukti kegagalan lintas bahasa yang tersedia hanya terbatas pada arsitektur berbasis contrastive learning seperti wav2vec2, sementara kejadian terhadap paradigma self-distillation yang dimiliki Data2vec dalam skenario serupa masih sangat terbatas. Kedua, meskipun penelitian terdahulu telah membandingkan langsung wav2vec2 dan Data2vec untuk pengenalan ucapan (ASR) Bahasa Arab [10], perbandingan tersebut dilakukan dengan supervised fine-tuning dan diukur menggunakan metrik transkripsi (WER/CER) bukan dalam kondisi frozen embedding tanpa fine-tuning dengan metrik retrieval. Ketiga, perbandingan

langsung kedua model untuk tugas audio retrieval yang dievaluasi melalui metrik similarity search seperti MAP, Top-K Accuracy, dan MRR hingga kini masih minim untuk diteliti, sehingga menyisakan pertanyaan fundamental apakah keunggulan salah satu paradigma pada ASR akan tetap berlaku pada retrieval.

Kesenjangan ini menjadi penting karena retrieval dan transkripsi mengukur properti representasi yang berbeda. Pada ASR, fitur diteruskan ke kepala klasifikasi yang ikut dilatih secara *supervised*. Sehingga metrik seperti WER tidak murni mengukur kualitas embedding awal, melainkan separabilitas fitur setelah proses pelatihan tersebut. Sebaliknya, pada retrieval berbasis frozen embedding tidak ada komponen yang dilatih, sehingga metrik seperti MAP secara intrinsik mengukur koherensi geometris ruang vector itu sendiri [30]. Oleh karena itu, keunggulan sebuah model pada ASR tidak dapat langsung diasumsikan berlaku pada retrieval dan inilah celah yang menjadi fokus utama penelitian ini.

4.1.2. Tujuan Penelitian

Berdasarkan identifikasi masalah tersebut, tujuan penelitian ini adalah mengimplementasikan Wav2Vec2 dan Data2Vec sebagai penghasil frozen embedding serta mengevaluasi dan membandingkan kinerja retrieval kedua model pada audio ayat Al-Qur'an. Hasil evaluasi digunakan untuk memberikan rekomendasi mengenai model dan konfigurasi lapisan yang sesuai berdasarkan dataset dan skenario penelitian yang digunakan, khususnya untuk domain ayat Al-Qur'an yang memiliki karakteristik fonetik khas. Untuk mencapai rekomendasi yang objektif, penelitian ini membandingkan dua model dengan paradigma pretraining yang berbeda, Wav2vec2 dengan paradigma *contrastive learning* dan Data2vec dengan paradigma *Self-Distillation* dalam skenario retrieval.

Tujuan penelitian ini terdiri atas dua tujuan utama. Pertama, mengimplementasikan model Wav2Vec2 dan Data2Vec sebagai penghasil frozen embedding dalam sistem retrieval audio ayat Al-Qur'an. Kedua, mengevaluasi dan membandingkan kinerja retrieval frozen embedding Wav2Vec2 dan Data2Vec berdasarkan metrik Mean Average Precision (MAP), Mean Reciprocal Rank (MRR), dan Top-K Accuracy, dengan cosine similarity sebagai fungsi penilaian.

4.1.3. Kriteria Evaluasi dan Keberhasilan

Kriteria evaluasi dan validitas eksperimen ditetapkan sebagai acuan untuk menilai ketercapaian dua tujuan penelitian, yaitu implementasi Wav2Vec2 dan Data2Vec sebagai penghasil frozen embedding serta evaluasi dan perbandingan kinerja retrieval kedua model. Kriteria tersebut mencakup keberhasilan implementasi sistem, validitas data evaluasi, dan prosedur perbandingan kinerja model.

Pada aspek implementasi, sistem dinyatakan berhasil apabila Wav2Vec2 dan Data2Vec dapat digunakan untuk mengekstraksi representasi frozen embedding dari data audio yang memenuhi persyaratan input model. Embedding yang dihasilkan harus memiliki bentuk dan dimensi yang konsisten, dapat dikaitkan dengan metadata identitas ayat, serta dapat digunakan dalam perhitungan cosine similarity dan penyusunan peringkat hasil retrieval. Tidak terbentuknya embedding pada sebagian audio tidak secara langsung dikategorikan sebagai kegagalan implementasi. Setiap kasus tersebut terlebih dahulu dianalisis berdasarkan penyebabnya, seperti durasi audio yang terlalu pendek, berkas audio yang rusak, sinyal kosong setelah preprocessing, ketidaksesuaian format input, keluaran numerik yang tidak valid, keterbatasan komputasi, atau kesalahan pada tahapan pemrosesan. Kasus yang disebabkan oleh karakteristik audio yang tidak memenuhi kebutuhan input model dicatat sebagai keterbatasan data atau keterbatasan model dalam memproses karakteristik input tertentu. Sementara itu, kasus yang disebabkan oleh kesalahan kode, konfigurasi, atau proses komputasi dikategorikan sebagai kegagalan teknis yang harus diperbaiki sebelum evaluasi dilanjutkan.

Untuk menjaga konsistensi perbandingan, evaluasi hanya dilakukan terhadap audio yang dapat diproses oleh kedua model. Apabila suatu audio tidak menghasilkan embedding pada salah satu model, audio tersebut tidak dimasukkan ke dalam evaluasi utama kedua model. Jumlah audio yang dikeluarkan, karakteristiknya, dan penyebab kegagalan ekstraksinya tetap didokumentasikan sebagai bagian dari analisis kualitas data dan keterbatasan penelitian. Prosedur ini memastikan bahwa Wav2Vec2 dan Data2Vec dibandingkan menggunakan himpunan kueri dan basis data yang sama.

Implementasi dinilai berhasil apabila pipeline ekstraksi dapat dijalankan secara konsisten pada seluruh data yang memenuhi persyaratan input model, sedangkan setiap data yang tidak dapat menghasilkan embedding telah diidentifikasi penyebabnya, didokumentasikan, dan ditangani menggunakan prosedur eksklusi yang sama pada kedua model.

Pada aspek validitas data evaluasi, setiap audio kueri harus memiliki setidaknya satu audio relevan di dalam basis data. Relevansi ditentukan berdasarkan kesamaan pasangan identitas surah dan ayat antara audio kueri dan audio pada basis data. Ketentuan tersebut diperlukan agar tidak terdapat kueri yang memperoleh nilai Average Precision sebesar nol hanya karena dokumen relevan tidak tersedia di dalam basis data.

Kinerja retrieval dievaluasi menggunakan Mean Average Precision (MAP), Mean Reciprocal Rank (MRR), dan Top-K Accuracy. MAP digunakan untuk menilai kualitas peringkat hasil retrieval secara keseluruhan, MRR digunakan untuk menilai posisi kemunculan dokumen relevan pertama, sedangkan Top-K Accuracy digunakan untuk mengetahui apakah dokumen relevan ditemukan pada sejumlah posisi teratas. Cosine similarity digunakan sebagai fungsi penilaian untuk menghitung kemiripan dan menghasilkan urutan kandidat ayat, bukan sebagai metrik evaluasi.

Untuk menjaga objektivitas pemilihan konfigurasi, lapisan terbaik masing-masing model ditentukan menggunakan himpunan pengembangan berdasarkan nilai MAP tertinggi. Lapisan terpilih kemudian digunakan untuk mengevaluasi kinerja akhir pada himpunan pengujian yang tidak digunakan selama proses pemilihan lapisan. Pemisahan tersebut dilakukan untuk mengurangi bias pemilihan konfigurasi dan menghasilkan estimasi kinerja yang lebih objektif.

Perbandingan Wav2Vec2 dan Data2Vec dilakukan berdasarkan nilai metrik yang diperoleh pada himpunan pengujian. Kebermaknaan selisih kinerja kedua model dianalisis menggunakan interval kepercayaan 95% yang dihitung melalui metode bootstrap dengan 10.000 resampling terhadap nilai Average Precision per kueri. Apabila interval kepercayaan selisih MAP tidak mencakup nilai nol, perbedaan kinerja kedua model dinyatakan memiliki dukungan statistik.

Sebaliknya, apabila interval kepercayaan mencakup nilai nol, belum terdapat bukti yang cukup untuk menyatakan bahwa salah satu model lebih unggul secara meyakinkan.

Penelitian tidak menetapkan nilai minimum MAP, MRR, atau Top-K Accuracy sebagai syarat keberhasilan. Ketercapaian penelitian ditentukan berdasarkan keberhasilan implementasi kedua model, validitas prosedur evaluasi, dan tersedianya hasil perbandingan empiris yang dapat menjawab rumusan masalah. Dengan demikian, hasil berupa perbedaan yang signifikan maupun tidak signifikan tetap menjadi temuan penelitian selama diperoleh melalui prosedur evaluasi yang konsisten dan dapat dipertanggungjawabkan.

4.2. Hasil Data Understanding

Fase Hasil *Data Understanding* menghasilkan pemahaman mengenai struktur, cakupan, dan kualitas dua himpunan data yang digunakan dalam penelitian, yaitu rekaman bacaan mahasiswa dan Quran-MD [28]. Rekaman mahasiswa digunakan sebagai *query* pada skenario lintas domain dan sebagai kueri serta *database* referensi pada skenario lintas mahasiswa. Sementara itu, Quran-MD digunakan sebagai *database* referensi pada skenario lintas domain dan sebagai kueri serta basis data pada skenario lintas qori.

Pemeriksaan dilakukan terhadap jumlah berkas, identitas pembaca, identitas surah dan ayat, struktur direktori, validitas audio, serta ketersediaan dokumen relevan pada setiap skenario. Hasil pemeriksaan tersebut digunakan untuk membentuk pasangan kueri dan basis data yang dapat dievaluasi secara terkontrol.

Quran-MD disimpan dalam format Parquet dengan atribut sebagaimana disajikan pada Tabel 4.1.

Tabel 4.1 Atribut dan Tipe Data Quran-MD

Nama Column	Tipe Data
surah_id	Int32
ayah_id	Int32
Surah_name_ar	String
Surah_name_en	String

Surah_name_tr	String
Ayah_count	Int32
Ayah_ar	String
Ayah_tr	String
Reciter_id	String
Reciter_name	String
Audio	Audio File (MP3 format)

Setiap klip pada kedua himpunan data dipetakan ke identitas surah dan ayat. Pasangan nomor surah dan nomor ayat tersebut digunakan sebagai dasar penentuan relevansi. Dengan demikian, suatu dokumen dinyatakan relevan terhadap kueri apabila keduanya memiliki identitas surah dan ayat yang sama, tanpa menggunakan transkripsi sebagai perantara.

4.2.1. Karakteristik Himpunan data Mahasiswa

Pengumpulan awal melibatkan 81 mahasiswa. Angka tersebut menunjukkan jumlah mahasiswa pada tahap pengumpulan dan tidak dapat langsung diperlakukan sebagai jumlah mahasiswa pada korpus eksperimen. Setelah proses audit dan penyaringan terhadap folder folder yang tidak terdapat video, korpus tervalidasi mencakup 60 mahasiswa.

Direktori hasil segmentasi memuat 25.945 berkas MP3 mentah. Sebanyak 116 berkas berukuran nol byte dikeluarkan sebelum proses ekstraksi *embedding*. Setelah eksklusi tersebut, diperoleh 25.829 klip audio valid. Korpus tervalidasi mencakup 38 surah, yaitu surah Al-Fatihah dan surah-surah dalam Juz Amma, serta 1.795 rekaman valid pada tingkat pasangan mahasiswa dan surah.

Dengan demikian, angka 81 dan 60 menjelaskan dua tahap yang berbeda. Angka 81 menunjukkan jumlah mahasiswa pada tahap pengumpulan, sedangkan angka 60 menunjukkan mahasiswa yang tervalidasi memiliki video rekaman pada folder yang sudah diupload. Demikian pula, 25.945 menunjukkan jumlah berkas MP3 mentah yang ditemukan, sedangkan 25.829 menunjukkan jumlah klip valid yang digunakan untuk ekstraksi *embedding* dan evaluasi.

Berdasarkan hasil rekonsiliasi dengan catatan audit segmentasi, 25.829 klip valid terdiri atas 24.872 klip dari rekaman yang memiliki catatan audit berhasil, 710 klip hasil segmentasi berbasis alokasi waktu proporsional dari 91 rekaman, dan 247 klip dari 19 rekaman yang tidak memiliki baris pasangan pada catatan audit. Ketiga kategori tersebut tetap dapat ditelusuri melalui manifes tervalidasi sehingga asal setiap klip dapat diketahui.

Variasi format penamaan ditemukan pada direktori mahasiswa dan nama berkas. Variasi tersebut meliputi penggunaan garis bawah atau tanda hubung sebagai separator, penggunaan nomor urut pengumpulan atau nomor surah sebagai prefiks, perbedaan kapitalisasi, serta penggunaan kata “Surah” atau “Q.S.”. Seluruh identitas kemudian dinormalisasi berdasarkan nomor surah standar. Normalisasi tersebut memungkinkan berkas dengan format penamaan berbeda dipetakan ke identitas surah yang sama. Dan juga terdapat beberapa video yang digabungkan antar surah nya, sehingga perlu dilakukan pemisahan secara manual, menjadikan file video tersebut menjadi file audio masing-masing surah.

4.2.2. Karakteristik Himpunan Data Quran-MD

Himpunan data Quran-MD menyediakan audio bacaan Al-Qur'an pada tingkat ayat dari 30 qori. Subset penelitian dibatasi pada surah Al-Fatihah dan Juz Amma sehingga cakupannya selaras dengan korpus mahasiswa. Setiap klip memiliki anotasi identitas qori, nomor surah, dan nomor ayat.

Pada tahap ekstraksi, tersedia 17.130 baris audio referensi. Sebanyak tiga baris mengalami kegagalan pemrosesan dan dikeluarkan secara konsisten pada kedua model. Dengan demikian, jumlah klip referensi yang dapat digunakan dalam evaluasi adalah 17.127 klip.

Pada skenario lintas qori, 30 qori dibagi menjadi dua kelompok yang tidak saling tumpang tindih. Sebanyak sembilan qori digunakan sebagai pemilik kueri, sedangkan 21 qori digunakan sebagai pemilik dokumen basis data. Pemisahan berdasarkan identitas qori dilakukan agar qori yang digunakan sebagai *query* tidak muncul pada *database*.

4.2.3. Cakupan relevansi dan Ukuran Skenario

Evaluasi dilakukan melalui tiga skenario. Skenario A merupakan skenario lintas domain dengan rekaman mahasiswa sebagai *query* dan Quran-MD sebagai *database* referensi. Skenario B merupakan skenario lintas qori dengan *query* dan *database* yang sama-sama berasal dari Quran-MD, tetapi menggunakan kelompok qori yang berbeda. Skenario C merupakan skenario lintas mahasiswa dengan *query* dan *database* referensi yang berasal dari kelompok mahasiswa yang berbeda.

Ukuran masing-masing skenario setelah validasi dan pembersihan disajikan pada Tabel 4.2.

Tabel 4.2 Ukuran Data dan Cakupan Relevansi pada Setiap Skenario Evaluasi

Skenario	Klip Query	Klip Database	Cakupan Relevansi
A (<i>Mahasiswa</i> → <i>Quran – MD</i>)	25.829	17.127	100%
B (<i>Quran – MD</i> → <i>Quran – MD</i>)	5.139	11.988	100%
C (<i>Mahasiswa</i> → <i>Mahasiswa</i>)	7.940	17.889	100%

Pada Skenario A, seluruh 25.829 klip mahasiswa digunakan sebagai himpunan *query* dan dibandingkan dengan 17.127 klip Quran-MD. Skenario ini merupakan skenario utama karena menguji transfer representasi dari bacaan mahasiswa ke basis data yang dibacakan oleh qori lain dan berasal dari domain rekaman berbeda.

Pada Skenario B, pembagian *leave-reciters-out* menghasilkan 5.139 klip kueri dari sembilan qori dan 11.988 klip basis data dari 21 qori lainnya. Skenario ini mengukur kemampuan model membedakan ayat ketika sumber kueri dan basis data berasal dari himpunan data yang sama, tetapi pembacanya berbeda.

Pada Skenario C, pembagian *leave-students-out* menghasilkan 7.940 klip kueri dari 18 mahasiswa dan 17.889 klip basis data dari 42 mahasiswa lainnya. Pemisahan berdasarkan mahasiswa mencegah pembaca yang sama muncul pada kedua sisi dan menguji kemampuan generalisasi antarbacaan mahasiswa.

Seluruh skenario memiliki cakupan relevansi 100%. Artinya, setiap kueri pada ketiga skenario memiliki sedikitnya satu dokumen relevan pada basis data berdasarkan pasangan nomor surah dan nomor ayat.

4.2.4. Kualitas Data

Pemeriksaan kualitas dilakukan pada tahap sebelum ekstraksi *embedding* dan setelah ekstraksi *embedding*. Sebelum ekstraksi, 116 berkas berukuran nol byte dikeluarkan dari 25.945 berkas audio berformat MP3 mentah. Berkas tersebut tidak dimasukkan ke dalam 25.829 klip tervalidasi dan bukan dihitung sebagai kegagalan model, namun sebagai data yang tidak bisa diuji.

Pada proses ekstraksi *embedding*, seluruh 25.829 klip mahasiswa berhasil diproses oleh Wav2Vec2 dan Data2vec. Dengan demikian, tidak terdapat kegagalan ekstraksi pada himpunan mahasiswa untuk kedua model. Pada himpunan Quran-MD, tiga dari 17.130 baris referensi mengalami kegagalan pemrosesan. Ketiga baris tersebut dikeluarkan melalui mekanisme *union filtering* sehingga kedua model dievaluasi pada 17.127 klip referensi yang sama.

Pemakaian indeks yang sama setelah pembersihan memastikan bahwa Wav2Vec2 dan Data2vec dibandingkan pada kueri dan dokumen yang identik. Tidak terdapat vektor nol maupun nilai *NaN* pada matriks akhir yang digunakan untuk menghitung cosine similarity.

4.3. Hasil Data Preparation

4.3.1. Normalisasi Audio

Seluruh berkas audio pada himpunan query dan database diseragamkan ke sampling rate 16 khz dengan kanal mono, sesuai dengan spesifikasi masukan yang disyaratkan oleh kedua model pretrained Wav2vec2 dan Data2vec. Normalisasi ini memastikan bahwa perbedaan format perekaman antara rekaman query, yang diupload mahasiswa dan rekaman pada Quran-MD tidak menjadi sumber variasi yang ditakutkan malah menjadi variable penentu hasil performa model SSL.

4.3.1.1. Normalisasi Data Quran-MD

Normalisasi audio dilakukan melalui pipeline bertahap untuk memastikan semua data memenuhi syarat untuk tiap model SSL. Dataset Quran-MD disimpan dalam format *Parquet* dengan audio terkompresi MP3 (bitrate 64kbps) sebagai raw bytes. Proses ekstraksi dan konversi mengikuti tahapan berikut

1. Ekstraksi Audio dari *Parquet*

Dalam proses ini digunakan library datasets dan soundfile. Audio dalam parquet disimpan sebagai struktur {bytes, path} dengan format MP3. Library datasets secara default melakukan decoding otomatis menggunakan *soundfile*, yang mana tidak mendukung format MP3. Oleh karena itu, decoding otomatis dinonaktifkan *cast_column("audio", Audio(decode=False))* untuk mengakses raw byte secara langsung.

2. Decoding MP3 dengan *librosa*

Raw bytes MP3 didecode menggunakan *librosa.load()* dengan parameter *sr=None* untuk mempertahankan sampling rate asli tanpa resampling paksa. Pendekatan ini mencegah degradasi kualitas akibat double resampling. Fungsi ini mengembalikan numpy array dengan shape (channels, samples) dan sampling rate asli.

3. Resampling menjadi 16kHz

Audio dengan sampling rate tidak sama dengan 16kHz dilakukan resampling menggunakan *librosa.resample()* dengan algoritma polyphase filtering default. Resampling ini menggunakan anti-aliasing filter untuk mencegah aliasing artifacts yang dapat mengganggu ekstraksi fitur audio downstream.

4. Konversi ke Mono

Audio stereo (jika ada) dikonversi ke mono menggunakan *librosa.to_mono()* dengan melakukan averaging pada channel. Meskipun dataset Quran-MD secara default sudah mono, langkah ini ditambahkan sebagai safeguard untuk menangani kasus edge.

5. Penyimpanan WAV PCM 16-bit

Audio yang telah dinormalisasi disimpan dalam format WAV dengan encoding PCM 16-bit menggunakan *soundfile.write()*. Format ini dipilih karena:

- Lossless compression (tidak ada degradasi kualitas)
- Kompatibilitas universal dengan library audio processing
- Sesuai dengan requirement input Wav2Vec2 dan Data2Vec2

4.3.1.2. Normalisasi data *query* (testing)

Tahapan data preparation pada data query yaitu mentransformasi rekaman video setoran hafalan mahasiswa menjadi unit-unit audio per ayat yang diperuntukkan untuk proses berikutnya. Proses ini melibatkan ekstraksi audio, penyelarasan teks ke suara (force alignment) dan pemotongan audio secara otomatis.

1. Ekstraksi Audio

Seluruh berkas video dalam format .mp4, .mov, .avi, .mkv yang diunggah oleh mahasiswa diekstraksi komponen audionya saja. Proses ini menggunakan library *moviepy* untuk aliran audio dari video kedalam format MP3.

2. Normalisasi Nama surah dan Nama berkas

Mengingat variasi penamaan berkas oleh mahasiswa (contoh: "78-annaba", "an-nas.mp4", "114. an nas"), dilakukan proses normalisasi teks untuk memetakan nama berkas ke ID surah yang valid pada dataset Quran. Proses ini meliputi

2.1. **Character Cleaning:** menghapus angka diawal nama, mengubah separator (dash/underscore) menjadi spasi, dan menghapus karakter non-alfanumerik.

2.2. **String Mapping:** memastikan file dengan termapping dengan benar, contohnya: surah ke 78 yaitu An-Naba jika hanya diberikan nama "naba" maka akan menjadi "an-naba" . yang mana "an-naba" merupakan value yang telah disetarakan dan menjadi master nama surah ke 78.

3. Transkripsi dan penyelarasan waktu (*Force Alignment*)

Untuk membagi satu audio utuh surah menjadi potongan per ayat, digunakan model WhisperX (berbasis-model large-v2). Prosesnya sebagai berikut

- Transkripsi Bahasa Arab: Model melakukan inferensi awal untuk mendeteksi kata-kata dalam bahasa Arab.
- Phoneme-level Alignment: Menggunakan model penyelarasan khusus untuk mendapatkan stempel waktu (*timestamp*) yang presisi di tingkat kata.
- Identifikasi Awal Surah: Sistem secara otomatis mendeteksi kata pertama dari surah (seperti '*amma*' pada An-Naba) untuk melewati bagian *ta'awwudh* atau pengenalan (*intro*) yang dilakukan oleh mahasiswa

4. Segmentasi Ayat berbasis Rasio Kata

Setelah stempel waktu kata didapatkan, dilakukan pembagian audio berdasarkan jumlah kata tiap ayat yang bersumber dari API Al-Quran Cloud. Audio dipotong menggunakan *pydub* berdasarkan rentang waktu mulai dari kata pertama ayat hingga kata terakhir ayat tersebut. Hasil akhirnya adalah berkas audio individu (ayah_01.mp3, ayah_02.mp3, dst) dengan format PCM yang terorganisir dalam direktori per mahasiswa dan per surah.

4.3.2. Pembagian set *dev* dan set *test*

Untuk menjamin pemilihan lapisan optimal tidak bias terhadap data yang sama yang digunakan untuk pelaporan akhir, himpunan query dibagi menjadi dua bagian set pengembangan 70%, dan set uji 30%. Pembagian dilakukan secara terstratifikasi berdasarkan pasangan (nomor surah, dan nomor ayat), sehingga distribusi ayat pada kedua set tetap seimbang dan tidak ada ayat yang sepenuhnya hilang dari salah satu set. Set pengembangan digunakan untuk menyapu seluruh lapisan (layer sweep) dan memilih lapisan dengan MAP tertinggi bagi masing-masing model, sedangkan set uji digunakan semata-mata untuk melaporkan kinerja akhir pada lapisan terpilih. Protocol dua-set ini mengikuti praktik standar evaluasi *query-by-example* pada tolak ukur SUPERB [3], yaitu memilih lapisan terbaik pada

set pengembangan dan melaporkannya pada set uji, guna menghindari kebocoran informasi yang dapat menghasilkan estimasi kinerja yang terlalu optimis.

4.4. Modeling

Fase Modeling dilakukan untuk mengekstrak frozen embedding dari kedua model Self-Supervised Learning tanpa proses fine-tuning, kemudian menghitung skor kemiripan untuk menghasilkan retrieval.

4.4.1. Ekstraksi Frozen Embedding per-lapisan

Wav2Vec2 dan Data2vec digunakan dalam kondisi *frozen*, yaitu tanpa proses *fine-tuning* maupun pembaruan parameter. Kedua model memproses masukan audio 16 kHz mono melalui *feature encoder* konvolusional dan 12 lapisan Transformer. Representasi diekstraksi dari 13 titik pengamatan, yaitu lapisan ke-0 sebagai keluaran *feature encoder* dan lapisan ke-1 sampai lapisan ke-12 sebagai keluaran setiap blok Transformer.

Setiap lapisan menghasilkan representasi berdimensi 768 pada sejumlah langkah waktu. Representasi temporal tersebut diagregasi menggunakan *temporal mean pooling* sehingga setiap klip menghasilkan satu vektor berdimensi 768 untuk setiap lapisan. Dengan demikian, setiap model menghasilkan 13 matriks *embedding* yang selanjutnya dapat dievaluasi secara terpisah.

Ekstraksi dilakukan terhadap 25.829 klip mahasiswa dan 17.130 baris audio referensi Quran-MD. Seluruh 25.829 klip mahasiswa berhasil diekstraksi oleh Wav2Vec2 dan Data2vec tanpa kegagalan. Pada himpunan referensi, tiga baris gagal diproses sehingga jumlah klip referensi yang dapat digunakan adalah 17.127.

Hasil validasi menunjukkan bahwa kedua model menghasilkan matriks berukuran 25.829×768 pada setiap lapisan untuk himpunan mahasiswa. Setiap baris matriks dipertahankan dalam urutan yang sama dengan manifestasi audio sehingga identitas surah, ayah, dan pembaca dapat ditelusuri kembali pada tahap evaluasi.

4.4.2. Data Cleaning

Berbeda dengan normalisasi audio yang menyeragamkan format masukan, tahap data cleaning bertujuan menyingkirkan klip yang gagal menghasilkan embedding valid agar tidak mencemari perhitungan kemiripan. *Cleaning* dilakukan secara bertahap mengikuti alur ekstraksi embedding.

4.4.2.1. Deteksi klip gagal saat ekstraksi

Pada saat frozen embedding, setiap klip diproses satu per satu oleh masing-masing model. Sejumlah kecil klip gagal diproses karena durasinya terlalu pendek, sehingga jumlah frame yang tersisa setelah melewati encoder konvolusi pada lapisan pertama tidak mencukupi untuk membentuk representasi. Kegagalan ini ditangkap sebagai pengecualian pada saat pemanggilan model. Klip yang gagal akan tetap disimpan pada buffer sebagai vector nol dan ditandai melalui kolom failed pada manifest output. Kegagalan teridentifikasi pada 1 klip di himpunan query (Surah Al-Fil ayat pertama) dan 3 klip pada database referensi.

4.4.2.2. Vektor Nol

Vektor nol berbahaya bagi evaluasi berbasis cosine similarity karena menghasilkan skor kemiripan nol (atau tidak terdefinisi/NaN) terhadap seluruh kandidat. Akibatnya urutan peringkat klip terbuset menjadi acak dan dapat merusak perhitungan MAP maupun MRR secara tidak disadari.

4.4.2.3. Penjaminan Keselarasan Baris

Mekanisme union menjaga keselarasan baris (row alignment) antar kedua model. Setiap indeks query dan referensi merujuk pada klip yang identik, sehingga perbandingan kinerja kedua model itu selaras dan tidak ada perbedaan data. Verifikasi terakhir memastikan himpunan data bersih tidak lagi memuat vektor bernilai nol maupun NaN.

4.4.3. Similarity Scoring dan Ranking

Peringkat retrieval dibentuk dengan menghitung cosine similarity antara vector embedding setiap query dan seluruh vector embedding dalam basis data

referensi pada lapisan yang sama. Untuk setiap query, seluruh klip referensi diurutkan menurun berdasarkan skor peringkat teratas.

cosine similarity di sini berperan sebagai scoring function yang menentukan urutan peringkat bukan sebagai metrik evaluasi. Pemilihan cosine similarity sesuai dengan sifat retrieval berbasis frozen embedding, yang mengukur kedekatan arah antar vector pada ruang representasi tanpa bergantung pada magnitudonya. Kualitas peringkat yang dihasilkan selanjutnya dievaluasi menggunakan metrik MAP, Top-K Accuracy, dan MRR pada fase *Evaluation*

4.5. Evaluation

Evaluasi dilakukan untuk membandingkan kualitas *retrieval* Wav2Vec2 dan Data2vec pada tiga skenario. Cosine similarity digunakan sebagai fungsi penilaian untuk mengurutkan dokumen berdasarkan kemiripan vektor. Cosine similarity tidak digunakan sebagai metrik evaluasi. Kualitas peringkat diukur menggunakan MAP, MRR, Top-1, Top-5, dan Top-10.

MAP mengukur kualitas keseluruhan urutan dokumen relevan, MRR menilai posisi dokumen relevan pertama, sedangkan Top-K menunjukkan proporsi kueri yang memiliki sedikitnya satu dokumen relevan pada K peringkat teratas. Nilai yang disajikan dalam tabel dinyatakan sebagai persentase, yaitu nilai metrik dalam bentuk proporsi dikalikan 100.

Pemilihan lapisan dilakukan hanya pada *development set*. Setelah lapisan terbaik diperoleh untuk setiap model dan skenario, lapisan tersebut digunakan satu kali pada *test set*. Pembagian *dev set* dan *test set* serta lapisan terpilih disajikan pada tabel berikut.

Tabel 4.3 Distribusi Pengetesan Dataset

Skenario	Total Query	Development	Test	Lapisan Wav2Vec2 / Data2vec
A	25.829	17.839	7.990	7 / 5
B	5.139	3.426	1.713	7 / 6
C	7.940	5.331	2.609	7 / 5

Hasil tersebut menunjukkan bahwa lapisan ke-7 menjadi lapisan terbaik Wav2Vec2 pada seluruh skenario. Pada Data2vec, lapisan ke-5 menjadi lapisan terbaik pada Skenario A dan C, sedangkan lapisan ke-6 menjadi lapisan terbaik pada Skenario B.

4.5.1. Kinerja Retrieval Frozen Embedding

Kinerja kedua model pada *test set* untuk ketiga skenario disajikan pada tabel berikut.

Tabel 4.4 Kinerja Model Pada Setiap Skenario

Skenario	Model	Lapisan	MAP	MRR	Top-1	Top-5	Top-10
A	Wav2Vec2	7	1,41%	9,05%	5,38%	11,51%	15,77%
A	Data2vec	5	1,58%	8,56%	4,88%	11,16%	15,19%
B	Wav2Vec2	7	13,42%	59,53%	50,85%	69,24%	74,78%
B	Data2vec	6	11,92%	52,84%	44,13%	62,17%	68,59%
C	Wav2Vec2	7	3,42%	27,99%	20,05%	35,99%	42,32%
C	Data2vec	5	3,74%	27,96%	20,58%	35,03%	42,58%

Pada Skenario A, Data2vec menghasilkan MAP lebih tinggi, yaitu 1,58%, dibandingkan Wav2Vec2 sebesar 1,41%. Namun, Wav2Vec2 memperoleh nilai lebih tinggi pada MRR dan seluruh Top-K. Wav2Vec2 menghasilkan MRR 9,05%, Top-1 5,38%, Top-5 11,51%, dan Top-10 15,77%, sedangkan Data2vec masing-masing menghasilkan 8,56%, 4,88%, 11,16%, dan 15,19%. Temuan ini menunjukkan bahwa Data2vec menghasilkan akumulasi *average precision* yang lebih baik, tetapi Wav2Vec2 lebih sering menempatkan dokumen relevan pertama pada posisi lebih awal.

Skenario B menghasilkan kinerja absolut tertinggi. Wav2Vec2 unggul pada seluruh metrik dengan MAP 13,42%, MRR 59,53%, Top-1 50,85%, Top-5 69,24%, dan Top-10 74,78%. Data2vec menghasilkan MAP 11,92%, MRR 52,84%, Top-1 44,13%, Top-5 62,17%, dan Top-10 68,59%. Kinerja yang lebih tinggi pada

skenario ini menunjukkan bahwa *retrieval* lebih mudah ketika kueri dan basis data berasal dari domain Quran-MD yang sama, meskipun qori pada kedua sisi dipisahkan.

Pada Skenario C, Data2vec memperoleh MAP 3,74%, lebih tinggi daripada Wav2Vec2 sebesar 3,42%. Data2vec juga sedikit lebih tinggi pada Top-1 dan Top-10, masing-masing sebesar 20,58% dan 42,58%, dibandingkan Wav2Vec2 sebesar 20,05% dan 42,32%. Sebaliknya, Wav2Vec2 sedikit lebih tinggi pada MRR, yaitu 27,99% dibandingkan 27,96%, serta pada Top-5, yaitu 35,99% dibandingkan 35,03%.

Secara umum, Wav2Vec2 menghasilkan MRR dan Top-5 yang lebih tinggi pada ketiga skenario. Data2vec menghasilkan MAP lebih tinggi pada Skenario A dan C, sedangkan Wav2Vec2 menghasilkan MAP lebih tinggi pada Skenario B. Oleh karena itu, keunggulan model tidak dapat dinyatakan secara mutlak tanpa menyebutkan metrik dan skenario yang digunakan.

4.5.2. Perbandingan Wav2vec2 dan Data2vec

Perbandingan statistik dilakukan terhadap selisih *average precision* per kueri dengan definisi selisih Data2vec dikurangi Wav2Vec2. Pengujian menggunakan 10.000 *bootstrap resampling*. Selang kepercayaan 95% yang tidak mencakup nol menunjukkan bahwa perbedaan MAP antara kedua model bersifat signifikan pada skenario tersebut.

Tabel 4.5 Selisih MAP pada kedua Model

Skenario	Selisih MAP	Selang Kepercayaan 95%	Kemenangan per Kueri Data2vec / Wav2Vec2
A	+0,17 poin persentase	[+0,10; +0,24] poin persentase	4.078 / 3.912
B	-1,51 poin persentase	[-1,97; -1,04] poin persentase	671 / 1.042

C	+0,32 poin persentase	[+0,18; +0,47] poin persentase	1.269 / 1.340
---	--------------------------	-----------------------------------	---------------

Berdasarkan MAP dan hasil bootstrap, perbandingan kedua model menunjukkan hasil yang berbeda pada setiap skenario. Pada Skenario A, Data2vec memperoleh MAP 0,0158, lebih tinggi daripada Wav2Vec2 sebesar 0,0141. Selisih MAP Data2vec terhadap Wav2Vec2 sebesar 0,00168 dengan interval kepercayaan 95% [0,00100; 0,00237], sehingga perbedaannya signifikan secara statistik. Meskipun demikian, Wav2Vec2 menghasilkan MRR, Top-1, Top-5, dan Top-10 yang lebih tinggi.

Pada Skenario B, Wav2Vec2 memperoleh MAP 0,1342, lebih tinggi daripada Data2vec sebesar 0,1192. Selisih MAP Data2vec terhadap Wav2Vec2 sebesar -0,01507 dengan interval kepercayaan 95% [-0,01966; -0,01044], sehingga perbedaannya signifikan secara statistik dan mengarah pada keunggulan Wav2Vec2. Pada skenario ini, Wav2Vec2 juga menghasilkan nilai lebih tinggi pada MRR dan seluruh Top-K. Nilai Top-1 tertinggi dalam penelitian, yaitu 50,85%, dicapai oleh Wav2Vec2 pada Skenario B.

Pada Skenario C, Data2vec memperoleh MAP 0,0374, lebih tinggi daripada Wav2Vec2 sebesar 0,0342. Selisih MAP Data2vec terhadap Wav2Vec2 sebesar 0,00317 dengan interval kepercayaan 95% [0,00176; 0,00465], sehingga perbedaannya signifikan secara statistik. Namun, hasil metrik lainnya bersifat campuran. Data2vec menghasilkan Top-1 dan Top-10 yang lebih tinggi, sedangkan Wav2Vec2 menghasilkan MRR dan Top-5 yang sedikit lebih tinggi.

Dengan demikian, tidak terdapat satu model yang menghasilkan kinerja tertinggi secara konsisten pada seluruh skenario dan metrik evaluasi. Data2vec menghasilkan MAP lebih tinggi pada Skenario A dan C, sedangkan Wav2Vec2 menghasilkan MAP lebih tinggi pada Skenario B. Hasil tersebut menunjukkan bahwa perbandingan kinerja Wav2Vec2 dan Data2vec perlu disampaikan secara spesifik berdasarkan skenario dan metrik yang digunakan. Uji signifikansi dalam penelitian ini hanya diterapkan pada selisih MAP, sedangkan perbedaan MRR dan Top-K dilaporkan secara deskriptif.

4.5.3. Kinerja Retrieval Frozen Embedding

Pada test set, konfigursi terbaik masing-masing model menghasilkan kinerja sebagai berikut

Model	Lapisan Terbaik	MAP	MRR	Top-1	Top-5	Top-10
Wav2vec2	7	0,0178	0,1146	0,0730	0,1496	0,1904
Data2vec	5	0,0188	0,1124	0,0699	0,1465	0,1935


Kedua Model menunjukkan kinerja retrieval yang rendah secara absolut (MAP di bawah 0,02 dan Top-1 di bawah 8%). Analisis per-query pada test set menegaskan pola ini, dari 2.232 query, tidak ada satu pun yang mencapai Average Precision sempurna, sekaligus tidak ada query yang bernilai nol, artinya setiap query berhasil menarik setidaknya satu klip relevan ke dalam peringkat. Namun, tidak ada yang diperingkatkan secara bersih di posisi teratas. Temuan ini mengindikasikan bahwa frozen embedding dari model SSL, dipadukan dengan scoring function cosine similarity, belum memadai sebagai basis retrieval ayat yang andal tanpa adaptasi lebih lanjut.

4.5.4. Lapisan paling informatif

Lapisan terbaik terletak di pertengahan jaringan wav2vec2, lebih tepatnya pada lapisan 7 dan Data2vec pada lapisan 5, lapisan terbaik pada kedua model untuk tugas retrieval ternyata bukan pada lapisan terakhir. Kinerja menaik dari lapisan awal, memuncak di pertengahan, lalu menurun pada lapisan akhir (Wav2vec2 L12 MAP=0,0054, Data2vec L12=0,0062).

Pola *inverted-U* ini konsisten dengan literatur analisis layer-wise pada model SSL audio [27], yang menunjukkan bahwa lapisan akhir cenderung terspesialisasi bagi tujuan pretraining dan kehilangan Sebagian informasi fonetik yang justru berguna bagi tugas retrieval. Temuan ini menvalidasi keputusan

metodologis menyapu seluruh 13 lapisan alih-alih mengasumsikan lapisan akhir sebagai representasi terbaik.



Gambar 4. 1 Hasil Evaluasi Tiap-tiap Layer

4.6. Deployment (Pertimbangan Penerapan)

Fase Deployment pada penelitian ini tidak berupa penerapan sistem pada lingkungan produksi. Melainkan pertimbangan penerapan dari temuan yang diperoleh, mengingat penelitian yang dilakukan adalah komparatif dan menghasilkan prototype. Bukan siap pakai.

4.6.1. Skema Penerapan Sistem Retrieval

Secara arsitektural, sistem retrieval berbasis frozen embedding dapat diterapkan melalui tiga tahap yang pertama yaitu proses ekstraksi untuk data ground truth pada database referensi menjadi vector embedding, kemudian mengekstraksi data audio query dari lapisan model Wav2vec2 dan Data2vec yang terbaik lalu dibandingkan dengan database referensi menggunakan scoring function cosine similarity, lalu proses terakhir dibuatkan perankingan hasil mana yang paling cocok dengan data yang ada di database referensi berdasarkan kemiripannya. Skema ini efisien karena ekstraksi referensi hanya perlu dilakukan sekali, sedangkan untuk proses pencarian cukup menghitung cosine similarity pada vektor yang sudah tersimpan.

4.6.2. Kelayakan penerapan berdasarkan temuan

Kelayakan penerapan sistem berbeda pada setiap skenario. Skenario B menghasilkan kinerja tertinggi, khususnya pada Wav2Vec2 lapisan ke-7 dengan Top-1 sebesar 50,85%, Top-5 sebesar 69,24%, dan Top-10 sebesar 74,78%. Hasil tersebut menunjukkan bahwa frozen Wav2Vec2 memiliki potensi untuk digunakan

sebagai komponen awal sistem *retrieval* ketika *query* dan basis data berasal dari domain audio yang serupa, meskipun pembacanya berbeda.

Kinerja pada Skenario A masih jauh lebih rendah. Pada skenario lintas domain mahasiswa ke Quran-MD, nilai Top-1 tertinggi adalah 5,38% yang diperoleh Wav2Vec2, sedangkan MAP tertinggi adalah 1,58% yang diperoleh Data2vec. Perbedaan tersebut menunjukkan adanya kesenjangan domain antara rekaman mahasiswa dan bacaan Quran-MD. Dengan demikian, keberhasilan pada skenario Quran-MD ke Quran-MD tidak dapat langsung dianggap sebagai bukti kesiapan sistem untuk pencarian bacaan mahasiswa terhadap basis data qori profesional.

Skenario C menempati posisi antara Skenario A dan B. Nilai Top-1 sekitar 20% dan Top-10 sekitar 42% menunjukkan bahwa pencarian antarbacaan mahasiswa lebih memungkinkan dibandingkan pencarian lintas domain, tetapi belum cukup untuk digunakan sebagai satu-satunya dasar keputusan pada aplikasi berisiko tinggi.

Frozen embedding tetap layak digunakan sebagai *baseline*, alat analisis representasi, atau komponen penghasil kandidat awal. Untuk penerapan yang menuntut ketepatan tinggi, hasil pemeringkatan perlu dilanjutkan dengan tahap verifikasi tambahan. Pengembangan selanjutnya dapat mencakup *fine-tuning* terkontrol, pembelajaran metrik, adaptasi domain, normalisasi karakteristik pembaca, serta penggunaan metode agregasi temporal yang lebih kaya daripada *mean pooling*.

Berdasarkan hasil tersebut, model yang direkomendasikan bergantung pada tujuan sistem. Wav2Vec2 lapisan ke-7 lebih sesuai apabila prioritas utama adalah menemukan dokumen relevan pertama pada peringkat atas, terutama pada domain Quran-MD. Data2vec lapisan ke-5 lebih sesuai apabila prioritas evaluasi adalah MAP pada skenario lintas domain atau lintas mahasiswa. Keputusan penerapan karena itu harus mempertimbangkan domain data, metrik utama, dan tingkat risiko penggunaan sistem.

BAB V KESIMPULAN DAN SARAN

5.1. Kesimpulan

Penelitian ini berhasil mengimplementasikan Wav2vec2 dan Data2vec sebagai model penghasil representasi laten dalam keadaan frozen dalam tugas retrieval audio ayat Al-Qur'an tanpa menggunakan transkripsi. Implementasi dilakukan melalui normalisasi audio, segmentasi rekaman menjadi unit per ayat, ekstraksi embedding per layer, pembetulan vektor per ayat menggunakan *mean pooling*, dan pemeringkatan berdasarkan hasil dari *cosine similarity* yang bertugas sebagai *scoring function*. Pemilihan lapisan terbaik dilakukan menggunakan *development set*, sedangkan kinerja atau performa pada *test set* dievaluasi menggunakan MAP, MRR, dan Top-K. Relasi relevansi ditentukan berdasarkan kesamaan identitas surah dan ayat antara query dan kandidat dalam database referensi, tanpa bergantung pada pembaca ayat Al-Qur'annya. Rangkaian tersebut menunjukkan bahwa kedua model dapat diimplementasikan dalam sistem retrieval ayat berbasis audio dengan menggunakan representasi akustik secara langsung.

Hasil perbandingan menunjukkan bahwa tidak terdapat satu model yang secara konsisten menghasilkan kinerja tertinggi pada seluruh skenario dan seluruh metrik evaluasi. Data2vec menghasilkan MAP yang lebih tinggi ketika rekaman mahasiswa digunakan sebagai query, baik terhadap dataset Quran-MD maupun terhadap rekaman mahasiswa dari pembaca yang berbeda. Sebaliknya, Wav2vec2 menghasilkan MAP yang lebih tinggi ketika *query* dan *database* referensi sama-sama berasal dari Quran-MD dengan pembagian qori yang saling lepas. Pada skenario tersebut, Wav2vec2 juga menghasilkan nilai tertinggi pada metrik evaluasi lainnya.

Arah perbandingan MRR dan Top-K tidak selalu sama dengan arah perbandingan MAP. Pada skenario lintas sumber data, Wav2vec2 menghasilkan MRR dan Top-K yang lebih tinggi meskipun MAP Data2vec lebih tinggi. Pada skenario antar mahasiswa, kedua model juga menunjukkan hasil yang berdekatan dan berbeda menurut metrik yang digunakan. Oleh karena itu, perbandingan Wav2vec2 dan Data2vec tidak cukup disimpulkan berdasarkan satu metrik saja,

tetapi perlu dinilai sesuai dengan scenario evaluasi dan aspek pemeringkatan yang diukur.

Hasil evaluasi per layer juga menunjukkan bahwa representasi yang paling informatif untuk retrieval ayat tidak berasal dari lapisan terakhir masing-masing model, melainkan dari lapisan menengah. Hal ini menegaskan pentingnya melakukan pemilihan lapisan pada *dev set* sebelum melaporkan kinerja yang di uji pada *test set*. Di antara ketiga kondisi evaluasi, retrieval lintas sumber data antara rekaman mahasiswa dan Quran-MD menjadi kondisi yang paling sulit. Dengan demikian, meskipun sistem retrieval berbasis frozen embedding berhasil diimplementasikan dan menghasilkan peringkat yang lebih baik daripada peringkat acak, kinerjanya belum memadai untuk penerapan operasional tanpa pengembangan lebih lanjut.

5.2. Saran

Penelitian selanjutnya disarankan memusatkan pengembangan pada adaptasi model terhadap domain bacaan Al-Qur'an. Wav2vec2 dan Data2vec dapat diuji setelah melalui fine-tuning pada korpus audio Al-Qur'an dan dikombinasikan dengan *metric learning*. Pengembangan ini merupakan tahap lanjutan dari penggunaan frozen embedding karena model tidak hanya mengekstraksi representasi bawaan, tetapi juga mempelajari kedekatan antara bacaan dari ayat yang sama dan perbedaan antara bacaan dari ayat yang berlainan.

Cakupan korpus juga perlu diperluas dengan melibatkan seluruh surah Al-Qur'an dan pembaca yang lebih beragam. Variasi tersebut dapat mencakup asal daerah, kemampuan membaca, perangkat perekaman, dan kondisi lingkungan yang berbeda. Perluasan korpus diperlukan untuk menguji kemampuan generalisasi model sekaligus memastikan bahwa hasil perbandingan tidak hanya berlaku pada cakupan surah dan karakteristik pembaca dalam penelitian ini.

Selain adaptasi model dan perluasan korpus, penelitian berikutnya dapat mengembangkan pembentukan representasi per ayat dengan membandingkan *mean pooling* terhadap metode agregasi lain, termasuk penggabungan representasi dari beberapa lapisan. Pengembangan tersebut sebaiknya dilengkapi dengan analisis kesalahan secara kualitatif terhadap *query* yang memperoleh peringkat rendah atau

tertukar dengan ayat lain. Analisis ini dapat membantu mengidentifikasi apakah kegagalan retrieval terutama berkaitan dengan kualitas segmentasi, variasi pembaca, kondisi audio, atau kemiripan fontetik antar ayat, sehingga perbaikan sistem dapat dilakukan secara lebih terarah.

DAFTAR PUSTAKA

- [1] A. Baevski, H. Zhou, A. Mohamed, and M. Auli, “wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations,” Oct. 22, 2020, *arXiv*: arXiv:2006.11477. doi: 10.48550/arXiv.2006.11477.
- [2] P. C. English, J. D. Kelleher, and J. Carson-Berndsen, “Searching for Structure: Appraising the Organisation of Speech Features in wav2vec 2.0 Embeddings,” in *Interspeech 2024*, ISCA, Sep. 2024, pp. 4613–4617. doi: 10.21437/Interspeech.2024-2047.
- [3] W. Öberg, “Query-by-Example Audio Search using Acoustic Word Embeddings: Transforming wav2vec 2.0 Embeddings using Contrastive Learning,” 2025.
- [4] M. Shanbhogue *et al.*, “Gemini Embedding 2: A Native Multimodal Embedding Model from Gemini,” May 26, 2026, *arXiv*: arXiv:2605.27295. doi: 10.48550/arXiv.2605.27295.
- [5] Y. Chen *et al.*, “WavRAG: Audio-Integrated Retrieval Augmented Generation for Spoken Dialogue Models,” Feb. 20, 2025, *arXiv*: arXiv:2502.14727. doi: 10.48550/arXiv.2502.14727.
- [6] H. Toyin, A. Djanibekov, A. Kulkarni, and H. Aldarmaki, “ArTST: Arabic Text and Speech Transformer,” in *Proceedings of ArabicNLP 2023*, Singapore (Hybrid): Association for Computational Linguistics, 2023, pp. 41–51. doi: 10.18653/v1/2023.arabnlp-1.5.
- [7] S. S. Li, B. Xu, X. Zhang, H. Liu, W. Chao, and L. P. Garcia, “A Quantitative Approach to Understand Self-Supervised Models as Cross-lingual Feature Extractors,” 2023.
- [8] A. Baevski, W.-N. Hsu, Q. Xu, A. Babu, J. Gu, and M. Auli, “data2vec: A General Framework for Self-supervised Learning in Speech, Vision and Language,” Oct. 25, 2022, *arXiv*: arXiv:2202.03555. doi: 10.48550/arXiv.2202.03555.
- [9] H. Xue, Q. Shao, P. Chen, P. Guo, L. Xie, and J. Liu, “TranUSR: Phoneme-to-word Transcoder Based Unified Speech Representation Learning for Cross-lingual Speech Recognition,” in *INTERSPEECH 2023*, Aug. 2023, pp. 216–220. doi: 10.21437/Interspeech.2023-746.
- [10] L. Alkanhal, A. Alessa, E. Almahmoud, and R. Alaqil, “Aswat: Arabic Audio Dataset for Automatic Speech Recognition Using Speech-Representation Learning,” in *Proceedings of ArabicNLP 2023*, Singapore (Hybrid): Association for Computational Linguistics, 2023, pp. 120–127. doi: 10.18653/v1/2023.arabnlp-1.10.
- [11] N. San *et al.*, “Leveraging pre-trained representations to improve access to untranscribed speech from endangered languages,” Sep. 14, 2021, *arXiv*: arXiv:2103.14583. doi: 10.48550/arXiv.2103.14583.
- [12] Z. Li, L. Wu, T. Li, and Y. Yan, “Improves Neural Acoustic Word Embeddings Query by Example Spoken Term Detection with Wav2vec Pretraining and Circle Loss,” in *2021 12th International Symposium on Chinese Spoken Language Processing (ISCSLP)*, Hong Kong: IEEE, Jan. 2021, pp. 1–5. doi: 10.1109/ISCSLP49672.2021.9362065.

- [13] Y. Xie, Z. Zhang, and Y. Yang, “Siamese Network with wav2vec Feature for Spoofing Speech Detection,” in *Interspeech 2021*, ISCA, Aug. 2021, pp. 4269–4273. doi: 10.21437/Interspeech.2021-847.
- [14] C. Tang, Y. Wang, X. Chen, and W.-Q. Zhang, “Exploring Effective Fusion Algorithms for Speech Based Self-Supervised Learning Models,” Dec. 20, 2022, *arXiv*: arXiv:2212.10092. doi: 10.48550/arXiv.2212.10092.
- [15] J. W. Yoon, S. M. Kim, and N. S. Kim, “MCR-Data2vec 2.0: Improving Self-supervised Speech Pre-training via Model-level Consistency Regularization,” Jun. 14, 2023, *arXiv*: arXiv:2306.08463. doi: 10.48550/arXiv.2306.08463.
- [16] S. Yang *et al.*, “A Large-Scale Evaluation of Speech Foundation Models,” May 29, 2024, *arXiv*: arXiv:2404.09385. doi: 10.48550/arXiv.2404.09385.
- [17] S. J. Russell, S. Russell, and P. Norvig, *Artificial Intelligence: A Modern Approach*. in Pearson series in artificial intelligence. Pearson, 2020. [Online]. Available: <https://books.google.co.id/books?id=koFptAEACAAJ>
- [18] T. M. Mitchell, *Machine learning*, Nachdr. in McGraw-Hill series in Computer Science. New York: McGraw-Hill, 2013.
- [19] I. Goodfellow, Y. Bengio, and A. Courville, *Deep learning*. in Adaptive computation and machine learning. Cambridge, Mass: The MIT press, 2016.
- [20] A. Vaswani *et al.*, “Attention Is All You Need,” Aug. 02, 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.
- [21] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*, 1st ed. Cambridge University Press, 2008. doi: 10.1017/CBO9780511809071.
- [22] T. Wang and P. Isola, “Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere,” Aug. 15, 2022, *arXiv*: arXiv:2005.10242. doi: 10.48550/arXiv.2005.10242.
- [23] D. Ulyanov, A. Vedaldi, and V. Lempitsky, “Instance Normalization: The Missing Ingredient for Fast Stylization,” Nov. 06, 2017, *arXiv*: arXiv:1607.08022. doi: 10.48550/arXiv.1607.08022.
- [24] J. L. Ba, J. R. Kiros, and G. E. Hinton, “Layer Normalization,” Jul. 21, 2016, *arXiv*: arXiv:1607.06450. doi: 10.48550/arXiv.1607.06450.
- [25] E. Schubert, “A Triangle Inequality for Cosine Similarity,” vol. 13058, 2021, pp. 32–44. doi: 10.1007/978-3-030-89657-7_3.
- [26] C. Schröer, F. Kruse, and J. M. Gómez, “A Systematic Literature Review on Applying CRISP-DM Process Model,” *Procedia Comput. Sci.*, vol. 181, pp. 526–534, 2021, doi: 10.1016/j.procs.2021.01.199.
- [27] A. Pasad, B. Shi, and K. Livescu, “Comparative Layer-Wise Analysis of Self-Supervised Speech Models,” in *ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Rhodes Island, Greece: IEEE, Jun. 2023, pp. 1–5. doi: 10.1109/ICASSP49357.2023.10096149.
- [28] M. U. Salman, M. A. Qazi, and M. T. Alam, “Quran-MD: A Fine-Grained Multilingual Multimodal Dataset of the Quran,” Jan. 25, 2026, *arXiv*: arXiv:2601.17880. doi: 10.48550/arXiv.2601.17880.
- [29] X. Chang *et al.*, “An Exploration of Self-Supervised Pretrained Representations for End-to-End Speech Recognition,” Oct. 09, 2021, *arXiv*: arXiv:2110.04590. doi: 10.48550/arXiv.2110.04590.

- [30] S. Zaiem, Y. Kemiche, T. Parcollet, S. Essid, and M. Ravanelli, “Speech Self-Supervised Representations Benchmarking: a Case for Larger Probing Heads,” Feb. 21, 2024, *arXiv*: arXiv:2308.14456. doi: 10.48550/arXiv.2308.14456.