

**PERBANDINGAN WAV2VEC2 DAN DATA2VEC TERHADAP FITUR
LATEN AUDIO UNTUK TILAWAH
AL-QURAN**

TUGAS AKHIR

Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Teknik
pada jurusan Teknik Informatika Fakultas Sains dan Teknologi
Universitas Islam Negeri Sunan Gunung Djati Bandung

Oleh

MUJAHID ANSORI MAJID

1197050093



**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI SUNAN GUNUNG DJATI
BANDUNG
2026**

DAFTAR ISI

DAFTAR ISI	i
DAFTAR GAMBAR	iii
DAFTAR TABEL	iv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Kerangka Pemikiran	6
1.7 Sistematika Penulisan	8
BAB II KAJIAN LITERATUR	11
2.1 <i>The State of The Art</i>	11
2.2 Studi Literatur	19
BAB III METODOLOGI PENELITIAN	31
3.1. Business Understanding	31
3.2. Data Understanding	32
BAB IV	43
HASIL DAN PEMBAHASAN	43
4.1. Hasil Business Understanding	43
4.1.1. Identifikasi Masalah	43
4.1.2. Tujuan Penelitian	44
4.1.3. Hipotesis dan kriteria keberhasilan	44
4.2. Hasil Data Understanding	45
4.2.1. Karakteristik Himpunan data Mahasiswa	46
4.2.2. Karakteristik Himpunan Data Quran-MD	47
4.2.3. Cakupan relevansi dan Ukuran Skenario	47
4.2.4. Kualitas Data	48
4.3. Hasil Data Preparation	48
4.3.1. Normalisasi Audio	48
4.3.2. Pembagian set <i>dev</i> dan set <i>test</i>	51
4.4. Modeling	51

4.4.1.	Ekstraksi Frozen Embedding per-lapisan	52
4.4.2.	Data Cleaning.....	52
4.4.3.	<i>Similarity Scoring</i> dan <i>Ranking</i>	53
4.5.	Evaluation	53
4.5.1.	Rumusan Masalah 1 – Kinerja Retrieval Frozen Embedding	54
4.5.2.	Rumusan Masalah 2 – Perbandingan Wav2vec2 dan Data2vec	54
4.5.3.	Rumusan Masalah 3 – Lapisan paling informatif	55
4.6.	Deployment (Pertimbangan Penerapan).....	56
4.6.1.	Skema Penerapan Sistem Retrieval	56
4.6.2.	Kelayakan penerapan berdasarkan temuan.....	56
DAFTAR PUSTAKA		57

DAFTAR GAMBAR

<i>Gambar 1 Kerangka Penelitian.....</i>	<i>6</i>
<i>Gambar 2 Arsitektur Wav2vec2 2.0.....</i>	<i>24</i>
<i>Gambar 3 Arsitektur Data2vec</i>	<i>26</i>
<i>Gambar 4 Gambar Summary statistic dataset Quran-MD.....</i>	<i>33</i>
<i>Gambar 5 Karakteristik Audio.....</i>	<i>34</i>
<i>Gambar 6 Total Videos Distribution histogram.....</i>	<i>35</i>
<i>Gambar 7 Box Plot Showing Outlier</i>	<i>36</i>

DAFTAR TABEL

<i>s</i> Tabel 1 State of the art.....	11
Table 2 Konfigurasi Blok Konvolusi Temporal pada Encoder Audio	22
Table 3 Summary Statistic Dataset Query	35
Table 4 Atribut dan Tipe Data Quran-MD	46
Table 5 Ukuran Data dan Cakupan Relevansi pada Setiap Skenario Evaluasi.....	47

BAB I PENDAHULUAN

1.1 Latar Belakang

Perkembangan *deep learning* dalam pemrosesan audio telah didominasi oleh model Self-Supervised Learning (SSL), dengan Wav2vec2 menjadi arsitektur pionir yang sangat berpengaruh. Model-model ini mampu mempelajari representasi audio mendalam (*latent embeddings*) dari data audio mentah tanpa memerlukan label transkripsi, dan telah menunjukkan efektivitas tinggi pada berbagai tugas pemrosesan suara [1], [2]. Kemampuan model-model ini dalam menghasilkan fitur laten menjadi fondasi bagi tugas-tugas non-transkripsi, termasuk penelusuran kemiripan audio, yang mencocokkan potongan bacaan dengan entri yang paling mirip di *database* berdasarkan kemiripan *vector embedding*, bukan mencocokkan melalui teks hasil enkripsi [3]. Pendekatan ini telah didukung oleh temuan empiris yang menunjukkan bahwa sistem retrieval berbasis latent embedding yang dihasilkan langsung dari audio secara konsisten mengungguli pendekatan dua tahap dari ASR ke retrieval, karena kesalahan transkripsi pada tahap ASR akan berpropagasi dan mendegradasi kualitas pencocokan pada tahap selanjutnya [4], [5]. Karakteristik inilah yang menjadikan pendekatan berbasis embedding lebih sesuai untuk konteks pencocokan bacaan Quran, yang menuntut presisi tinggi pada aspek fonetik dan tajwid.

Al-Qur'an berisi teks berbahasa Arab dengan kaidah pelafalan (tajwid) yang ketat dan presisi tinggi, tidak hanya memiliki signifikansi religius bagi umat Muslim, tetapi juga merupakan *testbed* fonetik yang menantang secara teknis untuk sistem pemrosesan suara.

Persoalan mendasar muncul ketika model SSL yang di-*pretrain* pada data yang berbahasa Inggris diterapkan pada fonetik Arab, yang memiliki karakteristik berbeda seperti contohnya *emphatic consonants* dan *pharyngeal sounds* yang tidak dimiliki oleh bahasa Inggris [6]. Dalam eksperimen yang dilakukan oleh Toyin model berbasis *Arab-monolingual* mampu mengungguli model multibahasa yang memiliki ukuran dua kali lipat dalam tugas pengenalan ucapan Arab[6]. Temuan ini diperkuat oleh Li et al yang secara kuantitatif menunjukkan bahwa encoder SSL yang dilatih menggunakan teks berbahasa Inggris menghasilkan fitur fonetik yang kurang

Commented [MM1]: [1] ("Wav2Vec2 sebagai arsitektur pionir SSL") wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," Oct. 22, 2020
[2] ("efektivitas tinggi pada berbagai tugas pemrosesan suara") Searching for Structure: Appraising the Organisation of Speech Features in wav2vec 2.0 Embeddings

Commented [MM2]: [3] Öberg (2025), query by example Pernyataan "Kemampuan menghasilkan fitur laten inilah yang menjadi fondasi bagi tugas-tugas non-transkripsi" di dukung oleh papernya pada bagian introduction

"One advantage of large pre-trained acoustic models is their ability to be fine-tuned for various downstream tasks. Some common tasks include: transcription, speech synthesis and cloning, query-by-example (QbE) spoken term detection, voice activity detection, speaker diarization, and named entity recognition. What all these downstream tasks have in common is that they are enabled by the latent speech features that these large models have learned to represent human speech.

Commented [MM3]: Propagasi = menyebar

Commented [MM4]: [4] Gemini embedding 2: a native multimodal embedding

Pada halaman result membuktikan bahwa asr hanya 70% sedangkan native audio mendapatkan hasil 73%

[5] wavrag, pada abstractnya menyatakan "existing RAG frameworks are primarily designed for text-based LLMs and rely on Automatic Speech Recognition to process speech input, which discards crucial audio information, risks transcription errors, and increases computational overhead."

Commented [MM5]: Testbed adalah lingkungan pengujian (testing environment) yang dibuat khusus untuk mencoba, mengevaluasi, atau memvalidasi suatu sistem, metode, algoritma, atau perangkat sebelum digunakan pada kondisi nyata.

Commented [MM6]: Emphatic consonants adalah konsonan yang diucapkan dengan bagian belakang lidah terangkat ke arah langit-langit lunak (velum) atau dengan penyempitan di daerah faring (secondary articulation). Hal ini membuat bunyinya terdengar lebih "tebal", "gelap", atau "berat" (ص, ض, ط, ظ)

Pharyngeal sounds adalah bunyi yang dihasilkan dengan menyempitkan saluran udara di faring (pharynx), yaitu bagian tenggorokan yang berada di belakang rongga mulut. (ح, ع)

informatif ketika diterapkan pada inputan lintas-bahasa tanpa adaptasi domain [7]. Namun demikian, bukti-bukti tersebut terbatas pada arsitektur berbasis *contrastive learning* seperti Wav2Vec2. Sementara itu, Data2Vec menggunakan paradigma *self-distillation* yang secara fundamental berbeda. alih-alih membandingkan representasi positif versus negatif, Data2Vec melatih jaringan *student* untuk memprediksi representasi kontekstual penuh yang dihasilkan oleh jaringan *teacher* atas seluruh masukan [1], [8]. Perbedaan ini secara teoretis berpotensi menghasilkan representasi fonetik yang lebih umum untuk lintas bahasa, karena target prediksi berupa konteks laten yang kaya bukan unit diskrit yang terikat pada distribusi fonetik bahasa *pretraining*. Dugaan ini didukung oleh temuan Xue et al. yang menunjukkan bahwa penggantian target diskrit dengan target kontinu ala Data2Vec menurunkan *phoneme error rate* lintas bahasa sebesar 5,3% [9].

Commented [MM7]: Contrastive learning adalah teknik dalam *machine learning* yang melatih model untuk mempelajari representasi (embedding) dengan cara mendekatkan data yang mirip dan menjauhkan data yang berbeda.

Commented [MM8]: Self-distillation adalah teknik dalam *deep learning* di mana sebuah model belajar dari dirinya sendiri, bukan dari model lain yang lebih besar.

Commented [MM9]: Fonem adalah satuan bunyi terkecil dalam suatu bahasa yang dapat membedakan makna

Temuan-temuan di atas menuntun pada satu celah riset yang belum terjawab: seluruh bukti kegagalan lintas-bahasa yang tersedia hanya terbatas pada arsitektur *contrastive learning*, sementara kajian terhadap paradigma *self-distillation* yang dimiliki Data2Vec dalam skenario serupa masih sangat terbatas. Lebih jauh lagi, perbandingan langsung antara Wav2Vec2 dan Data2Vec untuk tugas audio retrieval—yang dievaluasi melalui metrik similarity search seperti Top-K Accuracy, Mean Reciprocal Rank (MRR), dan Mean Average Precision (MAP), bukan metrik transkripsi (WER/CER)—hingga kini masih minim di literatur. Ketiadaan perbandingan ini menyisakan pertanyaan fundamental: apakah perbedaan paradigma *pretraining* antara kedua model menghasilkan kualitas representasi fonetik yang berbeda pula untuk tugas retrieval ayat Al-Qur'an.

Namun, potensi keunggulan *self-distillation* tersebut tidak dapat diasumsikan berlaku pada tugas *retrieval*, sebab *retrieval* dan transkripsi mengukur properti representasi yang berbeda. Pada ASR, fitur diteruskan ke kepala klasifikasi yang ikut dilatih secara *supervised*. Akibatnya, metrik seperti WER tidak murni mengukur kualitas embedding awal, melainkan separabilitas fitur setelah disesuaikan oleh proses pelatihan tersebut. Sebaliknya, pada retrieval berbasis *frozen embedding* tidak ada komponen yang dilatih, sehingga metrik seperti MAP secara *intrinsic* mengukur koherensi geometris ruang vector itu sendiri, tanpa bantuan optimasi tambahan.

Perbedaan ini memunculkan dua hipotesis yang saling bersaing. Hipotesis pertama (H1) memperkirakan Data2Vec tetap unggul: target prediksinya yang berupa representasi kontekstual laten penuh berpotensi menghasilkan fitur fonetik yang lebih kaya dan umum, sehingga keunggulannya diperkirakan bertahan pada retrieval. Hipotesis kedua (H2) memperkirakan sebaliknya, bahwa Wav2Vec2 justru lebih unggul pada retrieval: *contrastive loss*-nya secara eksplisit menarik pasangan positif dan menolak kandidat negatif, sehingga cenderung membentuk ruang embedding yang lebih *clusterable* dan lebih selaras dengan pengukuran jarak cosine — properti yang justru menentukan pada retrieval, bukan pada ASR.

Pengujian empiris atas kedua hipotesis inilah yang menjadi inti kontribusi penelitian ini. Jika H1 terkonfirmasi, temuan ini memperkuat pandangan bahwa kualitas embedding bersifat lintas-tugas — unggul di satu tugas cenderung unggul pula di tugas lain. Jika H2 yang terkonfirmasi, retrieval justru terbukti mengukur dimensi kualitas representasi yang berbeda sama sekali dari ASR (ortogonal), bukan sekadar versi lain dari hal yang sama.

Oleh karena itu, penelitian ini diarahkan untuk melakukan perbandingan komprehensif antara Wav2Vec2 dan Data2Vec guna mengukur efektivitas fitur laten audio kedua model dalam tugas retrieval ayat Al-Qur'an. Melalui perbandingan ini, penelitian ini juga bertujuan menganalisis bagaimana perbedaan arsitektur SSL memengaruhi kualitas representasi fonetik yang dihasilkan. Hasil analisis ini diharapkan dapat memberikan rekomendasi arsitektur yang paling optimal sebagai landasan teknis bagi pengembangan sistem *audio retrieval* pada domain bahasa Arab khususnya yang memiliki karakteristik fonetik khas seperti *emphatic consonants* dan *pharyngeal sounds*.

1.2 Rumusan Masalah

Berdasarkan Rumusan masalah terbagi menjadi beberapa point

1. Bagaimana kinerja *retrieval frozen-embedding* Wav2vec2 diukur dengan MAP dan Top-K Accuracy?
2. Bagaimana kinerja *retrieval frozen-embedding* Data2vec pada metrik yang sama?
3. Apakah layer yang optimal untuk *retrieval fonetik* berbeda dari layer yang dilaporkan optimal untuk ASR, dan apa implikasinya terhadap pemilihan arsitektur?

1.3 Tujuan Penelitian

Tujuan dari penelitian ini sebagai berikut:

1. Mengevaluasi kinerja *retrieval* ayat Al-Qur'an berbasis audio menggunakan *frozen embedding* Wav2Vec2 (MAP, Top-K, cosine similarity).
2. Mengevaluasi kinerja *retrieval* ayat Al-Qur'an berbasis audio menggunakan *frozen embedding* Data2vec pada metrik yang sama.
3. Membandingkan kedua model dan menganalisis apakah performa *retrieval* sejalan dengan performa ASR bersifat konsisten atau sebaliknya, untuk menentukan model yang paling sesuai untuk sistem pencarian ayat Al-Qur'an berbasis suara.
4. Menganalisis distribusi kinerja *retrieval* pada tiap lapisan kedua model untuk mengidentifikasi lapisan optimal bagi tugas *retrieval fonetik*.

1.4 Batasan Masalah

Batasan masalah dari penelitian ini adalah sebagai berikut:

1. Penelitian dibatasi pada penggunaan model pretrained Data2Vec dan Wav2Vec2, tanpa pelatihan ulang (fine-tuning) pada data khusus Al-Qur'an
2. Eksperimen dilakukan pada teks Al-Qur'an, dengan objek penelitian berupa surah Al – Fatihah dan surah-surah dalam Juz Amma.
3. Pengujian input audio hanya dapat dilakukan perayat.

Commented [MM10]: H1 (selaras dengan temuan ASR): Data2vec menghasilkan *retrieval* lebih baik daripada Wav2Vec2. Dasar teoretis: target prediksi Data2vec berupa representasi kontekstual laten penuh (rata-rata lapisan atas jaringan teacher) berpotensi menghasilkan representasi fonetik yang lebih kaya dan lebih umum, sehingga keunggulannya pada ASR Arab (Alkanhal dkk., 2023) diperkirakan bertahan pada *retrieval*.

H2 (*retrieval* mengekspos kekuatan berbeda): Wav2Vec2 menghasilkan *retrieval* lebih baik meskipun kalah pada ASR. Dasar teoretis: contrastive loss Wav2Vec2 secara eksplisit mendorong keterpisahan antar-segmen (menarik positif, menolak negatif), sehingga ruang embedding-nya cenderung lebih clusterable dan lebih cocok untuk pengukuran jarak cosine — properti yang justru menentukan pada *retrieval*, bukan pada ASR.


1.5 Manfaat Penelitian

Manfaat yang diharapkan dari hasil penelitian ini adalah sebagai berikut:

1. Memberikan pemahaman ilmiah yang lebih dalam tentang efektivitas model representasi audio seperti Data2Vec dan Wav2Vec2 dalam domain bahasa Arab, khususnya untuk tugas pencocokan kemiripan teks berbasis suara.
2. Memberikan acuan bagi peneliti dan pengembang aplikasi keislaman dalam memilih model *embedding* audio terbaik untuk diterapkan pada sistem pembelajaran Al-Qur'an berbasis suara

1.6 Kerangka Pemikiran

Berdasarkan uraian tersebut kerangka pemikiran dapat diuraikan sebagai berikut



Gambar 1 Kerangka Penelitian

Penelitian ini berangkat dari sebuah fenomena dalam bidang pemrosesan audio, yaitu kemampuan model *Self-Supervised Learning* (SSL) seperti Wav2vec2 dan Data2vec dalam menghasilkan representasi laten, langsung dari audio mentah tanpa memerlukan label transkripsi. Kemampuan ini membuka peluang bagi tugas penelusuran kemiripan audio (*audio retrieval*). Di mana sistem *retrieval* yang bekerja langsung pada *latent embedding* dapat mengungguli pendekatan dua tahap berbasis ASR. Keunggulan ini bersumber dari kemampuannya menghindari kesalahan propagasi (*error propagation*), yakni kesalahan transkripsi pada tahap ASR yang akan merambat dan mendegradasi kualitas pencocokan pada tahap selanjutnya.

Fenomena tersebut ditopang oleh sejumlah landasan teori dan studi literatur. Pada tataran mekanisme model, Wav2vec2 mempelajari representasi melalui *contrastive learning* yang membedakan sampel positif dan negatif menggunakan *quantized discrete units*. Sementara Data2vec mengadopsi paradigma *self-distillation* yang melatih jaringan student untuk memprediksi representasi kontekstual penuh dari jaringan *teacher* dengan target berupa konteks latent yang kontinu. Perbedaan paradigma inilah yang menjadi dasar perbandingan dalam penelitian ini. Pada tataran tugas *retrieval*, penelitian Öberg menunjukkan bahwa pencarian audio dapat dilakukan langsung dari audio tanpa tahap enkripsi [3]. Teori ini didukung pula oleh bukti empiris *Gemini embedding 2*, secara eksplisit menunjukkan bahwa pendekatan *cascaded ASR* ke *retrieval* mengalami *error propagation* [4]. Sedangkan WavRag membuktikan bahwa *retrieval* langsung dari audio mampu menyamai akurasi pipeline ASR dengan efisiensi yang jauh lebih tinggi [5].

Meskipun demikian, keunggulan tersebut belum tentu berlaku ketika model diterapkan pada domain fonetik yang spesifik seperti bahasa Arab dalam bacaan Al-Qur'an. Persoalan muncul karena model SSL umumnya di-*pretrain* pada korpus Bahasa Inggris dan kurang informatif untuk fonetik Arab. Penelitian Toyin et al dan Li et al telah menunjukkan keterbatasan ini [6], [7]. Namun bukti tersebut hanya terbatas pada arsitektur berbasis *contrastive learning* seperti Wav2vec2. Sementara itu, potensi paradigma *self-distillation* yang dimiliki Data2Vec untuk tugas audio *retrieval* Al-Quran masih sangat minim dikaji, dan perbandingan langsung antara kedua model menggunakan metrik *similarity search*, bukan metrik transkripsi seperti *word error rate* (WER) hingga kini masih terbatas dalam literatur.

Commented [MM11]: Representasi latent adalah fitur tersebut dari sebuah file (gambar, audio, atau binary file lainnya)

Untuk menjawab persoalan tersebut, penelitian ini menawarkan solusi berupa perbandingan komprehensif antara Wav2Vec2 dan Data2Vec dalam menghasilkan representasi laten untuk tugas retrieval ayat Al-Qur'an. Fitur laten dari kedua model pretrained diekstraksi dalam kondisi beku (frozen), kemudian dievaluasi secara objektif menggunakan metrik similarity search seperti Top-K Accuracy, Mean Reciprocal Rank (MRR), dan Mean Average Precision (MAP). Pendekatan ini bertujuan mengukur secara langsung pengaruh perbedaan arsitektur SSL terhadap kualitas representasi fonetik Arab.

Proses penelitian dilaksanakan mengikuti kerangka kerja Cross-Industry Standard Process for Data Mining (CRISP-DM) yang diadaptasi ke dalam enam tahap, yaitu pengumpulan data, pre-processing data, ekstraksi representasi laten (vector embedding), implementasi similarity search, evaluasi kinerja, serta analisis hasil dan penarikan kesimpulan. Melalui tahapan yang sistematis ini, penelitian diharapkan menghasilkan perbandingan kuantitatif kinerja retrieval antara Wav2Vec2 dan Data2Vec, sekaligus memberikan analisis mengenai pengaruh paradigma pretraining terhadap kualitas representasi fonetik. Hasil akhir penelitian ini berupa rekomendasi arsitektur SSL yang paling optimal sebagai landasan teknis bagi pengembangan sistem audio retrieval pada domain berbahasa Arab.

1.7 Sistematika Penulisan

Sistematika penulisan laporan tugas akhir ini disusun ke dalam lima bab yang saling berkait secara berurutan, dengan gambaran kandungan setiap bab sebagai berikut.

BAB I: PENDAHULUAN

Bab ini menguraikan dasar pemikiran yang melatarbelakangi dilakukannya penelitian, mencakup latar belakang yang memaparkan fenomena dan celah penelitian, rumusan masalah sebagai pertanyaan penelitian yang hendak dijawab, batasan masalah yang menetapkan ruang lingkup penelitian, manfaat penelitian, state of the art, kerangka pemikiran, serta sistematika penulisan. Bab ini berfungsi sebagai fondasi mengarahkan keseluruhan penelitian.

BAB II: TINJAUAN PUSTAKA

Bab ini memaparkan landasan teori dan konsep-konsep fundamental yang menjadi dasar ilmiah penelitian, meliputi teori mengenai Self-Supervised Learning (SSL), arsitektur dan mekanisme kerja model Wav2vec2 dan Data2Vec, konsep representasi latent (*latent embedding*), tugas audio retrieval, serta metrik evaluasi similarity search. Berbeda dengan Bab I yang menyoroti mengapa penelitian mesti dilakukan, bab ini menyediakan kerangka teoritis apa saja konsep yang digunakan untuk memahami dan menyelesaikan permasalahan.

BAB III: METODOLOGI PENELITIAN

Bab ini menjelaskan tahapan prosedur pelaksanaan penelitian secara sistematis mengikuti kerangka kerja *Cross-Industry Standard Process for Data Mining* (CRISP-DM) yang diadaptasi, mencakup pengumpulan data, pre-processing, ekstraksi representasi laten, implementasi similarity search, hingga skenario evaluasi. Jika Bab II menjelaskan apa landasan teorinya, bab ini menguraikan bagaimana teori tersebut diterapkan secara teknis dan operasional dalam penelitian.

BAB IV: HASIL DAN PENELITIAN

Bab ini menyajikan hasil yang diperoleh dari pelaksanaan metodologi pada Bab III, berupa data kuantitatif kinerja *retrieval* kedua model berdasarkan metrik *Top-K Accuracy*, *Mean Reciprocal Rank* (MRR), dan *Mean Average Precision* (MAP), disertai analisis dan interpretasi mendalam terhadap perbandingan Wav2vec2 dan Data2vec. Bab ini merupakan inti temuan penelitian yang menghubungkan hasil eksperimen dengan pertanyaan penelitian pada Bab I.

BAB V: KESIMPULAN DAN SARAN

Bab ini memuat kesimpulan yang menjawab secara ringkas dan tegas rumusan masalah berdasarkan temuan pada Bab IV, disertai saran dan untuk pengembangan penelitian selanjutnya. Berbeda dengan Bab IV yang menyajikan analisis rinci, bab ini merangkum intisari penelitian secara menyeluruh dan menawarkan arah bagi penelitian di masa mendatang.

BAB II KAJIAN LITERATUR

2.1 *The State of The Art*

Analisis literatur terhadap artikel maupun jurnal terdahulu yang relevan dilakukan untuk memperdalam pemahaman mengenai permasalahan utama dalam penerapan *Self-Supervised Learning* (SSL) pada representasi ucapan (*speech representation*) serta pemanfaatannya untuk pencarian audio berbasis kemiripan (*audio similarity search*) dengan pendekatan *query-by-example*. Kajian ini sekaligus bertujuan untuk mengidentifikasi keterbatasan penelitian sebelumnya. Berikut rangkuman dari penelitian terdahulu dalam bentuk table.

Tabel 1 State of the art

No	Judul Jurnal dan Peneliti	Metode	Dataset	Hasil
1	wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations Peneliti: Alexei Baevski dkk (2020)	Wav2vec2, <i>contrastive masked prediction of quantized units</i>	LS-960 (960 jam), LV-60k (53200 jam), Fine-tune: Libri-light 10 min-960	Wav2Vec2 mempelajari representasi suara dari raw audio melalui pendekatan Self-Supervised Learning (SSL) berbasis contrastive learning. Dengan hanya melakukan fine-tuning menggunakan 10 menit data latih berlabel (setara 48 rekaman dengan durasi rata-rata 12.5

No	Judul Jurnal dan Peneliti	Metode	Dataset	Hasil
				detik), model ini mencapai Word Error Rate (WER) sebesar 4.8/8.2 pada test-clean/other dataset LibriSpeech. [1]
2	data2vec: A General Framework for Self-supervised Learning in Speech, Vision and Language Peneliti: Alexei Baevski dkk 2022	Data2vec, <i>self-distillation of contextual latent representations</i> , teacher-student EMA, target kontinu (rata-rata top-K layer, Smooth L1 loss	LibriSpeech 960h / Libri-light 60K jam; Vision: ImageNet-1K; NLP: BooksCorpus + Wikipedia (GLUE)	Mengembangkan framework SSL seragam lintas modalitas dengan memprediksi representasi laten kontekstual (bukan token diskrit); WER test-other 5,5 (960h), 86,6% ImageNet, 82,7 GLUE membuktikan target kontinu unggul di low-resource [8]
3.	Aswat: Arabic Audio Dataset For Automatic Speech Recognition Using Speech-Representation Learning	Wav2vec2 dan Data2vec	Aswat (732 jam audio Arab), evaluasi pada Common Voice (AR) dan MGB-2	Membandingkan efektivitas Wav2vec2 dan Data2vec pada pengenalan ucapan Arab. Hasilnya SOTA

No	Judul Jurnal dan Peneliti	Metode	Dataset	Hasil
	Peneliti: Lamya Alkanhal, dkk (2021)			WER 11,7% (Common Voice) & 10,3% (MGB-2); data2vec konsisten mengungguli wav2vec untuk Arab [10]
4.	Query-by-Example Audio Search using Acoustic Word Embeddings: Transforming wav2vec 2.0 Embeddings using Contrastive Learning Peneliti: Wilhelm Öberg (2025)	<i>Embedding Transformation</i> menggunakan <i>Projection Network</i> dengan Contrastive Learning (Triplet Loss) pada <i>Embedding</i> Wav2Vec 2.0.	Google FLEURS + Common Voice (word-segmented); evaluasi SWE-Hard & X-Hard	Penelitian ini menginvestigasi peningkatan kinerja Pencarian Audio <i>Query-by-Example</i> (QbE) melalui transformasi <i>embedding</i> Wav2Vec 2.0 menggunakan Contrastive Learning (khususnya <i>Triplet Loss</i>). Tujuannya adalah melatih jaringan proyeksi untuk menyelaraskan <i>embedding</i> kata yang serupa dan memfilter karakteristik

No	Judul Jurnal dan Peneliti	Metode	Dataset	Hasil
				<i>speaker</i> dan kebisingan, sehingga menghasilkan ruang <i>embedding</i> yang lebih terstruktur. Metode ini berkontribusi pada pencarian audio yang sepenuhnya bebas transkripsi dan sangat relevan untuk tugas <i>retrieval</i> berbasis kemiripan fitur laten. [3]
5.	LEVERAGING PRE-TRAINED REPRESENTATIONS TO IMPROVE ACCESS TO UNTRANSCRIBED SPEECH FROM ENDANGERED LANGUAGES Penulis: Nay San, dkk (2021)	Melakukan Query-by-Example Spoken Term Detection menggunakan representasi frozen dari wav2vec 2.0 (versi English-mono dan XLSR-53), tanpa transkripsi maupun fine-	Bahasa low-resource: Gronings, Besemah, dan dataset Mavir/Mboshi-line; pra-pelatihan English (LibriSpeech) & multibahasa (XLSR-53, 53 bahasa)	Menguji kemampuan retrieval lintas-bahasa menggunakan embedding SSL yang dibekukan (frozen), tanpa bergantung pada transkripsi, yang hasilnya Peningkatan relatif 56–86%

No	Judul Jurnal dan Peneliti	Metode	Dataset	Hasil
		tuning		atas SOTA; English-mono mengungguli XLSR multibahasa di 4 dataset [11]
6.	Improves Neural Acoustic Word Embeddings Query by Example Spoken Term Detection with Wav2vec Pretraining and Circle Loss Penulis: Zhaoqi Li, dkk (2021)	Menggabungkan Neural Acoustic Word Embeddings dengan pra-pelatihan wav2vec untuk QbE-STD, dilatih menggunakan cosine/triplet (circle) loss	Korpus QbE-STD	Membuktikan bahwa embedding SSL mengungguli fitur MFCC untuk retrieval berbasis kemiripan (similarity-based retrieval). Hasilnya AP +11,1% vs MFCC; sistem terbaik +19,7% atas baseline MFCC
7.	Siamese Network with Wav2vec Feature for Spoofing Speech Detection Peneliti: Yang Xie, dkk (2022)	Two-Phase Learning: 1. Siamese Network + Contrastive Loss pada fitur Wav2vec. 2. MLP Classifier pada <i>embedding</i> hasil Phase 1.	ASVspoof 2019 Logical Access (LA)	Mengusulkan sistem dua fase untuk mengatasi masalah generalisasi terhadap serangan <i>spoofing</i> ucapan (<i>out-of-distribution</i>)

No	Judul Jurnal dan Peneliti	Metode	Dataset	Hasil
				yang tidak dikenal. Sistem ini memanfaatkan fitur Wav2vec yang sudah dilatih (<i>pretrained</i>) sebagai fitur input diskriminatif. Pendekatan ini secara signifikan meningkatkan kinerja, mengurangi <i>Equal Error Rate</i> (EER) dari 4.07% (SOTA sebelumnya) menjadi 1.15% pada <i>benchmark</i> ASVspoof 2019.
8.	Exploring Effective Fusion Algorithms for Speech Based Self-Supervised Learning Models Peneliti: Tang C, dkk (2022)	Membandingkan dan menggabungkan HuBERT dan Data2vec pada task SUPERB SID (<i>speaker identification</i>) & ASR (<i>automatic</i>	SUPERB benchmark (task SID & ASR; basis LibriSpeech/VoxCeleb-line)	Membuktikan bahwa penggabungan model dalam domain SID (<i>speaker identification</i>) lebih buruk, sedangkan dalam

No	Judul Jurnal dan Peneliti	Metode	Dataset	Hasil
		<i>speech recognition</i>)		ASR menghasilkan hasil yang lebih baik [12]
9.	MCR-Data2vec 2.0: Improving Self-supervised Speech Pre-training via Model-level Consistency Regularization Penulis: Yoon, dkk (2023)	Data2Vec 2.0 Base dengan regularisasi konsistensi; fine-tuning hanya pada lapisan tugas, sedangkan model utama tidak dilakukan <i>fine-tune</i> .	LibriSpeech 960 jam, 11 SUPERB subtasks	Membuat novel model pretrained baru (MCR-Data2vec) hasilnya MCR meningkatkan performa pada SID, ASV, dan Speech Enhancement, namun sedikit menurunkan performa pada QbE. [13]
10.	A Large-Scale Evaluation of Speech Foundation Models Peneliti: Yang, dkk (2024)	Evaluasi Data2Vec Base dan Large pada 15 tugas downstream dengan embedding yang dibekukan (frozen embedding) dan lightweight prediction head.	LibriSpeech, QUESST (QbE), VoxCeleb (SID/ASV), LibriTTS (VC), etc.	Data2Vec mencapai performa terbaik pada Voice Conversion dan Phone Recognition, tetapi kurang optimal pada SID dan OOD-ASR dibanding HuBERT dan WavLM [14].

Penelitian mengenai representasi ucapan yang dilatih sendiri (*self-supervised*) telah mengalami kemajuan pesat, dimulai dengan fondasi seperti Wav2vec 2.0 dan Data2vec [1], [8] yang mampu mempelajari representasi laten koheren dari *raw audio*. Namun, mayoritas penelitian awal dan penelitian lanjutan berkonsentrasi pada peningkatan kinerja ASR (*automatic speech recognition*), termasuk studi lintas bahasa dan adaptasi domain. Sebagaimana penelitian lain berfokus pada non-retrieval yang tetap memanfaatkan kualitas embedding SSL, seperti deteksi *spoofing* suara dan identifikasi suarat yang menggabungkan *Siamase Network* pada fitur Wav2vec2 [15]. Meskipun demikian, Sebagian studi mulai menggeser fokus ke kapabilitas *retrieval* dari *embedding* ini, misalnya penelitian Öberg mengenai audio search berbasis transformasi *embedding* Wav2vec2 dengan *contrastive learning* [3]

Pada ranah *retrieval* berdasarkan kemiripan, sejumlah penelitian telah membuktikan keunggulan pendekatan berbasis *embedding* SSL. Nay san, dkk telah membuktikan bahwa representasi dari Wav2vec2 dapat melakukan *query-by-example spoken term detection* lintas bahasa tanpa transkripsi maupun fine-tuning dengan peningkatan 56%-86% atas *state of the art* sebelumnya [11]. Sejalan dengan itu, Zhaoqi Li, dkk membuktikan bahwa *Neural Acoustic Word Embeddings* berbasis pretrain Wav2vec2 mengungguli fitur MFCC untuk retrieval berbasis kemiripan [16]. Temuan-temuan ini menegaskan bahwa kualitas embedding SSL menjadikannya sangat sesuai dengan untuk tugas *similarity search*.

Dalam konteks bahasa Arab alkanhal, dkk melakukan perbandingan langsung antara Wav2vec2 dan Data2vec. Mereka menemukan bahwa Data2vec konsisten mengungguli Wav2vec2 dalam domain ASR Arab. Namun, perbandingan tersebut dilakukan dengan supervised fine-tuning dan juga dengan pengukuran metrik transkripsi, bukan frozen embedding tanpa fine-tuning dan metrik retrieval. Di sisi lain, kajian terhadap Data2vec pada tugas-tugas non-ASR mulai bermunculan dan justru memperlihatkan pola yang bergantung pada jenis tugasnya. Tang, dkk menemukan bahwa efektivitas Data2vec berbeda tergantung tugasnya, Data2vec lebih unggul dalam tugas yang berbasis konten contohnya ASR, namun kurang optimal dalam identifikasi pembicara. Yoon, dkk mengonfirmasi kecenderungan serupa, Data2vec 2.0 kuat pada tugas berbasis konten seperti ASR, tetapi performa query-by-

example nya justru menurun ketika diberi regulasi tambahan [13]. Evaluasi berskala besar yang dilakukan oleh Yang, dkk mempertegas hal ini, menunjukkan bahwa Data2vec mencapai performa terbaik pada Voice Conversion dan Phone Recognition, tetapi tertinggal pada Speaker Identification dan ASR out-of-distribution dibanding HuBERT dan WavLM.

Berdasarkan kajian tersebut, terlihat bahwa keunggulan Data2vec tidak bersifat universal, melainkan spesifik terhadap jenis tugas. Fakta ini memunculkan pertanyaan fundamental yang belum terjawab dalam literatur: apakah keunggulan Data2vec pada ASR bahasa Arab akan sama ketika kedua model dievaluasi tanpa fine-tuning dan menggunakan metrics dalam domain similarity search seperti MAP, Top-K, dan MRR.

Penelitian ini menghadirkan perbedaan penting dengan menempatkan kedua model tersebut dalam konteks *retrieval* audio ayat Al-Qur'an yang mana memiliki karakteristik fonetik dan aturan tajwid yang unik. Berbeda dengan penelitian pada umumnya yang menitik beratkan pada pengukuran performa transkripsi ASR, penelitian ini mengevaluasi kemampuan Wav2vec2 dan Data2vec dalam mencocokkan cuplikan bacaan dengan ayat terkait melalui pendekatan komparatif berbasis kemiripan embedding. Dengan demikian, penelitian ini menawarkan kontribusi yang masih minim dieksplorasi, sekaligus menyediakan landasan teknis bagi pengembangan sistem pendukung hafalan dan pembelajaran Al-Qur'an yang lebih adaptif dan aplikatif.

2.2 Studi Literatur

2.2.1 Kecerdasan buatan (Artificial Intelligence)

Kecerdasan buatan (Artificial Intelligence) merupakan salah satu cabang ilmu komputer yang mempelajari perancangan sistem yang mampu melakukan kecerdasan manusia, seperti penalaran, persepsi, pembelajaran, dan pengambilan keputusan [17]. Russel dan Norvig mengklasifikasikan AI ke dalam empat sudut pandang, yaitu sistem yang berpikir seperti manusia, bertindak seperti manusia, berpikir secara rasional, dan bertindak secara rasional. Pendekatan terakhir yakni rational agent yang bertindak untuk mencapai hasil terbaik menurut ukuran kinerja tertentu, menjadi kerangka dominan dalam AI modern [17].

Dalam perkembangannya, Machine learning (ML) muncul sebagai sub-bidang AI yang berfokus pada kemampuan sistem untuk belajar pola dari data tanpa dirprogram secara eksplisit untuk setiap kasus [18]. ML sendiri terbagi menjadi tiga paradigma utama supervised learning (belajar dari data yang berlabel), unsupervised learning (menemukan struktur dari data tak berlabel), dan self-supervised learning yang menjadi fondasi penelitian ini. Penelitian ini berada dalam ranah AI karena memanfaatkan model pembelajaran representasi untuk memahami dan mencocokkan sinyal ucapan Al-Qur'an secara otomatis.

2.2.2 Deep Learning

Deep learning adalah cabang dari machine learning yang menggunakan jaringan saraf tiruan berlapis yang jumlahnya sangat banyak (*deep neural networks*) untuk mempelajari representasi data secara berjenjang (*hierarchical representation*) [19]. Berbeda dari ML tradisional yang bergantung pada feature engineering manual yang mana, harus membutuhkan manusia untuk memberikan data yang berlabel, deep learning mempelajari fitur secara otomatis. Lapisan-lapisan awal menangkap fitur tingkat rendah (misalnya pola frekuensi pada audio), sedangkan lapisan yang lebih dalam menyusun fitur tingkat tinggi yang lebih abstrak (misalnya unit fonetik) [19]

Sebuah jaringan saraf tersusun atas neuron-neuron yang mentransformasikan input melalui bobot this equation $\mathbf{W}$, bias $\mathbf{b}$. Dan fungsi aktivasi non-linear σ , sehingga keluaran satu lapisan dinyatakan sebagai

$$\mathbf{h} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b})$$

Parameter jaringan dioptimasi dengan meminimalkan *loss function* melalui algoritma *backpropagation* dan *gradient descent* [19]. Arsitektur yang relevan bagi penelitian ini adalah jaringan konvolusi (Convolutional Neural Network, CNN) yang efektif mengekstrak fitur local dari sinyal, dan Transformer [20] yang memodelkan ketergantungan jangka Panjang melalui mekanisme self-attention. Kedua arsitektur inilah yang Menyusun tulang punggung model Wav2vec2 2.0 dan varian speech dari Data2Vec.

2.2.3 Similarity Search

Similarity search adalah proses menemukan objek-objek dalam suatu database yang paling mirip dengan sebuah objek kueri (data input), berdasarkan ukuran kemiripan tertentu [21]. Dalam paradigma modern, setiap objek, baik teks, gambar, maupun audio, direpresentasikan sebagai vector bilangan riil di ruang berdimensi tinggi, sehingga pencarian kemiripan tereduksi menjadi persoalan *Nearest Neighbor Search* di ruang vector tersebut [21]

Formalnya, diberikan sebuah vector kueri $\mathbf{q}$ dan himpunan vector database $D=\{\mathbf{d}_1, \dots, \mathbf{d}_N\}$, sistem menghitung skor kemiripan $s(\mathbf{q}, \mathbf{d}_i)$ untuk setiap $\mathbf{d}_i$, lalu mengurutkan hasilnya secara menurun untuk menghasilkan daftar peringkat (*ranked list*). Pendekatan ini menjadi tulang punggung sistem information retrieval modern [21]. Dalam penelitian ini, similarity search diterapkan pada embedding audio ayat Al-Qur'an. Data kueri dibandingkan langsung terhadap database embedding ayat tanpa melalui tahap transkripsi, sehingga menghindari propagasi kesalahan dari tahap ASR (*automatic speech recognition*).

2.2.4 Vector Embedding

Vector Embedding adalah representasi suatu objek dalam bentuk vector yang padat berdimensi tetap $\mathbf{v} \in \mathbb{R}^d$ yang dirancang sedemikian rupa sehingga kedekatan geometris antar-vektor mencerminkan kemiripan semantic atau perseptual antar objek yang diwakilinya [19]. Prinsip utamanya adalah distributional hypothesis, yang mana objek-objek yang serupa akan menempati posisi yang berdekatan di dalam ruang vector (*embedding space*)

Pada domain audio, embedding dihasilkan oleh model self-supervised seperti Wav2vec2 2.0 dan Data2vec, yang memetakan sinyal audio mentah menjadi barisan vector kontekstual. Embedding inilah yang menjadi objek perbandingan dalam penelitian ini. Kualitas sebuah embedding untuk tugas retrieval ditentukan oleh sejauh mana ia mengelompokkan (cluster) ayat yang sama secara berdekatan sekaligus memisahkan ayat yang berbeda, suatu sifat geometric yang menjadi dasar hipotesis pada penelitian ini.

2.2.5 Self-Supervised Learning (SSL)

Self-Supervised Learning (SSL) adalah paradigma pembelajaran mesin di mana model dilatih untuk mempelajari representasi yang berguna dari data yang

tidak memiliki *label* dengan menghasilkan labelnya sendiri. SSL terletak di antara *Supervised Learning* (yang membutuhkan label manual ekstensif) dan *Unsupervised Learning* (yang mencari pola tanpa label).

Inti dari SSL terletak pada penciptaan "Tugas Preteks" (*Pretext Task*). Tugas ini memaksa model untuk memahami dan memprediksi bagian tersembunyi (*masked*) atau bagian yang hilang (*corrupted*) dari data input itu sendiri.

2.2.6 Wav2vec2 2.0

Wav2vec2 2.0 adalah sebuah model self-supervised learning (SSL) yang mempelajari representasi dari ucapan langsung atau audio mentah melalui pendekatan *contrastive learning*. Arsitekturnya terdiri dari tiga komponen inti; feature encoder konvolusional, jaringan konteks berbasis Transformer, dan modul kuantisasi yang bekerja dalam satu tugas pretext. Memprediksi unit terakuantisasi yang benar dari representasi konteks pada posisi yang ditutup (*masked*).

2.2.6.1 Feature encoder

Sinyal audio mentah $\mathcal{X}$ (16 kHz) diproses oleh tujuh blok konvolusi temporal, masing-masing berisi 512 kanal dengan Layer Normalization dan aktivasi GELU. Susunan stride (5,2,2,2,2,2,2) dan lebar kernel (10,3,3,3,3,2,2) menghasilkan barisan representasi laten $z_1, \dots, z_T$ pada frekuensi keluaran sekitar 49 Hz (jarak antar-frame ≈ 20 ms), dengan receptive field selebar 400 sampel input atau setara 25 ms audio.

Table 2 Konfigurasi Blok Konvolusi Temporal pada Encoder Audio

Blok	Stride	Kernel	Kanal
1	5	10	512
2-5	2	3	512
6-7	2	2	512

2.2.6.2 Jaringan konteks $g: \mathcal{Z} \rightarrow \mathcal{C}$

Representasi laten z diumpankan ke jaringan Transformer N4 yang memodelkan ketergantungan jangka panjang antar-frame melalui self-attention, menghasilkan representasi kontekstual $c_1, \dots, c_T$. Konfigurasi Base memakai 12 blok ($d = 768$, 8 Head, sedangkan Large memakai 24 blok ($d = 1024$, 16 head).

Informasi posisi ditanamkan melalui relative positional convolutional embedding (kernel 128, 16 grup), bukan positional encoding absolut. Representasi laten $\mathbf{z}$ diumpangkan ke jaringan Transformer N4 yang memodelkan ketergantungan jangka panjang antar-frame melalui self-attention, menghasilkan representasi kontekstual $c_1, \dots, c_T$. Konfigurasi Base memakai 12 blok ($d = 768$, 8 head), sedangkan Large memakai 24 blok ($d = 1028$, 16 head). Informasi posisi ditanamkan melalui relative positional convolutional embedding (kernel 128, 16 grup), bukan positional encoding absolut.

2.2.6.3 Modul kuantisasi

Secara paralel, laten $\mathbf{z}$ didiskretisasi melalui product quantization N9 dengan $G = 2$ codebook, masing-masing $V = 320$ entri. Pemilihan entri dibuat terdiferensiasi menggunakan Gumbel-Softmax N7, N8:

$$p_{g,v} = \frac{\exp((l_{g,v} + n_{g,v})/\tau)}{\sum_{k=1}^V \exp((l_{g,k} + n_{g,k})/\tau)}$$

dengan $l_{g,v}$ logit entri v pada grup g , τ temperatur (dijadwalkan turun dari 2 ke 0,5), dan $n_v = -\log(-\log(u_v))$, $u_v \sim \mathcal{U}(0,1)$ derau Gumbel. Pada forward pass dipilih entri diskret $i = \arg \max_j p_{g,j}$; pada backward pass digunakan gradien fungsi Gumbel-Softmax kontinu (straight-through estimator N10) sehingga tetap dapat dilatih.

2.2.6.4 Fungsi Objektif

Pelatihan diarahkan gabungan dua komponen

$$\mathcal{L} = \mathcal{L}_m + \alpha \mathcal{L}_d, \quad \alpha = 0,1$$


Contrastive loss $\mathcal{L}_m$ memaksa model membedakan target benar q_t dari $K = 100$ pengecoh:

$$\mathcal{L}_m = -\log \frac{\exp\left(\frac{\text{sim}(c_t, q_t)}{\kappa}\right)}{\sum_{\tilde{q} \sim Q_t} \exp\left(\frac{\text{sim}(c_t, \tilde{q})}{\kappa}\right)}$$

Dengan $\kappa = 0,1$ dan $\text{sim}(a,b) = \frac{a^T b}{|a||b|}$ (cosine similarity, berperan sebagai scoring function). Diversity loss $\mathcal{L}_d$ mendorong pemakaian merata seluruh entri codebook via maksimalisasi entropi:

$$\mathcal{L}_d = \frac{1}{G} \sum_{g=1}^G \sum_{v=1}^V \overline{p_{g,v}} \log \overline{p_{g,v}}$$

Melalui mekanisme kontrastif inilah Wav2vec2 2.0 dihipotesiskan menghasilkan embedding yang lebih clusterable untuk retrieval berbasis cosine [22]



Gambar 2 Arsitektur Wav2vec2 2.0

2.2.7 Data2vec

Data2vec merupakan model Self-Supervised Learning (SSL) yang modality agnostic, artinya inputan yang dapat diproses dapat berupa audio, gambar ataupun text. Perbedaan mendasarnya dengan Wav2vec2 2.0 terletak pada bentuk prediksi, Data2vec tidak memprediksi unit diskret terkuantisasi, melainkan representasi laten kontekstual yang bersifat kontinu. Yang dihasilkan oleh model itu sendiri melalui skema self-distillation

2.2.7.1 Skema Teacher dan Student (self-distillation)

Satu arsitektur Transformer [20] beroperasi dalam dua peran. Jaringan student yang memproses input yang dimasking dan menghasilkan prediksi $f_t(x)$ pada tiap posisi termasking. Jaringan teacher memproses input penuh (tanpa masking) dan menyediakan target regresi y_t . Student dilatih meregresi target teacher hanya pada posisi termasking

2.2.7.2 Pembaruan Teacher via EMA

Pembaruan teacher tidak dilakukan oleh gradient, melainkan menggunakan exponential moving average (EMA) dari parameter student $\Delta \leftarrow \tau \Delta + (1 - \tau)$ dengan Δ parameter teacher, θ parameter student. Nilai τ dinaikan linear dari τ_0 ke τ_e langkah awal lalu ditahan konstan, untuk ucapan $\tau_0 = 0, \tau_e = 0, \tau_n = 30.0$

2.2.7.3 Konstruksi Target Kontekstual

Target dibentuk dengan merata-ratakan keluaran K blok Transformer teratas teacher, setelah masing-masing dinormalisasi

$$y_t = \frac{1}{K} \sum_{l=L-K+1}^L \hat{a}_t^l$$

Dengan L dengan jumlah total blok (12 pada base), $K = 8$ blok teratas $\hat{a}_t^l$ keluaran blok l ternormalisasi. Untuk ucapan digunakan *instance normalization* [23]. Untuk gambar layer normalization [24]. Normalisasi ini mencegah keruntuhan representasi (representation collapse). Karent target menggabungkan berupa lapisan atas, ia bersifat kontekstual penuh. Hal ini menjadi dasar hipotesis bahwa Data2ve menghasilkan fitur fonetik lebih kaya [10], [14].

Commented [MM12]: Bayangin lo punya crayon dengan cuma 8 warna di kotak crayon. Kalau lo mau gambar langit yang sebenarnya punya jutaan gradasi warna biru, lo terpaksa milih salah satu dari 8 warna itu — misal "biru muda" atau "biru tua". Nggak ada pilihan "biru muda tapi 23% lebih terang dikit". Itu yang dilakuin Wav2Vec2: suara yang sebenarnya halus dan terus-menerus (kontinu), dipaksa "dibulatkan" jadi salah satu dari sekumpulan kategori suara yang udah ditentukan sebelumnya (kayak kotak crayon 8 warna tadi). Prosesnya disebut "**kuantisasi**" — dari sesuatu yang halus jadi kotak-kotak/kategori.

Commented [MM13]: Sekarang bayangin lo nggak dibatasin 8 crayon. Lo boleh nyampur warna sepuasnya buat dapetin warna biru yang PAS — biru langit sore itu, bukan cuma "biru" doang. Itu yang dilakuin Data2Vec: dia nggak maksa "bulatkan ke kategori tertentu", tapi biarin nilai-nilainya tetep halus/terus-menerus (kontinu) — kayak angka desimal yang bisa sedetail apapun (0.234, 0.2341, 0.23414, dst), bukan cuma pilih dari beberapa opsi terbatas. "Laten" = tersembunyi/nggak keliatan langsung (representasi internal si model, bukan suara aslinya). "Kontekstual" = maknanya nyesuain sama kata-kata di sekitarnya — kayak kata "bisa" beda arti kalau dipasangin sama "aku bisa makan ular" vs "ular bisa itu berbahaya".

Commented [MM14]: Bayangin lo lagi latihan basket sendirian, tapi lo rekam gerakan lo pas lagi *on fire* (lagi jago-jagonya, konsisten masuk terus), terus lo tonton ulang rekaman itu buat ngajarin diri lo sendiri di kesempatan latihan berikutnya.

Jadi:

- "**Guru**" (teacher) = versi "lo" yang lebih stabil/tenang (biasanya rata-rata dari beberapa lo versi terakhir)
- "**Murid**" (student) = versi "lo" yang lagi belajar sekarang, mencoba niru apa yang "guru" hasilkan


Yang unik: **guru dan murid itu sebenarnya model yang SAMA**, cuma "guru"-nya itu semacam foto rata-rata dari versi-versi murid sebelumnya (biar lebih stabil dan nggak grasak-grusuk). Makanya disebut **self-distillation** — "belajar dari diri sendiri", bukan dari orang lain yang udah expert dari awal.

2.2.7.4 Fungsi Objektif

Student meregresi target dengan Smooth L1 loss (huber):

$$\mathcal{L}(y_t, f_t(x)) = \begin{cases} \frac{1}{2}(y_t - f_t(x))^2 / \beta, & |y_t - f_t(x)| \leq \beta \\ |y_t - f_t(x)| - \frac{1}{2}\beta, & \text{selainnya} \end{cases}$$

Parameter β mengatur peralihan wilayah kuadrat (l_2) dan linear (l_1) untuk $\beta \rightarrow \infty$ loss menjadi MSE murni yang bekerja baik pada domain ucapan.



Gambar 3 Arsitektur Data2vec

2.2.8 Cosine Similarity

Cosine Similarity mengukur kemiripan antara dua vektor berdasarkan sudut cosine di antara keduanya, tanpa perlu memperhitungkan besar magnitudonya (bx5)

$$\text{sim}(q, d) = \cos \theta = \frac{q \cdot d}{|q| |d|} = \frac{\sum_{i=1}^d q_i d_i}{\sqrt{\sum_{i=1}^d q_i^2} \sqrt{\sum_{i=1}^d d_i^2}}$$

Nilainya berkisar pada $[-1, 1]$, dengan nilai mendekati 1 menandakan arah vektor yang sangat mirip. Perlu ditegaskan bahwa dalam bidang retrieval, cosine similarity berperan sebagai fungsi penilaian (*scrolling function*), bukan sebagai metrik evaluasi [21]. Manning dkk. Membedakan secara tegas antara mekanisme scoring ranking dan metrik evaluasi efektivitas sistem. Selain itu cosine distance ($1 - \cos \theta$) bukan metrik jarak matematis, arena melanggar pertidaksamaan segitiga [25]. oleh karena itu, dalam penelitian ini cosine similarity digunakan sebagai fungsi penilai kemiripan untuk menghasilkan peringkat, sedangkan efektivitas retrieval diukur menggunakan metrik evaluasi yang dijelaskan pada sub-bab berikutnya.

2.2.9 Metriks Evaluasi Retrieval

Efektivitas sistem retrieval dievaluasi menggunakan metrik yang berbasis pada kualitas peringkat (ranking) hasil pencarian [21]. Penelitian ini menggunakan tiga metrik utama berikut.

2.2.9.1 Top K Accuracy

Metrik ini mengukur proporsi kueri yang dokumen relevannya ditemukan dalam K peringkat teratas dalam pencarian

$$\text{Top} - K \text{ Accuracy} = 1 \div |Q| \sum_{q \in Q} 1[\text{rank}(q) \leq K]$$

Dengan $|Q|$ adalah jumlah total kueri, dan $1[\cdot]$ adalah fungsi indikator yang bernilai 1 apabila dokumen relevan berada pada peringkat kurang dari atau sama dengan K, dan berniali 0 jika sebaliknya. Metrik ini mencerminkan kegunaan praktis sistem bagi pengguna yang umumnya hanya memeriksa hasil teratas

2.2.9.2 Mean Reciprocal Rank (MRR)

MRR mengukur seberapa tinggi peringkat dokumen relevan pertama, dengan menghitung rata-rata kebalikan peringkatnya [21]. MRR memiliki rumus demikian

$$MRR = \frac{1}{|Q|} \sum_{i=1}^{|Q|} \frac{1}{\text{rank}_i}$$

Dengan rank_i posisi peringkat dokumen relevan pertama untuk kueri ke- i . Nilai MRR mendekati 1 menunjukkan dokumen relevan cenderung berada di peringkat paling atas.

2.2.9.3 Mean Average Precision (MAP)

MAP merupakan metrik yang paling komprehensif karena memperhitungkan presisi pada setiap posisi dokumen relevan sepanjang daftar peringkat [21]. Untuk sebuah kueri, Average Precision (AP) dihitung sebagai

$$AP = \frac{1}{|R|} \sum_{k=1}^N P(k) \cdot \text{rel}(k)$$

Dengan $P(k)$ presisi pada peringkat k , $\text{rel}(k)$ fungsi indicator relevansi dokumen di peringkat k , $|R|$ jumlah total dokumen relevan, dan N jumlah dokumen. MAP kemudian adalah rata-rata AP atas seluruh kueri

$$MAP = \frac{1}{|Q|} \sum_{q=1}^{|Q|} AP(q)$$

Ketiga metrik ini; Top-K Accuracy, MRR, dan MAP merupakan metrik evaluasi yang secara konseptual berbeda dengan cosine similarity yang berperan sebagai *scoring function*

2.2.10 Dataset Quran-MD

Penelitian ini menggunakan dataset Quran-MD (bx7), sebuah dataset multimodal yang tersedia pada platform huggingface. Dataset ini mengintegrasikan dimensi teks, linguistic, dan audio pada tingkat ayat maupun kata. Untuk setiap ayat disediakan teks Arab asli serta rekaman dari 30 pembaca

Commented [MM15]: Studi Kasus: Pencarian Video YouTube

3 kueri, tiap kueri punya 1 video relevan, sistem kembalikan 5 hasil teratas:

Kueri Jawaban benar di rank AP
"resep nasi goreng" 1 1/1 = 1.000
"tutorial coding python" 3 1/3 = 0.333
"cara ganti oli motor" 4 1/4 = 0.250
MAP = (1.000+0.333+0.250)/3 = 0.528

(qori) yang berbeda guna mempresentasikan keragaman gaya bacaan (qiraat) dan nuansa dialektik.

Secara kuantitatif, koleksi Quran-MD terdiri atas dua sub-dataset terpisah. sub-dataset ayat (Buraaq/quran-md-ayahs) berisi 187080 sampel rekaman ayat lengkap. Dan sub-dataset kata (Buraaq/quran-md-words) berisi 77429 sampel pelafalan kata individual, sehingga totalnya mencakup sekitar 264509 audio format berformat mp3 yang meliputi 114 surah dan 6236 ayat unik (bx7). Sesuai batasan masalah penelitian, objek yang digunakan dibatasi pada surah Al-fatihah dan juz 30 dari sub-dataset tingkat ayat. Pasangan audio-teks yang tersedia pada dataset ini memungkinkan penerapan tugas similarity search berbasis suara tanpa transkripsi.

2.2.11 Metode Penelitian CRISP-DM

Penelitian ini mengadopsi kerangka kerja (*framework*) Cross-industry Standard Process for Data Mining (CRISP-DM) sebagai metodologi (bx8). CRISP-DM merupakan model process standar yang bersifat iteratif dan tidak bergantung pada industri maupun teknologi tertentu, sehingga sesuai untuk penelitian berbasis data dan machine learning. Kerangka ini terdiri atas enam fase yang saling terikat:

1. Business Understanding. Merumuskan tujuan penelitian, yaitu membandingkan efektivitas embedding Wav2vec2 dan Data2vec untuk retrieval ayat Al-Qur'an, beserta hipotesis H1 dan H2.
2. Data understanding. Mengeksplorasi karakteristik dataset Quran-MD, mencakup distribusi qari, kualitas audio, dan cakupan surah yang digunakan.
3. Data preparation. Menyeleksi Surah Al-Fatihah dan Juz Amma, melakukan pre-processing audio dan menyiapkan pasangan kueri dan database untuk pengujian
4. Modeling. Mengekstrak embedding dari kedua model SSL tanpa adanya fine-tuning, lalu menghitung skor kemiripan menggunakan cosine similarity untuk menghasilkan peringkat retrieval.
5. Evaluation. Mengukur kinerja retrieval kedua model menggunakan metrik MAP, Top-K Accuracy, dan MRR.

6. Deployment. Menyusun kesimpulan dan rekomendasi model terbaik sebagai acuan bagi pengembangan system pembelajaran Al-Quran berbasis audio.

BAB III

METODOLOGI PENELITIAN

Metodologi penelitian yang diadaptasi dari penelitian ini yaitu *framework Cross-Industry Standard Process for Data Mining* (CRISP-DM). Dikarenakan *framework* ini bersifat sistematis, adaptif serta iterative dan tidak terikat pada teknologi tertentu, sehingga sesuai dengan penelitian berbasis data dan *Machine Learning*. Namun demikian, karena penelitian ini bertujuan untuk membandingkan efektivitas fitur laten model Self-Supervised Learning tanpa dilakukan *transfer learning*, maka terdapat dua fase dalam *framework* CRISP-DM yang perlu disesuaikan agar selaras dengan tujuan penelitian ini, yaitu *Modeling* dan *Deployment*. Fase *Modeling* tidak berupa pelatihan model, melainkan ekstraksi representasi laten. Sementara fase *Deployment* diarahkan pada sintesis temuan, pengujian hipotesis, dan perumusan rekomendasi arsitektur, bukan penerapan sistem dalam lingkungan produksi. Dengan penyesuaian tersebut, proses penelitian dilaksanakan secara terstruktur melalui enam fase, mulai dari *Business Understanding*, *Data Understanding*, *Data Preparation*, *Modeling*, *Evaluation* dan *Deployment* yang diadaptasi.

3.1. Business Understanding

Fase *business understanding* berfungsi menerjemahkan permasalahan penelitian menjadi sasaran analitis yang terukur [26]. Tujuan utama yang ditetapkan dalam penelitian ini adalah mengukur dan membandingkan efektivitas fitur laten dua model Self-Supervised Learning (SSL) model, yaitu Wav2vec2 dan Data2vec. Dalam tugas *retrieval* ayat Al-Quran. Perbandingan dilakukan dalam kondisi *frozen*. Penelitian ini memanfaatkan model *pre-trained* tanpa pelatihan ulang (*fine-tuning*). Sehingga metrik yang dihasilkan merupakan *raw performance* masing masing model.

Sasaran tersebut menghasilkan dua hipotesis yang saling berkebalikan sebagai inti kontribusi penelitian. Hipotesis pertama memperkirakan Data2vec unggul, karena target prediksinya yang berupa representasi kontekstual laten penuh berpotensi menghasilkan fitur fonetik yang kaya dan umum. Hipotesis kedua memperkirakan justru Wav2vec2 yang unggul pada *retrieval*. Karena *contrastive-loss*-nya secara eksplisit menari pasangan positif dan menolak kandidat negatif, sehingga cenderung menciptakan ruang *embedding* yang lebih clusterable dan lebih selaras dengan pengukuran jarak cosine-property yang justru menentukan dalam kasus *retrieval*. Penelitian ini tidak hanya membandingkan angka kinerja,

Commented [MM16]: Murid A (Data2vec) — belajarnya dengan cara "nebak gambaran besar". Dikasih potongan suara yang disensor, terus disuruh nebak "representasi lengkap"-nya kayak apa (bukan cuma satu jawaban spesifik, tapi keseluruhan konteksnya). Karena belajarnya luas dan nggak fokus ke satu hal, dia jadi punya pengetahuan yang kaya dan serbaguna — cocok buat banyak jenis tugas.

H1: Murid A (Data2vec) menang, karena representasinya lebih kaya/umum → fitur fonetiknya lebih bagus

Commented [MM17]: Murid B (Wav2vec2) — belajarnya dengan cara "cari pasangan yang cocok, tolak yang salah" (*contrastive learning*). Dikasih satu suara asli, terus disuruh milih: "mana nih yang beneran pasangannya di antara banyak kandidat palsu?" Karena dia dilatih terus buat *membedakan* yang mirip vs nggak mirip, hasil belajarnya jadi rapi banget kalau diukur pakai "jarak" — mirip kayak dia otomatis mengelompokkan hal-hal yang mirip jadi dekat, yang beda jadi jauh.

H2: Murid B (Wav2vec2) menang, justru karena cara belajarnya (*contrastive*) udah "cocok bawaan" sama tugas *retrieval* yang berbasis jarak/kemiripan

melainkan menguji apakah keunggulan suatu paradigma *pre-training* bersifat lintas tugas atau justru spesifik terhadap jenis tugas.


Agar kedua hipotesis dapat diuji secara objektif, pada fase ini ditetapkan pula definisi relevansi yang menjadi dasar penyusunan ground truth. Sebuah rekaman dinyatakan relevan terhadap suatu query apabila keduanya merupakan ayat yang sama meskipun dibacakan oleh pembaca (qori) yang berbeda. Definisi ini memungkinkan sistem retrieval diuji atas kemampuannya mengenali kesamaan konten ayat lintas variasi pembaca, gaya bacaan, dan nuansa dialektik. Kriteria keberhasilan penelitian kemudian ditetapkan menggunakan metrik evaluasi retrieval berbasis kualitas peringkat, yaitu Mean Average Precision (MAP), Top-K Accuracy, dan Mean Reciprocal Rank (MRR) [21]. Sejalan dengan hal tersebut, cosine similarity diposisikan sebagai fungsi penilaian (scoring function) untuk menghasilkan peringkat, bukan sebagai metrik evaluasi.

Penelitian ini dibatasi pada penggunaan pre-trained model tanpa fine-tuning, dengan objek teliti berupa surah Al-Fatihah dan Juz Amma, serta pengujian pada tingkat ayat. Salah satu sasaran analitis yang turut dirumuskan adalah identifikasi lapisan (layer) yang paling optimal bagi tugas *retrieval* fonetik. Perumusan sasaran ini dilandasi temuan bahwa informasi fonetik dan leksikal pada model SSL tidak terdistribusi secara merata di seluruh lapisan, melainkan terkonsentrasi pada lapisan tertentu yang bergantung pada paradigma pre-training. Pada model yang menggunakan contrastive seperti Wav2vec2, informasi fonetik cenderung meningkat di layer tengah dan menurun di layer akhir [27]. Sehingga lapisan terbaik untuk sebuah studi kasus tidak selalu berada pada lapisan terakhir. Dengan demikian penelitian ini sejak awal diarahkan untuk melakukan ekstraksi secara *layer-wise*.

3.2. Data Understanding

Fase Data Understanding bertujuan mengenali karakteristik data secara menyeluruh sebelum dilakukan pemrosesan, mencakup pengumpulan data, pendeskripsian sifat data, eksplorasi pola, serta verifikasi kualitasnya [26]. Pada fase data understanding, tidak adanya perubahan data. Namun mengamati data dan menilai data, sehingga data-data yang ada masih berupa data mentah. Pemahaman yang ada pada proses ini menjadi landasan untuk proses *pre-processing* kedepannya. Sekaligus memastikan bahwa data yang tersedia memang mampu mendukung tujuan penelitian.


Data yang akan digunakan bersumber dari dataset Quran-MD yang tersedia pada platform *HuggingFace*, khususnya sub-dataset pada tingkat ayat [28]. Dataset ini menyediakan pasangan audio-teks untuk setiap ayat disertai rekaman audio dari 30 qori yang berbeda yang bertujuan untuk merepresentasikan keragaman gaya bacaan ayat Al-Quran. Pada tahap pengumpulan awal, akan didokumentasikan struktur dataset yang meliputi berkas audio, teks Arab yang berpasangan, serta metadata penanda ayat berupa nomor surah, nomor ayat, dan identitas qori. Untuk *summary* dari dataset divisualisasikan dalam Gambar 4. Namun karena batasan masalah penelitian ini, yang digunakan hanyalah 37 surah yang ada di juz Amma dan surah Al-Fatihah.



```
Total Records: 187,080
Unique Surahs: 114
Unique Ayahs: 286
Unique Reciters: 30
Bitrates: [32, 40, 64, 128, 192] kbps
```

Gambar 4 Gambar Summary statistic dataset Quran-MD

Selanjutnya akan dilakukan analisis file audio. Mencakup format audio, *sampling rate* asli dan jumlah kanal. Pendeskripsian ini penting karena untuk model Wav2vec2 dan Data2vec mengharuskan input audio pada sampling rate 16kHz dan pada kanal mono. Jika dilihat dari data Quran-MD. Selain itu juga akan ada perhitungan terkait distribusi jumlah qori per ayat, distribusi durasi rekaman antar ayat, serta distribusi jumlah ayat pada tiap surah dalam subset yang digunakan. Proses ini memiliki peran krusial karena menentukan banyaknya dokumen relevan bagi setiap query, yang secara langsung memengaruhi perhitungan metrik *Mean Average Precision* (MAP) dan *Mean Reciprocal Rank* (MRR). Sementara itu, distribusi durasi ayat perlu dipahami karena ketimpangan durasi antara ayat pendek dan ayat panjang berpotensi memengaruhi hasil agregasi fitur melalui *temporal pooling* pada tahap ekstraksi representasi laten. Analisis karakteristik audio meliputi distribusi *sampling rate*, jumlah kanal, dan durasi rekaman disajikan dalam Gambar 5



Gambar 5 Karakteristik Audio


Temuan dari fase Data Understanding ini akan menjadi landasan bagi penetapan prosedur pre-processing dan penyusunan ground truth pada fase-fase selanjutnya.

Dataset testing yang digunakan dalam penelitian ini terdiri atas rekaman video bacaan Juz Amma dan surah Al-Fatihah dari 81 mahasiswa Program studio Teknik Informatika UIN Sunan Gunung Djati Bandung. Juz Amma merupakan bagian dari Al-Qur'an yang mencakup 37 surah, yang dimulai dari surah ke-78 (An-Naba) sampai dengan surah ke-114 (An-Nas). Dengan demikian, setiap mahasiswa diharapkan mengumpulkan total 38 video (1 surah Al-Fatihah ditambah 37 surah Juz Amma). Rekaman tersebut dikumpulkan sebagai bagian dari pemenuhan mata kuliah Tahfidz dan persyaratan sidang komprehensif.

Table 3 Summary Statistic Dataset Query

Total Mahasiswa	81
Lengkap	25
Tidak Lengkap	56
Rata-rata video	22.2
Median video	28.0
Min Video	0
Max Video	38


Pada Tabel 3 menunjukkan ringkasan statistik dataset query. Dari 81 mahasiswa, hanya 25 mahasiswa (30.9%) yang telah melengkapi seluruh 38 video, sedangkan 56 mahasiswa (69.1%) belum melengkapi seluruh 38 video. Rata-rata jumlah video per mahasiswa adalah 22,2 dengan median 28,0, menunjukkan bahwa sebagian besar mahasiswa belum mencapai target kelengkapan.



Gambar 6 Total Videos Distribution histogram

Analisis lebih mendalam terhadap surah yang paling sering tidak lengkap ditunjukkan pada Gambar 6. Bar chart horizontal menampilkan 15 surah yang paling sering *missing* dari dataset mahasiswa. Surah-surah ini menjadi indikator pola kelengkapan yang perlu diperhatikan.

Setiap data mahasiswa disimpan dalam direktori terpisah yang diidentifikasi berdasarkan kombinasi Nomor Induk Mahasiswa (NIM) dan nama, misalnya "NIM_NAMA". Namun, konvensi penamaan tidak homogen. Ditemukan variasi separator seperti underscore ("_") dan dash ("-"), serta perbedaan format penamaan berkas video. Beberapa mahasiswa menggunakan nomor surah asli sebagai prefiks (misalnya "78-AnNaba.mp4"), sementara yang lain menggunakan nomor urut pengumpulan (misalnya "1. An-Nas.mp4" yang sebenarnya adalah surah ke-114). Variasi lain meliputi perbedaan kapitalisasi ("Al-Ghasyiyah" vs "al-ghasyiyah"), penggunaan simbol khusus ("Al-_Asr", "Al-A_la"), dan penambahan kata "Surah" atau "Q.S" di awal nama berkas.



Gambar 7 Box Plot Showing Outlier

Box plot pada Gambar 7 memperlihatkan adanya outlier dalam distribusi jumlah video. Beberapa mahasiswa memiliki jumlah video yang sangat rendah (0-4 video), sementara yang lain mencapai 38 video. Variansi ini menunjukkan tingkat pengumpulan mahasiswa yang beragam. Heterogenitas struktur penamaan dan ketidaklengkapan data menjadi tantangan utama dalam tahap prapemrosesan. Diperlukan proses normalisasi untuk menghasilkan representasi data yang konsisten, serta mekanisme pencocokan nama surah yang toleran terhadap variasi penamaan untuk memungkinkan pemrosesan otomatis yang akurat.

3.3.Data Preparation

Fase Data Preparation bertujuan mengubah data mentah menjadi data yang siap digunakan untuk proses ekstraksi representasi laten. Fase ini mencakup empat tahap yaitu seleksi data, normalisasi audio, verifikasi segmentasi ayat, konstruksi ground truth sebagai dasar evaluasi retrieval ayat.

Proses pertama adalah seleksi data sesuai dengan Batasan masalah, yakni memilih rekaman dari surah Al-Fatihah dan surah-surah dalam Juz Amma yang disusun berdasarkan ayat. Dari proses seleksi ini akan disusun *identifier* yang terdiri dari gabungan qori, surah dan ayat. Untuk data pada Quran-MD karena mencakup keseluruhan surah yang kita perlukan hanyalah surah Al-Fatihah dan surah-surah Juz Amma. Sedangkan pada data *query* yaitu rekaman mahasiswa itu sudah terdiri dari surah-surah Juz Amma, namun perlu diingat untuk tugas pengumpulan tahfiz terdapat video ayat Al-Quran yang ada kaitannya dengan Sains dan teknologi, itupun perlu dipisahkan.

Proses kedua adalah normalisasi data, normalisasi data adalah menstandarisasi seluruh data audio yang akan dijadikan *ground truth* dan juga data input query yang nantinya digunakan sebagai data testing. Langkah ini untuk menjadi solusi dari pembahasan data understanding yang mengungkap bahwa data Quran-MD itu memiliki audio sampling rate dan jumlah kanal yang berbeda. Sehingga perlu dilakukan konversi pada data yang berbeda untuk sampling rate 16Khz dan jumlah kanal menjadi tunggal (*mono*). Hal ini bertujuan supaya hasil dari representasi laten antara model Wav2vec2 dan Data2vec berasal dari performa masing-masing model tersebut, bukan dari ketidaksesuaian data yang ada.

Proses ketiga adalah *pre-processing* diawali dengan proses normalisasi struktur dataset, yaitu menyeragamkan penamaan direktori dan berkas berdasarkan nomor serta nama surah yang sesuai dengan urutan dalam Al-Qur'an. Proses ini dilakukan untuk mengatasi ketidakkonsistenan penamaan, seperti perbedaan penggunaan huruf besar dan huruf kecil, variasi simbol, maupun format penamaan yang tidak mengikuti konvensi tertentu. Hasil normalisasi tersebut digunakan sebagai dasar dalam proses identifikasi surah secara otomatis pada tahap selanjutnya.

Setelah proses normalisasi selesai, dilakukan segmentasi ayat dan verifikasi terhadap data. Data yang digunakan sebagai *input query* berupa rekaman video mahasiswa yang dalam satu videonya membacakan satu surah secara utuh, mencakup seluruh surah dalam Juz Amma

beserta surah Al-Fatihah. Oleh karena itu, setiap rekaman terlebih dahulu diekstraksi menjadi berkas audio, kemudian dilakukan proses segmentasi untuk membagi audio surah menjadi beberapa segmen yang masing-masing merepresentasikan satu ayat. Segmentasi dilakukan melalui dua tahap. Pertama, model *forced alignment WhisperX* digunakan untuk memperoleh *timestamp* pada tingkat kata dari rekaman mahasiswa satu full surat. Kedua, batas antar ayat ditentukan melalui alokasi proporsional berdasarkan jumlah kata tiap ayat yang bersumber dari API Al-Quran, kemudian audio dipotong menggunakan library *pydub*. Perlu dicatat bahwa pembagian durasi berdasarkan rasio jumlah kata dapat menyebabkan kesalahan kecil pada setiap batas ayat. Kesalahan tersebut dapat terbawa dan bertambah secara kumulatif pada batas-batas berikutnya, sehingga posisi segmentasi dapat semakin melenceng dari batas ayat yang sebenarnya, terutama pada bagian akhir surah.

3.4. Modeling

Fase Modeling pada penelitian ini diadaptasi dari makna aslinya dalam *framework* CRISP-DM. karena penelitian ini menggunakan *frozen embedding* tanpa fine-tuning atau transfer learning, fase ini tidak melibatkan pelatihan model, melainkan befokus pada ekstraksi representasi laten dari mdoel pre-trained serta konstruksi *similarity* yang menjadi dasar proses retrieval. Fase ini terdiri atas empat sub-proses yaitu pemilihan model, ekstraksi representasi laten secara layer-wise, agregasi fitur menjadi vektor embedding, dan perhitungan skor kemiripan untuk menghasilkan peringkat.

Pada sub proses pertama yaitu pemilihan model, penelitian ini menggunakan dua model self-supervised Learning (SSL), yaitu Wav2vecc2 dan Data2vec, dalam kondisi *frozen*. Keduanya dipilih karena menggunakan paradigma pretraining yang berbeda, yaitu pendekatan contrastive pada Wav2vec2 dan pendekatan self-distillation dengan target laten kontekstual pada Data2vec. Perbedaan paradigma inilah yang menjadi objek perbandingan utama dan menjadi dasar bagi pengujian hipotesis H1 dan H2.

Proses selanjutnya adalah ekstrasi representasi laten. Setiap audio yang telah dinormalisasi, baik pada Database (D) maupun Query set (Q), diinputkan ke masing-masing model untuk memperoleh representasi laten. Ekstrasi tidak dibatasi pada lapisan transformer terakhir, melainkan dilakukan pada seluruh lapisan. Pendekatan layer-wise ini diperlukan karena informasi fonetika dan leksikal pada model SSL tidak terdistribusi merata di seluruh lapisan, melainkan terkonsentrasi pada lapisan tertentu yang bergantung pada paradigma

Commented [MM18]: Layer-wise ditegaskan eksplisit dengan justifikasi Pasad 27 — ini memperbaiki inkonsistensi di draf lama Anda (baris 1086 yang hanya menyebut "lapisan terakhir").

- Cosine sebagai scoring function dipertahankan sesuai kaidah repo (Manning 21), tidak dicampur dengan metrik evaluasi.
- H1/H2 dirujuk sebagai objek uji, tanpa mengulang rumusan penuhnya (sudah ada di Business Understanding & BAB I).
- Saya tidak menyebut FAISS di sini walau ada di jadwal penelitian Anda (tabel baris 1192); jika ingin FAISS dimasukkan sebagai mekanisme pencarian approximate, beri tahu — tapi untuk skala 571 ayat, pencarian exact (brute-force cosine) sudah memadai dan lebih tepat secara metodologis.

pretraining. Pada model bertipe bertipe contrastive seperti Wav2vec2, informasi fonetik cenderung memuncak di lapisan menengah dan menurun pada lapisan akhir, sehingga lapisan terbaik untuk suatu tugas belum tentu merupakan lapisan terakhir [27]. Dengan mengekstraksi seluruh lapisan, penelitian dapat menganalisis distribusi kinerja antar lapisan dan mengidentifikasi lapisan yang paling optimal bagi tugas retrieval fonetik.

Sub proses ketiga adalah agregasi fitur. Representasi laten pada tiap lapisan berupa urutan vektor sepanjang durasi audio, sehingga perlu digregasi menjadi satu vector berdimensi tetap agar dapat dibandingkan antar audio. Agregasi dilakukan melalui temporal pooling, dalam hal ini mean pooling, yang merata-ratakan seluruh vector sepanjang dimensi waktu. Hasilnya adalah satu vector embedding per rekaman untuk setiap kombinasi model dan lapisan, yang selanjutnya disusun menjadi basis data vector terpisah bagi masing-masing kombinasi tersebut.

Sub proses terakhir adalah perhitungan *similarity score*. Untuk setiap input query, vector embedding nya akan dibandingkan terhadap seluruh vector pada Database menggunakan cosine similarity, kemudian hasilnya diurutkan dari skor tertinggi hingga terendah untuk membentuk daftar peringkat (ranked list). Perlu ditegaskan bahwa dalam penelitian ini cosine similarity berperan sebagai scoring function yang menghasilkan peringkat, bukan sebagai metrik evaluasi [21]. Ayat dengan skor kemiripan tertinggi dianggap sebagai hasil retrieval yang paling mendekati query, sedangkan kualitas keseluruhan peringkat akan diukur pada fase evaluasi menggunakan metrik yang sesuai.

3.5. Evaluation

Fase ini bertujuan untuk mengukur efektivitas retrieval dari kedua model secara kuantitatif dan menguji hipotesis penelitian berdasarkan hasil yang diperoleh. Pada fase inilah peringkat yang dihasilkan cosine similarity akan dinilai menggunakan metrik evaluasi retrieval. Metrik evaluasi menilai kualitas keseluruhan peringkat terhadap ground truth, bukan menghitung kemiripan antar vector [21]. Fase ini terdiri atas lima sub proses yaitu perhitungan metrik evaluasi, evaluasi layer-wise, pengujian hipotesis, perbandingan tiga scenario evaluasi terkontrol dan analisis kualitatif.

Sub proses pertama adalah perhitungan metrik evaluasi retrieval. Penelitian ini menggunakan tiga metrik berbasis kualitas peringkat, yaitu Top-K Accuracy, Mean Reciprocal Rank (MRR), dan Mean Average Precision (MAP). Top-K Accuracy mengukur proporsi query yang dokumen relevannya berhasil ditempatkan dalam K peringkat teratas,

dengan variasi nilai K berupa Top-1, Top-5, dan Top-10, dimana Top-1 berfungsi sebagai kriteria keberhasilan yang paling ketat. MRR mengukur seberapa tinggi peringkat dokumen relevan pertama, sedangkan MAP menilai kualitas peringkat secara menyeluruh dengan memperhitungkan presisi pada setiap posisi dokumen relevan sepanjang daftar. Ketiga metrik dihitung secara terpisah untuk Wav2vec2 dan Data2vec agar dapat dibandingkan secara langsung.

Sub proses kedua adalah evaluasi layer-wise. Ketiga metrik dihitung pada setiap lapisan transformer dari kedua model. Hasilnya disusun menjadi kurva kinerja terhadap indeks lapisan sehingga dapat diidentifikasi lapisan yang menghasilkan kinerja retrieval tertinggi bagi masing-masing model. Evaluasi ini menjadi dasar untuk menjawab pertanyaan penelitian mengenai apakah lapisan optimal bagi tugas retrieval fonetik berbeda dari lapisan yang selama ini dilaporkan optimal untuk tugas ASR, sekaligus menilai implikasinya terhadap pemilihan arsitektur.

Sub proses ketiga adalah pengujian hipotesis. Berdasarkan perbandingan nilai metrik antara kedua model pada lapisan optimalnya masing-masing, penelitian menguji dua hipotesis yang saling berkebalikan. Apabila Data2vec menghasilkan kinerja retrieval yang lebih tinggi, maka hipotesis pertama (H1) terkonfirmasi dan mendukung pandangan bahwa keunggulan representasi bersifat lintas tugas. Sebaliknya apabila Wav2vec2 yang lebih unggul, maka hipotesis kedua (H2) terkonfirmasi dan menunjukkan bahwa tugas retrieval mengukur dimensi kualitas representasi yang berbeda dari tugas ASR.

Sub proses keempat adalah perbandingan tiga scenario evaluasi dalam lingkungan yang terkontrol. Untuk memisahkan pengaruh kualitas representasi model dari pengaruh kualitas data, retrieval dijalankan pada tiga scenario yang berbagi satu protokol identik. Layer sweep pada dev set, pelaporan pada test set, serta uji signifikansi *bootstrap* namun berbeda pada sumber data query dan databasenya. Skenario A merupakan kondisi penelitian, yaitu query rekaman mahasiswa terhadap database Quran-MD (lintas dataset). Skenario B menggunakan Quran-MD pada kedua sisi dengan pembagian *leave-reciters-out*, sehingga query tidak muncul pada database, skenario ini menilai kualitas embedding pada kondisi akustik terkendali. Skenario C menggunakan data mahasiswa pada kedua sisi dengan pembagian *leave-students-out*, sehingga domain gap akustik dihilangkan sepenuhnya namun noise segmentasi tetap dipertahankan. Pada ketiga skenario, relevansi didefinisikan sebagai kesamaan pasangan (surah, ayat) lintas pembaca, sehingga tidak ada satu pembaca yang

muncul pada kedua sisi. Perbandingan skenario A dengan B mengisolasi pengaruh perbedaan domain akustik, sedangkan perbandingan skenario B dengan C mengisolasi pengaruh kualitas akuisisi dan segmentasi. Karena ketiga skenario memiliki ukuran database dan kerapatan dokumen relevan yang berbeda, nilai MAP dilaporkan bersama lift terhadap baseline acak agar perbandingan antar skenario bersifat jujur.

Sub proses terakhir adalah analisis kualitatif untuk melengkapi temuan kuantitatif. Analisis ini dilakukan melalui studi kasus mendalam terhadap query yang berhasil maupun gagal dalam proses retrieval. Kasus keberhasilan dan kegagalan ditelaah untuk menilai sensitivitas fonetik masing-masing model, misalnya mengidentifikasi kondisi ketika suatu model keliru mengambil ayat lain yang memiliki kemiripan bunyi atau pola matra yang tinggi. Hasil analisis ini digunakan untuk mengaitkan temuan empiris dengan justifikasi teori mengenai perbedaan struktur embedding yang dihasilkan oleh paradigma contrastive learning dan self-distillation.

3.6. Deployment

Fase Deployment pada penelitian ini diadaptasi dari makna aslinya dalam CRISP-DM. Karena penelitian bersifat komparatif dan fase ini tidak melibatkan penerapan model dalam sistem produksi. Melainkan berfokus pada sintesis temuan menjadi kesimpulan yang utuh serta perumusan rekomendasi bagi penelitian lanjutan. Fase ini terdiri atas tiga sub proses yaitu sintesis temuan, perumusan rekomendasi pemilihan model, dan identifikasi arah penelitian lanjutan.

Sub proses pertama adalah sintesis temuan. Seluruh hasil dari fase evaluation, baik opsiperbandingan metrik antar model, kurva kinerja, layer-wise, hasil pengujian hipotesis, maupun temuan dari analisis kualitatif, dirangkum menjadi satu kesimpulan yang menjawab rumusan masalah secara menyeluruh. Sintesis ini menegaskan model mana yang lebih unggul untuk tugas retrieval ayat Al-Quran berbasis frozen embedding, hipotesis mana yang terkonfirmasi, serta lapisan mana yang paling optimal bagi masing-masing model.

Sub proses kedua adalah perumusan rekomendasi pemilihan model. Berdasarkan temuan yang telah disintesis, penelitian merumuskan panduan praktis mengenai model dan konfigurasi lapisan yang paling sesuai untuk membangun sistem pencarian kemiripan ayat Al-Quran tanpa proses transkripsi maupun *fine-tuning*. Rekomendasi ini mempertimbangkan tidak hanya kualitas retrieval tertinggi, tetapi juga karakteristik representasi masing-masing paradigma pretraining sebagaimana terungkap dari hasil evaluasi.

Commented [MM19]: Sintesis temuan di sini maksudnya adalah proses **menggabungkan dan merangkai** semua hasil eksperimen yang sudah kamu dapatkan dari fase-fase sebelumnya (evaluasi model, hasil MAP, Top-K Accuracy, per kombinasi model+layer) menjadi satu **kesimpulan yang koheren dan bermakna** — bukan sekadar melaporkan angka satu-satu.

Sub proses terakhir adalah identifikasi arah penelitian lanjutan berdasarkan keterbatasan yang teridentifikasi selama penelitian, dirumuskan sejumlah arah pengembangan yang dapat ditempuh pada penelitian berikutnya. Arah tersebut mencakup, antara lain, penerapan constrastive fine-tuning untuk menguji apakah adaptasi ringan pada model pretrain dapat meningkatkan kualitas retrieval, perluasan cakupan data ke seluruh juz Al-Quran, serta pengujian model Self-Supervised Learning lain sebagai pembanding tambahan. Arah-arrah ini sekaligus menandai batas ruang lingkup penelitian saat ini dan potensi kontribusinya di masa mendatang.

BAB IV

HASIL DAN PEMBAHASAN

4.1. Hasil Business Understanding

Tahap Business understanding menghasilkan dua output utama sesuai alur penelitian, yaitu identifikasi masalah penelitian, yaitu identifikasi masalah penelitian beserta tujuan penelitian, serta penetapan hipotesis awal dan indicator keberhasilan. Kedua output ini menjadi fondasi arah seluruh proses penelitian yang dilaksanakan, mulai dari pengumpulan data audio hingga evaluasi kinerja retrieval kedua model yang dibandingkan.

4.1.1. Identifikasi Masalah

Proses identifikasi masalah dilakukan melalui kajian literatur terhadap penelitian terdahulu mengenai model Self-Supervised Learning (SSL) untuk pemrosesan suara, serta analisis terhadap penerapan model-model tersebut pada domain Bahasa Arab. Berdasarkan hasil identifikasi tersebut, ditemukan bahwa model SSL yang di-*pretrain* pada data berbahasa Inggris cenderung menurun kinerjanya ketika diterapkan pada fonetik Arab, yang memiliki karakteristik khas seperti *emphatic consonants* dan *pharyngeal sounds* yang tidak dimiliki Bahasa Inggris [29]. Al Qur'an, sebagai teks berbahasa Arab dengan kaidah tajwid yang ketat dan presisi tinggi, menjadikan tantangan ini semakin nyata karena pencocokan bacaan menuntut ketepatan pada aspek fonetik, bukan sekedar kecocokan tekstual.

Analisis lebih lanjut terhadap literatur mengungkapkan tiga kesenjangan utama. Pertama, seluruh bukti kegagalan lintas bahasa yang tersedia hanya terbatas pada arsitektur berbasis contrastive learning seperti wav2vec2, sementara kejadian terhadap paradigma self-distillation yang dimiliki Data2vec dalam skenario serupa masih sangat terbatas. Kedua, meskipun penelitian terdahulu telah membandingkan langsung wav2vec2 dan Data2vec untuk pengenalan ucapan (ASR) Bahasa Arab [10], perbandingan tersebut dilakukan dengan supervised fine-tuning dan diukur menggunakan metrik transkripsi (WER/CER) bukan dalam kondisi frozen embedding tanpa fine-tuning dengan metrik retrieval. Ketiga, perbandingan langsung kedua model untuk tugas audio retrieval yang dievaluasi melalui metrik similarity search seperti MAP, Top-K Accuracy, dan MRR hingga kini masih minim untuk diteliti, sehingga menyisakan pertanyaan fundamental apakah keunggulan salah satu paradigma pada ASR akan tetap berlaku pada retrieval.

Commented [MM20]: Emphatic consonants (konsonan tebal/velarized-pharyngealized)

Dalam Bahasa Arab, ada empat konsonan yang disebut *emphatic* (Arab: *hurūf al-ibbāq*): ط (t), ص (s), ض (d), ظ (z). Ini adalah versi "tebal" dari konsonan biasa ت (t), س (s), د (d), ذ (dh).

Commented [MM21]: 4.2.5. Non-EnglishSpeech Another question

....
likeAPCandWav2Vec2.0showsaseverely
performance degradation, yielding upto 30% relative increase of
the CER results

Kesenjangan ini menjadi penting karena retrieval dan transkripsi mengukur properti representasi yang berbeda. Pada ASR, fitur diteruskan ke kepala klasifikasi yang ikut dilatih secara *supervised*. Sehingga metrik seperti WER tidak murni mengukur kualitas embedding awal, melainkan separabilitas fitur setelah proses pelatihan tersebut. Sebaliknya, pada retrieval berbasis frozen embedding tidak ada komponen yang dilatih, sehingga metrik seperti MAP secara intrinsik mengukur koherensi geometris ruang vector itu sendiri [30]. Oleh karena itu, keunggulan sebuah model pada ASR tidak dapat langsung diasumsikan berlaku pada retrieval dan inilah celah yang menjadi fokus utama penelitian ini.

4.1.2. Tujuan Penelitian

Berdasarkan identifikasi masalah tersebut, ditetapkan tujuan penelitian ini menghasilkan rekomendasi arsitektur SSL yang paling optimal sebagai landasan teknis bagi pengembangan system audio retrieval ayat Al-Qur'an, khususnya untuk domain Bahasa Arab yang memiliki karakteristik fonetik khas. Untuk mencapai rekomendasi yang objektif, penelitian ini membandingkan dua model dengan paradigma pretraining yang berbeda, Wav2vec2 dengan paradigma contrastive learning dan Data2vec dengan paradigma Self-Distillation dalam skenario retrieval.

Tujuan tersebut dipaparkan dijelaskan dalam lebih detail menjadi tiga tujuan yang spesifik. Pertama, mengevaluasi kinerja retrieval frozen embedding wav2vec2 dan Data2vec pada metrik yang sama, yaitu MAP dan Top-K Accuracy, dengan cosine similarity sebagai fungsi *scoring*. Kedua, membandingkan kedua model secara statistik untuk menentukan apakah performa retrieval sejalan dengan performa ASR atau justru bersifat orthogonal, sebagai dasar penentuan model terbaik. Ketiga, menganalisis distribusi kinerja retrieval pada tiap lapisan (*layer-wise*) dari seluruh 13 lapisan kedua model untuk mengidentifikasi lapisan optimal bagi tugas retrieval fonetik, dengan skema pemilihan lapisan terbaik pada himpunan pengembangan 70% dan pelaporan akhir pada himpunan uji 30%.

4.1.3. Hipotesis dan kriteria keberhasilan

Sebagai acuan dalam mengevaluasi pencapaian tujuan penelitian, ditetapkan hipotesis awal beserta kriteria keberhasilan yang mencakup dua aspek, yaitu aspek validitas eksperimen dan aspek signifikansi perbandingan model.

Commented [MM22]: Kenapa cocok: Klaim kamu bilang keunggulan model A atas B pada ASR tidak otomatis berlaku di retrieval. Paper ini secara literal bilang hal yang setara tapi lebih umum: ranking antar model (siapa lebih unggul dari siapa) **berubah tergantung protokol evaluasi/downstream model** yang dipakai. ASR (fine-tuned, ada classification head) dan retrieval (frozen, MAP) adalah dua protokol evaluasi berbeda — jadi pernyataan mereka mencakup kasus spesifik kamu sebagai instance dari fenomena umum itu.

Perbedaan paradigma kedua model memunculkan dua hipotesis yang saling berkebalikan. Hipotesis pertama (H1) memperkirakan Data2vec tetap unggul, target prediksinya yang berupa representasi kontekstual laten penuh berpotensi menghasilkan fitur fonetik yang lebih kaya dan umum, sehingga keunggulannya diperkirakan bertahan pada domain retrieval. Hipotesis kedua (H2) memperkirakan sebaliknya, bahwa Wav2vec2 justru unggul pada domain retrieval, dikarenakan constrastive lossnya secara eksplisit menarik pasangan positif dan menolak kandidat negatif, sehingga cenderung membentuk ruang embedding yang lebih clusterable dan lebih selaras dengan pengukuran jarak cosine. Property yang justru menentukan pada retrieval, bukan pada ASR. Jika H1 terkonfirmasi, kualitas embedding terbukti bersifat lintas tugas. Jika H2 terkonfirmasi, retrieval terbukti mengukur dimensi kualitas representasi yang berbeda (ortogonal) dari ASR.

Pada aspek validitas eksperimen, kriteria keberhasilan meliputi keberhasilan ekstraksi seluruh pasangan query dan database menjadi embedding lapisan-per-lapisan tanpa kegagalan sistematis, serta terpenuhinya cakupan relevansi penuh, yaitu setiap ayat query memiliki setidaknya satu dokumen relevan di dalam database, sehingga tidak ada kueri yang dipaksa bernilai $MAP = 0$ secara artifisial. Klip yang gagal diekstraksi pada model manapun ditangani secara konsisten agar tidak masuk dalam perhitungan.

Pada aspek signifikansi perbandingan model, kriteria keberhasilan ditetapkan bukan pada ambang metrik absolut, melainkan pada kemampuan eksperimen untuk membedakan kinerja kedua model secara meyakinkan. Perbedaan MAP antara Data2vec dan Wav2vec2 pada himpunan uji dinilai signifikan apabila interval kepercayaan 95% yang dihitung melalui metode bootstrap (dengan $B = 1000$ resampling atas nilai average precision per-kueri) tidak memuat nilai nol. Terpenuhinya kriteria ini memungkinkan penelitian menyimpulkan secara tegas hipotesis mana H1 atau H2 yang didukung oleh bukti empiris, sekaligus menjawab tujuan penelitian.

4.2. Hasil Data Understanding

Data dalam skenario ini data terbagi menjadi dua kelompok. *ground truth* dan data testing, yang mana ground truth didapatkan dari Quran-MD [28], dan data testing didapatkan dari pengumpulan rekaman bacaan Al-Quran dari mahasiswa. Eksplorasi ini menghasilkan pemahaman mengenai cakupan, distribusi, serta kualitas data. Termasuk temuan yang

berimplikasi pada validitas valuasi. Quran-MD berupa parquet file yang berisikan file berikut.

Table 4 Atribut dan Tipe Data Quran-MD

Nama Column	Tipe Data
surah_id	Int32
ayah_id	Int32
Surah_name_ar	String
Surah_name_en	String
Surah_name_tr	String
Ayah_count	Int32
Ayah_ar	String
Ayah_tr	String
Reciter_id	String
Reciter_name	String
Audio	Audio File (MP3 format)

Adapun data query berbentuk berkas video yang masing-masing merupakan pembacaan satu surah Al-Qur'an secara penuh oleh seorang mahasiswa.

Karena evaluasi pada penelitian ini dijalankan pada skenario terkontrol (A, B, dan C) yang berbeda pada sumber data query dan databasenya, pemahaman data berikut mencakup kedua himpunan sekaligus, yaitu himpunan mahasiswa dan himpunan Quran-MD, beserta pembagiannya pada masing-masing skenario.

4.2.1. Karakteristik Himpunan data Mahasiswa

Himpunan data mahasiswa terdiri atas 7.119 file audio ayat yang direkam oleh 42 mahasiswa, tersebar pada 396 pasangan (mahasiswa, surah) dan mencakup 20 surah dari Juz Amma. Setiap berkas merepresentasikan bacaan satu surat oleh satu mahasiswa. Seluruh nama folder, meskipun memiliki variasi format penulisan, berhasil dinormalisasi dan dipetakan ke nomor surah standar yang sesuai. Tidak ada folder yang gagal dikenali atau tidak dapat ditentukan nomor surahnya.

Distribusi cakupan surah pada himpunan kueri sangat tidak seimbang. Beberapa surah direkam oleh mayoritas mahasiswa, misalnya 'Abasa dan Al-Balad, masing-masing oleh 32 mahasiswa sementara sejumlah surah lainnya (Al-Bayyina, Al-Humaza, dan Al-Masad) hanya direkam oleh satu mahasiswa, ketidakseimbangan ini penting dicatat karena metrik retrieval pada surah dengan cakupan sangat rendah akan memiliki variansi tinggi dan sensitif terhadap kesalahan tunggal, sebagaimana dibahas lebih lanjut pada evaluasi kelemahan penelitian.

4.2.2. Karakteristik Himpunan Data Quran-MD

Himpunan Quran-MD memuat 17.130 bacaan yang dibacakan oleh 30 qori mencakup surah Al-Fatihah dan Juz Amma (38 surah). Verifikasi integritas manifest menunjukkan 0 berkas hilang dan 0 identitas ayat kosong, sehingga seluruh entri valid sebagai target retrieval. Setiap klip beranotasi identitas ayat (nomor surah dan nomor ayat) secara akurat, yang menjadi dasar penentuan relevansi. Setiap klip beranotasi identitas ayat (nomor surah dan nomor ayat) secara akurat, yang menjadi dasar penentuan relevansi./

Himpunan Quran-MD berperan sebagai database pada scenario A dan sebagai query sekaligus database pada scenario B. pada scenario B, ke-30 qori dibagi secara leave-reciters-out dengan pembagian 9 qori sebagai query dan 21 qori sebagai database, sehingga tidak ada qori yang muncul pada kedua sisi.

4.2.3. Cakupan relevansi dan Ukuran Skenario

Aspek terpenting bagi validitas evaluasi adalah cakupan relevansi, yaitu jaminan bahwa setiap query memiliki setidaknya satu dokumen relevan pada database. Ukuran dan cakupan relevansi ketiga skenario setelah penyingkiran klip gagal dirangkum pada tabel berikut.

Table 5 Ukuran Data dan Cakupan Relevansi pada Setiap Skenario Evaluasi

Skenario	Klip Query	Klip Database	Cakupan Relevansi
A (Mahasiswa->Quran-MD)	7.118	17.127	100%
B (Quran-MD->Quran-MD)	5.139	11.988	100%
C (Mahasiswa->Mahasiswa)	2.452	4.666	99,31%

Pada scenario A dan B, seluruh ayat unik yang muncul sebagai query tercakup 100% oleh setidaknya satu klip pada database, sehingga tidak ada query yang secara artifisial dipaksa bernilai $MAP = 0$ akibat ketiadaan dokumen relevan. Pada scenario C, cakupan relevansi mencapai 99,31% sebanyak 17 query tidak memiliki dokumen relevan pada database dan dikeluarkan dari perhitungan metrik, sehingga dari 2.452 klip query terdapat 2.435 query yang tercakup dan dievaluasi.

4.2.4. Kualitas Data

Eksplorasi mengungkap dua temuan kualitas yang harus dilaporkan secara transparan. Pertama karena segmentasi ayat pada himpunan query dilakukan secara manual, audit menemukan bahwa dari 396 pasangan (mahasiswa, surah), 353 berstatus lengkap sesuai dengan jumlah ayat pada surah, sedangkan 43 berstatus tidak lengkap yaitu jumlah berkas hasil segmentasi kurang dari jumlah ayat sebenarnya. Kasus paling ekstrem adalah satu mahasiswa pada surah Al-Fil yang hanya menghasilkan 1 dari 5 ayat. Ketidaklengkapan ini mengindikasikan potensi kesalahan segmentasi pada sebagian kecil data.

Kedua, pada tahap ekstraksi embedding teridentifikasi sejumlah klip yang gagal diproses karena durasi audio sangat pendek. 1 Klip pada himpunan query dan 3 klip pada database. Klip-klip ini ditangani secara khusus agar tidak menjadi data yang kurang bagus dalam perhitungan kemiripan. Sebagaimana yang telah diuraikan dalam data preparation.

4.3. Hasil Data Preparation

4.3.1. Normalisasi Audio

Seluruh berkas audio pada himpunan query dan database diseragamkan ke sampling rate 16 khz dengan kanal mono, sesuai dengan spesifikasi masukan yang disyaratkan oleh kedua model pretrained Wav2vec2 dan Data2vec. Normalisasi ini memastikan bahwa perbedaan format perekaman antara rekaman query, yang diupload mahasiswa dan rekaman pada Quran-MD tidak menjadi sumber variasi yang ditakutkan malah menjadi variable penentu hasil performa model SSL.

4.3.1.1. Normalisasi Data *Ground Truth*

Normalisasi audio dilakukan melalui pipeline pemrosesan bertahap untuk memastikan memastikan semua data memenuhi syarat untuk tiap model SSL. Dataset Quran-MD disimpan dalam format *Parquet* dengan audio terkompresi MP3 (bitrate 64kbps) sebagai raw bytes. Proses ekstraksi dan konversi mengikuti tahapan berikut

1. Ekstraksi Audio dari *Parquet*

Dalam proses ini digunakan library *datasets* dan *soundfile*. Audio dalam *parquet* disimpan sebagai struktur {bytes, path} dengan format MP3. Library *datasets* secara default melakukan decoding otomatis menggunakan *soundfile*, yang mana tidak mendukung format MP3. Oleh karena itu, decoding otomatis dinonaktifkan `cast_column("audio", Audio(decode=False))` untuk mengakses raw byte secara langsung.

2. Decoding MP3 dengan *librosa*

Raw bytes MP3 didecode menggunakan *librosa.load()* dengan parameter `sr=None` untuk mempertahankan sampling rate asli tanpa resampling paksa. Pendekatan ini mencegah degradasi kualitas akibat double resampling. Fungsi ini mengembalikan numpy array dengan shape (channels, samples) dan sampling rate asli.

3. Resampling menjadi 16kHz

Audio dengan sampling rate tidak sama dengan 16kHz dilakukan resampling menggunakan *librosa.resample()* dengan algoritma polyphase filtering default. Resampling ini menggunakan anti-aliasing filter untuk mencegah aliasing artifacts yang dapat mengganggu ekstraksi fitur audio downstream.

4. Konversi ke Mono

Audio stereo (jika ada) dikonversi ke mono menggunakan *librosa.to_mono()* dengan melakukan averaging pada channel. Meskipun dataset Quran-MD secara default sudah mono, langkah ini ditambahkan sebagai safeguard untuk menangani kasus edge.

5. Penyimpanan WAV PCM 16-bit

Audio yang telah dinormalisasi disimpan dalam format WAV dengan encoding PCM 16-bit menggunakan *soundfile.write()*. Format ini dipilih karena:

- Lossless compression (tidak ada degradasi kualitas)

- Kompatibilitas universal dengan library audio processing
- Sesuai dengan requirement input Wav2Vec2 dan Data2Vec2

4.3.1.2. Normalisasi data query (testing)

Tahapan data preparation pada data query yaitu mentransformasi rekaman video setoran hafalan mahasiswa menjadi unit-unit audio per ayat yang diperuntukkan untuk proses berikutnya. Proses ini melibatkan ekstraksi audio, penyelarasan teks ke suara (force alignment) dan pemotongan audio secara otomatis.

1. Ekstraksi Audio

Seluruh berkas video dalam format .mp4, .mov, .avi, .mkv yang diunggah oleh mahasiswa diekstraksi komponen audionya saja. Proses ini menggunakan library *moviepy* untuk aliran audio dari video kedalam format MP3.

2. Normalisasi Nama surah dan Nama berkas

Mengingat variasi penamaan berkas oleh mahasiswa (contoh: "78-annaba", "an-nas.mp4", "114. an nas"), dilakukan proses normalisasi teks untuk memetakan nama berkas ke ID surah yang valid pada dataset Quran. Proses ini meliputi

- 2.1. *Character Cleaning*: menghapus angka diawal nama, mengubah separator (dash/underscore) menjadi spasi, dan menghapus karakter non-alfanumerik.
- 2.2. *String Mapping*: memastikan file dengan termapping dengan benar, contohnya: surah ke 78 yaitu An-Naba jika hanya diberikan nama "naba" maka akan menjadi "an-naba" . yang mana "an-naba" merupakan value yang telah disetarakan dan menjadi master nama surah ke 78.

3. Transkripsi dan penyelarasan waktu (*Force Alignment*)

Untuk membagi satu audio utuh surah menjadi potongan per ayat, digunakan model WhisperX (berbasis-model large-v2). Prosesnya sebagai berikut

- Transkripsi Bahasa Arab: Model melakukan inferensi awal untuk mendeteksi kata-kata dalam bahasa Arab.

- Phoneme-level Alignment: Menggunakan model penyalarsan khusus untuk mendapatkan stempel waktu (*timestamp*) yang presisi di tingkat kata.
- Identifikasi Awal Surah: Sistem secara otomatis mendeteksi kata pertama dari surah (seperti 'amma pada An-Naba) untuk melewati bagian *ta'awwudh* atau pengenalan (*intro*) yang dilakukan oleh mahasiswa

4. Segmentasi Ayat berbasis Rasio Kata

Setelah stempel waktu kata didapatkan, dilakukan pembagian audio berdasarkan jumlah kata tiap ayat yang bersumber dari [API Al-Quran Cloud](http://api.alquran.cloud/v1/juz/30/quran-uthmani). Audio dipotong menggunakan *pydub* berdasarkan rentang waktu mulai dari kata pertama ayat hingga kata terakhir ayat tersebut. Hasil akhirnya adalah berkas audio individu (ayah_01.mp3, ayah_02.mp3, dst) dengan format PCM yang terorganisir dalam direktori per mahasiswa dan per surah.

Commented [MM23]: <http://api.alquran.cloud/v1/juz/30/quran-uthmani>

4.3.2. Pembagian set *dev* dan set *test*

Untuk menjamin pemilihan lapisan optimal tidak bias terhadap data yang sama yang digunakan untuk pelaporan akhir, himpunan query dibagi menjadi dua bagian set pengembangan 70%, dan set uji 30%. Pembagian dilakukan secara terstratifikasi berdasarkan pasangan (nomor surah, dan nomor ayat), sehingga distribusi ayat pada kedua set tetap seimbang dan tidak ada ayat yang sepenuhnya hilang dari salah satu set. Set pengembangan digunakan untuk menyapu seluruh lapisan (*layer sweep*) dan memilih lapisan dengan MAP tertinggi bagi masing-masing model, sedangkan set uji digunakan semata-mata untuk melaporkan kinerja akhir pada lapisan terpilih. Protocol dua-set ini mengikuti praktik standar evaluasi *query-by-example* pada tolak ukur SUPERB [3], yaitu memilih lapisan terbaik pada set pengembangan dan melaporkannya pada set uji, guna menghindari kebocoran informasi yang dapat menghasilkan estimasi kinerja yang terlalu optimis.

4.4. Modeling

Fase Modeling dilakukan untuk mengekstrak frozen embedding dari kedua model Self-Supervised Learning tanpa proses fine-tuning, kemudian menghitung skor kemiripan untuk menghasilkan retrieval.

4.4.1. Ekstraksi Frozen Embedding per-lapisan

Kedua model, Wav2vec2 dan Data2vec, digunakan dalam kondisi *frozen* yaitu seluruh bobot model dipertahankan sebagaimana hasil pretraining, tanpa pembaruan parameter apapun. Dari setiap klip audio diekstraksi representasi pada 13 lapisan (satu lapisan proyeksi fitur dan dua belas lapisan Transformer), masing-masing berdimensi 768. Untuk memperoleh satu vector tetap per klip, representasi tingkat frame pada tiap lapisan diagregasi melalui mean pooling sepanjang dimensi waktu, sehingga setiap klip direpresentasikan oleh satu vector berdimensi 768 pada tiap lapisan.

Ekstraksi dilakukan secara terpisah untuk himpunan query (7.119 Klip) dan *database reference* (17.130 klip) pada kedua model. Urutan untuk ekstraksi harus dijaga, dikarenakan vector pada indeks yang sama baik pada Wav2vec2 maupun Data2vec selalu merujuk pada klip audio yang sama. Konsistensi ini merupakan prasyarat agar perbandingan kinerja kedua model bersifat adil dan bebas dari ketidakselarasan data. Verifikasi menunjukkan seluruh keluaran bebas dari nilai NaN, dengan hanya klip gagal yang telah ditangani pada fase sebelumnya.

4.4.2. Data Cleaning

Berbeda dengan normalisasi audio yang menyeragamkan format masukan, tahap data cleaning bertujuan menyingkirkan klip yang gagal menghasilkan embedding valid agar tidak mencemari perhitungan kemiripan. *Cleaning* dilakukan secara bertahap mengikuti alur ekstraksi embedding.

4.4.2.1. Deteksi klip gagal saat ekstraksi

Pada saat frozen embedding, setiap klip diproses satu per satu oleh masing-masing model. Sejumlah kecil klip gagal diproses karena durasinya terlalu pendek, sehingga jumlah frame yang tersisa setelah melewati encoder konvolusi pada lapisan pertama tidak mencukupi untuk membentuk representasi. Kegagalan ini ditangkap sebagai pengecualian pada saat pemanggilan model. Klip yang gagal akan tetap disimpan pada buffer sebagai vector nol dan ditandai melalui kolom failed pada manifest output. Kegagalan teridentifikasi pada 1 klip di himpunan query (Surah Al-Fil ayat pertama) dan 3 klip pada database referensi.

4.4.2.2. Vektor Nol

Vektor nol berbahaya bagi evaluasi berbasis cosine similarity karena menghasilkan skor kemiripan nol (atau tidak terdefinisi/NaN) terhadap seluruh kandidat. Akibatnya urutan peringkat klip terbuset menjadi acak dan dapat merusak perhitungan MAP maupun MRR secara tidak disadari.

4.4.2.3. Penjaminan Keselarasan Baris

Mekanisme union menjaga keselarasan baris (row alignment) antar kedua model. Setiap indeks query dan referensi merujuk pada klip yang identik, sehingga perbandingan kinerja kedua model itu selaras dan tidak ada perbedaan data. Verifikasi terakhir memastikan himpunan data bersih tidak lagi memuat vektor bernilai nol maupun NaN.

4.4.3. Similarity Scoring dan Ranking

Peringkat retrieval dibentuk dengan menghitung cosine similarity antara vector embedding setiap query dan seluruh vector embedding dalam basis data referensi pada lapisan yang sama. Untuk setiap query, seluruh klip referensi diurutkan menurun berdasarkan skor peringkat teratas.

Perlu ditegaskan bahwa cosine similarity di sini berperan sebagai scoring function yang menentukan urutan peringkat bukan sebagai metrik evaluasi. Pemilihan cosine similarity sesuai dengan sifat retrieval berbasis frozen embedding, yang mengukur kedekatan arah antar vector pada ruang representasi tanpa bergantung pada magnitudonya. Kualitas peringkat yang dihasilkan selanjutnya dievaluasi menggunakan metrik MAP, Top-K Accuracy, dan MRR pada fase *Evaluation*.

4.5. Evaluation

Pada penelitian ini hasil akan dievaluasi per rumusan masalah, setiap temuan dipaparkan lalu langsung dibahas sebelum berpindah pada persoalan yang lainnya. Untuk menjaga objektivitas, himpunan query dibagi menjadi dua bagian yang tidak terikat melalui pemisahan terstratifikasi berdasarkan pasangan (surah, ayat) dev set (4.886 query, 70%) dan test set (2.232 query, 30%). Stratifikasi memastikan setiap ayat terwakili secara proporsional pada kedua himpunan, sehingga distribusi ayat akan merata.

Dev set digunakan sebagai tahap **penalaan**, seluruh 13 lapisan representasi tiap model diuji, dan lapisan dengan MAP tertinggi dipilih sebagai konfigurasi terbaik (Wav2vec2

Commented [MM24]: Penalaan secara spesifik merujuk pada pemilihan hyperparameter/konfigurasi, bukan pembaruan bobot lewat backpropagation. Karena skripsimu eksplisit menggunakan frozen embeddings (bobot model tidak diubah), pemilihan "penalaan lapisan" (*layer tuning* atau *layer selection*) adalah istilah yang tepat—ini membedakan pendekatanmu dari fine-tuning konvensional yang mengubah bobot model.

lapisan 7 dan Data2vec lapisan 5). Test set yang tidak pernah disentuh selama pemilihan lapisan-baru digunakan pada tahap akhir untuk melaporkan metrik final. Pemisahan ini krusial untuk menghindari bias seleksi, apabila lapisan terbaik dipilih dan dilaporkan pada data yang sama, skor yang dihasilkan akan cenderung tinggi. Dengan memisahkan tahap pemilihan (dev set) dari tahap pelaporan (test set), skor akhir yang diperoleh benar-benar mencerminkan kemampuan generalisasi model secara adil.

Proses retrieval itu sendiri dilakukan sebagai berikut, setiap vector embedding query dibandingkan terhadap seluruh 17.130 vektor pada database referensi menggunakan cosine similarity sebagai *scoring function*. Hasilnya akan dilakukan perankingan berdasarkan skor. Dan signifikansi bootstrap ($B = 10.000$) pada selisih MAP per-query menentukan apakah perbedaan antar model bermakna secara statistic atau sekadar fluktuasi acak.

4.5.1. Rumusan Masalah 1 – Kinerja Retrieval Frozen Embedding

Pada test set, konfigursi terbaik masing-masing model menghasilkan kinerja sebagai berikut

Model	Lapisan Terbaik	MAP	MRR	Top-1	Top-5	Top-10
Wav2vec2	7	0,0178	0,1146	0,0730	0,1496	0,1904
Data2vec	5	0,0188	0,1124	0,0699	0,1465	0,1935

Kedua Model menunjukkan kinerja retrieval yang rendah secara absolut (MAP di bawah 0,02 dan Top-1 di bawah 8%). Analisis per-query pada test set menegaskan pola ini, dari 2.232 query, tidak ada satu pun yang mencapai Average Precision sempurna, sekaligus tidak ada query yang bernilai nol, artinya setiap query berhasil menarik setidaknya satu klip relevan ke dalam peringkat. Namun, tidak ada yang diperingkatkan secara bersih di posisi teratas. Temuan ini mengindikasikan bahwa frozen embedding dari model SSL, dipadukan dengan scoring function cosine similarity, belum memadai sebagai basis retrieval ayat yang andal tanpa adaptasi lebih lanjut.

4.5.2. Rumusan Masalah 2 – Perbandingan Wav2vec2 dan Data2vec

Selisih MAP antar model pada test set adalah +0,0009 (data2vec di atas Wav2vec2). Uji signifikansi bootstrap ($B = 10.000$) menghasilkan selang kepercayaan 95% -0,00005, +0,0024 yang memnuat nol, sehingga perbedaan tidak signifikan secara statistic. Secara per

kueri, Data2vec unggul pada 1.164 query dan Wav2vec2 1.068 query, perbandingan ini nyaris seimbang

Berdasarkan kriteria keberhasilan yang ditetapkan signifikansi via bootstrap CI, bukan ambang absolut), hipotesis H1 maupun H2 tidak terkonfirmasi, sehingga tidak terdapat bukti statistic bahwa salah satu model unggul untuk tugas retrieval ayat berbasis cosine similarity. Keunggulan tipis Data2vec bersifat nominal dan tidak dapat dibedakan dari fluktuasi acak. Temuan ini menunjukkan bahwa keunggulan Data2vec pada ASR Bahasa Arab [10], tidak dapat digeneralisasi begitu saja ke tugas retrieval berbasis embedding tanpa transkripsi. Dengan demikian, temuan ini sekaligus menjawab celah penelitian yang diangkat dalam studi ini.

4.5.3. Rumusan Masalah 3 – Lapisan paling informatif


Lapisan tapisan terbaik terletak di pertengahan jaringan wav2vec2, lebih tepatnya pada lapisan 7 dan Data2vec pada lapisan 5, lapisan terbaik pada kedua model untuk tugas retrieval ternyata bukan pada lapisan terakhir. Kinerja menaik dari lapisan awal, memuncak di pertengahan, lalu menurun pada lapisan akhir (Wav2vec2 L12 MAP=0,0054, Data2vec L12=0,0062).

Pola *inverted-U* ini konsisten dengan literatur analisis layer-wise pada model SSL audio [27], yang menunjukkan bahwa lapisan akhir cenderung terspesialisasi bagi tujuan pretraining dan kehilangan Sebagian informasi fonetik yang justru berguna bagi tugas retrieval. Temuan ini menvalidasi keputusan metodologis menyapu seluruh 13 lapisan alih-alih mengasumsikan lapisan akhir sebagai representasi terbaik.

Commented [MM25]: Inverted-U itu artinya "berbentuk U yang dibalik" — kayak bentuk gunung, bukan kayak mangkuk.

Bayangkan kamu lagi main ayunan:

- Di awal (baru mulai ayun) → pelan, belum seru
- Di **tengah-tengah** (ayunan lagi kenceng-kencengnya) → paling seru, paling tinggi!
- Di **akhir** (ayunan mulai berhenti) → pelan lagi, nggak seru lagi



4.6. Deployment (Pertimbangan Penerapan)

Fase Deployment pada penelitian ini tidak berupa penerapan sistem pada lingkungan produksi. Melainkan pertimbangan penerapan dari temuan yang diperoleh, mengingat penelitian yang dilakukan adalah komparatif dan menghasilkan prototype. Bukan siap pakai.

4.6.1. Skema Penerapan Sistem Retrieval

Secara arsitektural, sistem retrieval berbasis frozen embedding dapat diterapkan melalui tiga tahap yang pertama yaitu proses ekstraksi untuk data ground truth pada database referensi menjadi vector embedding, kemudian mengekstraksi data audio query dari lapisan model Wav2vec2 dan Data2vec yang terbaik lalu dibandingkan dengan database referensi menggunakan scoring function cosine similarity, lalu proses terakhir dibuatkan perankingan hasil mana yang paling cocok dengan data yang ada di database referensi berdasarkan kemiripannya. Skema ini efisien karena ekstraksi referensi hanya perlu dilakukan sekali, sedangkan untuk proses pencarian cukup menghitung cosine similarity pada vektor yang sudah tersimpan.

4.6.2. Kelayakan penerapan berdasarkan temuan

Namun demikian, kinerja yang diperoleh belum memenuhi kelayakan untuk penerapan operasional. Dengan MAP di bawah 0,02 dan Top-1 di bawah 8%, sistem dalam kondisinya saat ini belum dapat diandalkan sebagai alat pencarian ayat yang akurat bagi pengguna akhir. Oleh karena itu, penerapan nyata mensyaratkan peningkatan terlebih dahulu, misalnya melalui fine-tuning pada domain, pembelajaran metrik (metric learning), atau strategi agregasi embedding yang lebih canggih daripada mean pooling.

DAFTAR PUSTAKA

- [1] A. Baevski, H. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A Framework for Self-Supervised Learning of Speech Representations," Oct. 22, 2020, *arXiv*: arXiv:2006.11477. doi: 10.48550/arXiv.2006.11477.
- [2] P. C. English, J. D. Kelleher, and J. Carson-Berndsen, "Searching for Structure: Appraising the Organisation of Speech Features in wav2vec 2.0 Embeddings," in *Interspeech 2024*, ISCA, Sep. 2024, pp. 4613–4617. doi: 10.21437/Interspeech.2024-2047.
- [3] W. Öberg, "Query-by-Example Audio Search using Acoustic Word Embeddings: Transforming wav2vec 2.0 Embeddings using Contrastive Learning," 2025.
- [4] M. Shanbhogue *et al.*, "Gemini Embedding 2: A Native Multimodal Embedding Model from Gemini," May 26, 2026, *arXiv*: arXiv:2605.27295. doi: 10.48550/arXiv.2605.27295.
- [5] Y. Chen *et al.*, "WavRAG: Audio-Integrated Retrieval Augmented Generation for Spoken Dialogue Models," Feb. 20, 2025, *arXiv*: arXiv:2502.14727. doi: 10.48550/arXiv.2502.14727.
- [6] H. Toyin, A. Djanibekov, A. Kulkarni, and H. Aldarmaki, "ArTST: Arabic Text and Speech Transformer," in *Proceedings of ArabicNLP 2023*, Singapore (Hybrid): Association for Computational Linguistics, 2023, pp. 41–51. doi: 10.18653/v1/2023.arabicnlp-1.5.
- [7] S. S. Li, B. Xu, X. Zhang, H. Liu, W. Chao, and L. P. Garcia, "A Quantitative Approach to Understand Self-Supervised Models as Cross-lingual Feature Extractors," 2023.
- [8] A. Baevski, W.-N. Hsu, Q. Xu, A. Babu, J. Gu, and M. Auli, "data2vec: A General Framework for Self-supervised Learning in Speech, Vision and Language," Oct. 25, 2022, *arXiv*: arXiv:2202.03555. doi: 10.48550/arXiv.2202.03555.
- [9] H. Xue, Q. Shao, P. Chen, P. Guo, L. Xie, and J. Liu, "TranUSR: Phoneme-to-word Transcoder Based Unified Speech Representation Learning for Cross-lingual Speech Recognition," in *INTERSPEECH 2023*, Aug. 2023, pp. 216–220. doi: 10.21437/Interspeech.2023-746.
- [10] L. Alkanhal, A. Alessa, E. Almahmoud, and R. Alaql, "Aswat: Arabic Audio Dataset for Automatic Speech Recognition Using Speech-Representation Learning," in *Proceedings of ArabicNLP 2023*, Singapore (Hybrid): Association for Computational Linguistics, 2023, pp. 120–127. doi: 10.18653/v1/2023.arabicnlp-1.10.
- [11] N. San *et al.*, "Leveraging pre-trained representations to improve access to untranscribed speech from endangered languages," Sep. 14, 2021, *arXiv*: arXiv:2103.14583. doi: 10.48550/arXiv.2103.14583.
- [12] C. Tang, Y. Wang, X. Chen, and W.-Q. Zhang, "Exploring Effective Fusion Algorithms for Speech Based Self-Supervised Learning Models," Dec. 20, 2022, *arXiv*: arXiv:2212.10092. doi: 10.48550/arXiv.2212.10092.
- [13] J. W. Yoon, S. M. Kim, and N. S. Kim, "MCR-Data2vec 2.0: Improving Self-supervised Speech Pre-training via Model-level Consistency Regularization," Jun. 14, 2023, *arXiv*: arXiv:2306.08463. doi: 10.48550/arXiv.2306.08463.
- [14] S. Yang *et al.*, "A Large-Scale Evaluation of Speech Foundation Models," May 29, 2024, *arXiv*: arXiv:2404.09385. doi: 10.48550/arXiv.2404.09385.
- [15] Y. Xie, Z. Zhang, and Y. Yang, "Siamese Network with wav2vec Feature for Spoofing Speech Detection," in *Interspeech 2021*, ISCA, Aug. 2021, pp. 4269–4273. doi: 10.21437/Interspeech.2021-847.
- [16] Z. Li, L. Wu, T. Li, and Y. Yan, "Improves Neural Acoustic Word Embeddings Query by Example Spoken Term Detection with Wav2vec Pretraining and Circle Loss," in *2021 12th International Symposium on Chinese Spoken Language Processing (ISCSLP)*, Hong Kong: IEEE, Jan. 2021, pp. 1–5. doi: 10.1109/ISCSLP49672.2021.9362065.
- [17] S. J. Russell, S. Russell, and P. Norvig, *Artificial Intelligence: A Modern Approach*. in Pearson series in artificial intelligence. Pearson, 2020. [Online]. Available: <https://books.google.co.id/books?id=koFptAEACAAJ>

- [18] T. M. Mitchell, *Machine learning*, Nachdr. in McGraw-Hill series in Computer Science. New York: McGraw-Hill, 2013.
- [19] I. Goodfellow, Y. Bengio, and A. Courville, *Deep learning*. in Adaptive computation and machine learning. Cambridge, Mass: The MIT press, 2016.
- [20] A. Vaswani *et al.*, “Attention Is All You Need,” Aug. 02, 2023, *arXiv*: arXiv:1706.03762. doi: 10.48550/arXiv.1706.03762.
- [21] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*, 1st ed. Cambridge University Press, 2008. doi: 10.1017/CBO9780511809071.
- [22] T. Wang and P. Isola, “Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere,” Aug. 15, 2022, *arXiv*: arXiv:2005.10242. doi: 10.48550/arXiv.2005.10242.
- [23] D. Ulyanov, A. Vedaldi, and V. Lempitsky, “Instance Normalization: The Missing Ingredient for Fast Stylization,” Nov. 06, 2017, *arXiv*: arXiv:1607.08022. doi: 10.48550/arXiv.1607.08022.
- [24] J. L. Ba, J. R. Kiros, and G. E. Hinton, “Layer Normalization,” Jul. 21, 2016, *arXiv*: arXiv:1607.06450. doi: 10.48550/arXiv.1607.06450.
- [25] E. Schubert, “A Triangle Inequality for Cosine Similarity,” vol. 13058, 2021, pp. 32–44. doi: 10.1007/978-3-030-89657-7_3.
- [26] C. Schröer, F. Kruse, and J. M. Gómez, “A Systematic Literature Review on Applying CRISP-DM Process Model,” *Procedia Comput. Sci.*, vol. 181, pp. 526–534, 2021, doi: 10.1016/j.procs.2021.01.199.
- [27] A. Pasad, B. Shi, and K. Livescu, “Comparative Layer-Wise Analysis of Self-Supervised Speech Models,” in *ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Rhodes Island, Greece: IEEE, Jun. 2023, pp. 1–5. doi: 10.1109/ICASSP49357.2023.10096149.
- [28] M. U. Salman, M. A. Qazi, and M. T. Alam, “Quran-MD: A Fine-Grained Multilingual Multimodal Dataset of the Quran,” Jan. 25, 2026, *arXiv*: arXiv:2601.17880. doi: 10.48550/arXiv.2601.17880.
- [29] X. Chang *et al.*, “An Exploration of Self-Supervised Pretrained Representations for End-to-End Speech Recognition,” Oct. 09, 2021, *arXiv*: arXiv:2110.04590. doi: 10.48550/arXiv.2110.04590.
- [30] S. Zaiem, Y. Kemiche, T. Parcollet, S. Essid, and M. Ravanelli, “Speech Self-Supervised Representations Benchmarking: a Case for Larger Probing Heads,” Feb. 21, 2024, *arXiv*: arXiv:2308.14456. doi: 10.48550/arXiv.2308.14456.