

Alur Fase Data Understanding pada Kerangka CRISP-DM

Mulai: Fase Data Understanding

1. Collect Initial Data

- Mengakses dataset Quran-MD (HuggingFace), sub-dataset tingkat ayat
- Mendokumentasikan struktur: audio, teks Arab, metadata qori
- Menyeleksi cakupan sesuai batasan: Surah Al-Fatihah + Juz Amma

2. Describe Data (Sifat Permukaan)

- Format berkas audio (mp3)
- Sampling rate asli & jumlah kanal (mono/stereo)
- Cakupan: jumlah surah, ayat unik, dan jumlah qori

3. Explore Data (EDA)

- Distribusi jumlah qori per ayat (menentukan $|R|$ untuk MAP/MRR)
- Distribusi durasi rekaman antar-ayat (dampak ke temporal pooling)
- Distribusi jumlah ayat per surah pada subset

4. Verify Data Quality

- Ayat kekurangan variasi qori (tak punya pasangan relevan)
- Rekaman rusak / terpotong / derau berlebih
- Konsistensi anotasi batas ayat (satu berkas = satu ayat utuh)

Revisi Business Understanding

- atau batasan (iteratif)

Tidak

Data layak & mendukung tujuan?

Ya

Lanjut ke Fase Data Preparation